

Analisis Pengaruh Strategi Fine-Tuning Dua Tahap terhadap Akurasi Pengenal Emosi Ucapan Berbahasa Indonesia

PROPOSAL SKRIPSI

Disusun oleh:

Gaung Taqwa Indraswara

NIM: 235150207111043



PROGRAM STUDI TEKNIK INFORMATIKA

DEPARTEMEN TEKNIK INFORMATIKA

FAKULTAS ILMU KOMPUTER

UNIVERSITAS BRAWIJAYA

MALANG

2026

DAFTAR ISI

1	Pendahuluan	1
1.1	Latar Belakang	1
1.2	Rumusan Masalah	2
1.3	Rumusan Hipotesis	3
1.4	Tujuan	3
1.5	Manfaat	4
1.6	Batasan Masalah	4
1.7	Sistematika Pembahasan	5
1.8	Jadwal Penelitian	5
2	Landasan Kepustakaan	7
2.1	Kajian Pustaka	7
2.2	Speech Emotion Recognition (SER)	8
2.3	Pembelajaran Self-Supervised	8
2.4	Wav2Vec2/XLSR	9
2.5	Cross-Lingual Transfer pada Pemrosesan Ucapan	10
2.6	Strategi Fine-Tuning Dua Tahap	10
2.7	Low-Rank Adaptation (LoRA)	11
2.8	Validasi Silang K-Fold dan Pengujian Signifikansi Statistik	12
2.9	Metrik Evaluasi	12
2.9.1	Akurasi, Presisi, Recall, dan F1-Score	12
2.9.2	Waktu Pelatihan dan Penggunaan Memori	13
3	Metodologi Penelitian	14
3.1	Tipe Penelitian	14
3.2	Studi Literatur	16
3.3	Pengumpulan Data	16
3.4	Fine-Tuning Sumber	17
3.5	Fine-Tuning Target	17
3.6	Evaluasi K-Fold	18
3.7	Analisis Kinerja Komputasi	18
3.8	Analisis Hasil	18
3.9	Kesimpulan dan Saran	19
3.10	Peralatan Pendukung	19
3.10.1	Perangkat Lunak (Software)	19
3.10.2	Perangkat Keras (Hardware)	19
	Daftar Referensi	21
	Lampiran	23

DAFTAR GAMBAR

2.1	Alur umum sistem speech emotion recognition	8
2.2	Alur umum pembelajaran self-supervised	9
2.3	Arsitektur Wav2Vec2	9
2.4	Alur umum cross-lingual transfer	10
2.5	Alur strategi fine-tuning dua tahap	11
2.6	Arsitektur Low-Rank Adaptation (LoRA)	11
2.7	Ilustrasi satu putaran validasi silang k-fold ($k = 5$); peran fold sebagai data uji bergantian pada setiap putaran hingga kelima fold pernah menjadi data uji	12
3.1	Diagram alir metode penelitian	15

DAFTAR TABEL

1.1	Jadwal penelitian	6
2.1	Daftar penelitian terdahulu	7
3.1	Karakteristik dataset yang digunakan	16
3.2	Empat kondisi eksperimen (desain 2×2)	17
3.3	Estimasi kecukupan VRAM per kartu (6GB)	20

BAB 1 PENDAHULUAN

1.1 Latar Belakang

Emosi merupakan komponen mendasar yang menyertai hampir setiap bentuk komunikasi antarmanusia, karena emosi memungkinkan seseorang menyampaikan maksud dan keadaan batin secara lebih utuh daripada makna literal kata-kata. Melalui emosi, seseorang dapat menunjukkan empati dan menyesuaikan responsnya terhadap lawan bicara, sehingga interaksi menjadi lebih bermakna dan manusiawi. Dalam interaksi manusia dan mesin, pengenalan emosi dari sinyal ucapan memegang peranan penting bagi pengembangan komputasi afektif dan sistem interaktif yang mampu merespons pengguna secara lebih personal (Dar and Delhibabu, 2024). Tanpa kemampuan tersebut, sistem cenderung memperlakukan seluruh pengguna secara seragam, padahal keadaan emosional yang berbeda semestinya direspons secara berbeda pula. Oleh karena itu, kajian mengenai pengenalan emosi secara otomatis terus berkembang dan relevan lintas disiplin.

Di antara berbagai saluran ekspresi emosi seperti raut wajah, gestur tubuh, dan tulisan, suara manusia menempati posisi istimewa karena emosi dapat tersampaikan langsung melalui pola intonasi, tekanan, kecepatan, dan ritme saat seseorang berbicara. Ciri ini sering muncul spontan dan sulit disembunyikan, sehingga ucapan kerap dianggap sumber informasi emosi yang relatif jujur dibandingkan saluran ekspresi lain. Karakteristik inilah yang mendasari berkembangnya *speech emotion recognition* (SER), yaitu bidang kajian yang berupaya mengenali kondisi emosi seseorang secara otomatis dari sinyal ucapannya. Tinjauan pustaka Dar and Delhibabu (2024) menunjukkan bahwa SER telah menjadi perhatian penting dalam pengembangan sistem interaksi manusia-mesin dan komputasi afektif, dengan cakupan penerapan yang terus meluas. Luasnya cakupan tersebut menunjukkan bahwa SER bukan sekadar topik teoretis, melainkan teknologi berpotensi dampak nyata bagi interaksi manusia dengan sistem digital.

Meskipun signifikansinya diakui luas, perkembangan teknologi bahasa berbasis ucapan masih timpang antarbahasa, karena sebagian besar teknologi kecerdasan buatan terpusat pada sebagian kecil bahasa dengan sumber daya digital terbesar (Bella et al., 2023). Ketimpangan ini oleh Bella et al. (2023) disebut bias linguistik, yang membuat performa teknologi bahasa berbeda-beda secara tidak proporsional antarbahasa meski diuji pada kondisi setara. Bahasa Indonesia, meskipun dituturkan ratusan juta jiwa, termasuk kelompok bahasa yang sumber dayanya masih tertinggal dibandingkan bahasa besar seperti Inggris. Ketimpangan ini semakin terasa pada tugas SER, yang membutuhkan data ucapan beranotasi emosi dalam jumlah memadai, padahal pengumpulan dan anotasinya memerlukan biaya, waktu, dan tenaga ahli. Kesenjangan inilah yang menjadikan pengembangan SER berbahasa Indonesia sebagai permasalahan penelitian yang penting sekaligus menantang.

Salah satu arah yang banyak ditempuh untuk mengatasi kesenjangan sumber daya pada bahasa yang kurang terwakili adalah *cross-lingual transfer*, yaitu strategi memindahkan pengetahuan yang dipelajari model dari bahasa bersumber da-

ya besar ke bahasa bersumber daya terbatas (Wu et al., 2021). Strategi ini menjanjikan karena memungkinkan model memanfaatkan representasi ucapan yang telah dipelajari secara luas tanpa membangun ulang pembelajaran dari data Indonesia yang masih terbatas. Beberapa penelitian telah menunjukkan potensi arah ini: Nugroho et al. (2025) menunjukkan bahwa model-model dasar XLSR-Wav2Vec2 yang telah di-*fine-tune* untuk ucapan Indonesia – memanfaatkan data Mozilla Common Voice serta OpenSLR berbahasa Jawa dan Sunda – dapat mencapai akurasi SER hingga 91,67%, sementara Santoso, Budianto and Dutono (2026) menunjukkan bahwa skema *fine-tuning* dua tahap dapat menghasilkan akurasi 90% pada dataset SER Indonesia yang mereka kembangkan.

Akan tetapi, penerapan *cross-lingual transfer* secara spesifik pada SER berbahasa Indonesia masih belum menjawab secara sistematis seberapa jauh keterbatasan data dapat diatasi tanpa mengorbankan kualitas pengenalan emosi. Penelitian Santoso, Budianto and Dutono (2026) hanya melaporkan satu konfigurasi *fine-tuning* dua tahap terbaik tanpa membandingkannya dengan strategi lain seperti pelatihan satu tahap langsung pada data Indonesia, maupun tanpa menguji apakah perbedaan performa antarstrategi tersebut signifikan secara statistik. Demikian pula, belum ada kajian yang membandingkan *full fine-tuning* dengan *fine-tuning* efisien-parameter seperti *Low-Rank Adaptation* (LoRA) pada konteks SER Indonesia, padahal LoRA menjanjikan efisiensi komputasi yang relevan bagi peneliti dengan sumber daya terbatas. Berdasarkan uraian tersebut, diperlukan kajian analitik mengenai pengaruh strategi *fine-tuning* lintas bahasa terhadap akurasi klasifikasi emosi pada ucapan berbahasa Indonesia, yang akan dianalisis dalam skripsi ini. Istilah “dua tahap” pada judul penelitian ini merujuk pada payung strategi utama yang diuji, yaitu perbandingan skema *single-stage* dan *two-stage*; pemilihan metode adaptasi pada titik penyesuaian ke data target – *full fine-tuning* atau LoRA – merupakan keputusan desain di dalam payung tersebut, dan diuji secara eksplisit melalui rumusan masalah kedua serta desain eksperimen empat kondisi pada Bab 3.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah dipaparkan, maka permasalahan dalam penelitian ini dapat dirumuskan sebagai berikut.

1. Bagaimana perbedaan performa klasifikasi emosi antara model yang dilatih langsung (*single-stage*) pada dataset emosi berbahasa Indonesia dan model yang melalui *fine-tuning* dua tahap (pra-latih pada korpus emosi berbahasa Inggris, lalu diadaptasi ke data Indonesia)?
2. Apakah terdapat perbedaan performa yang signifikan secara statistik antara strategi *full fine-tuning* dan strategi *fine-tuning* efisien-parameter (LoRA) pada tahap adaptasi ke data target, baik pada skema *single-stage* maupun *two-stage*?
3. Bagaimana konsistensi hasil klasifikasi emosi antar-*fold* pada skema validasi silang untuk masing-masing strategi *fine-tuning* yang diuji?

1.3 Rumusan Hipotesis

Rumusan masalah pertama dan kedua diuji signifikansi statistiknya melalui uji normalitas Shapiro-Wilk yang dilanjutkan uji *paired t-test* atau *Wilcoxon signed-rank test* (lihat Subbab 2.8 dan Subbab 3.6), sehingga dirumuskan hipotesis statistik sebagai berikut.

Hipotesis untuk Rumusan Masalah 1 (perbandingan *single-stage* dan *two-stage*):

- H_0 : Tidak terdapat perbedaan performa yang signifikan secara statistik antara model *single-stage* dan model *two-stage*.
- H_1 : Terdapat perbedaan performa yang signifikan secara statistik antara model *single-stage* dan model *two-stage*.

Hipotesis untuk Rumusan Masalah 2 (perbandingan *full fine-tuning* dan LoRA):

- H_0 : Tidak terdapat perbedaan performa yang signifikan secara statistik antara strategi *full fine-tuning* dan LoRA pada tahap adaptasi ke data target, baik pada skema *single-stage* maupun *two-stage*.
- H_1 : Terdapat perbedaan performa yang signifikan secara statistik antara strategi *full fine-tuning* dan LoRA pada tahap adaptasi ke data target, baik pada skema *single-stage* maupun *two-stage*.

Rumusan masalah ketiga bersifat deskriptif (menilai konsistensi antar-*fold*), sehingga tidak dirumuskan sebagai pengujian hipotesis statistik formal.

1.4 Tujuan

Tujuan dari penelitian ini menjawab rumusan masalah yang telah dipaparkan, maka penelitian ini memiliki tujuan sebagai berikut.

1. Menganalisis perbedaan performa klasifikasi emosi antara model yang dilatih langsung pada data Indonesia (*single-stage*) dan model yang melalui *fine-tuning* dua tahap dari korpus emosi berbahasa Inggris ke data Indonesia, diukur melalui akurasi, presisi, recall, dan F1-score.
2. Menguji signifikansi statistik perbedaan performa antara strategi *full fine-tuning* dan strategi *fine-tuning* efisien-parameter (LoRA) pada tahap adaptasi ke data target, serta membandingkan efisiensi komputasinya dari sisi waktu pelatihan dan penggunaan memori.
3. Mengevaluasi konsistensi hasil klasifikasi emosi antar-*fold* pada skema validasi silang untuk setiap strategi *fine-tuning* yang diuji.

1.5 Manfaat

Penelitian ini diharapkan dapat memberikan manfaat sebagai berikut.

1. Memberikan bukti empiris mengenai pengaruh strategi *fine-tuning* lintas bahasa terhadap akurasi SER berbahasa Indonesia, sehingga dapat menjadi rujukan bagi peneliti lain yang mengembangkan sistem pengenalan emosi ucapan pada bahasa dengan sumber daya terbatas.
2. Memberikan gambaran perbandingan yang teruji secara statistik antara strategi *full fine-tuning* dan LoRA, sehingga dapat membantu peneliti maupun praktisi dalam memilih strategi adaptasi model yang efisien dari segi sumber daya komputasi tanpa mengorbankan akurasi secara signifikan.
3. Berkontribusi pada pengembangan riset komputasi cerdas berbahasa Indonesia, khususnya pada bidang pemrosesan sinyal ucapan yang masih relatif terbatas jumlah kajiannya.

1.6 Batasan Masalah

Batasan masalah yang membatasi penulis dalam melakukan penelitian ini adalah sebagai berikut.

1. Backbone *self-supervised* yang digunakan dibatasi pada keluarga Wav2Vec2/XLSR-53.
2. Korpus sumber pada tahap *fine-tuning* dibatasi pada korpus emosi berbahasa Inggris (RAVDESS/CREMA-D), sedangkan korpus target dibatasi pada dataset emosi berbahasa Indonesia (E-SERAVD).
3. Skema kelas emosi yang dibandingkan disamakan antarkorpus agar konsisten, sehingga kelas emosi yang tidak beririsan antara korpus sumber dan target tidak dianalisis lebih lanjut.
4. Evaluasi performa dibatasi pada metrik kualitas klasifikasi – akurasi, presisi, recall, dan F1-score, yang diuji melalui skema validasi silang k-fold dan pengujian signifikansi statistik menggunakan uji Shapiro-Wilk untuk normalitas, dilanjutkan uji *paired t-test* atau *Wilcoxon signed-rank test* sesuai hasil uji normalitas tersebut – serta metrik efisiensi komputasi berupa waktu pelatihan dan penggunaan memori (VRAM).
5. Eksperimen dijalankan pada 2 unit GPU NVIDIA RTX 3060 6GB, sehingga konfigurasi batch size dan teknik optimasi memori (misalnya *gradient checkpointing*) disesuaikan dengan kapasitas tersebut.

1.7 Sistematika Pembahasan

Bab 1 Pendahuluan membahas mengenai latar belakang penelitian ini diangkat, rumusan masalah, rumusan hipotesis, tujuan dan manfaat penelitian, batasan masalah, sistematika pembahasan, serta jadwal penelitian yang berjudul Analisis Pengaruh Strategi Fine-Tuning Dua Tahap terhadap Akurasi Pengenalan Emosi Ucapan Berbahasa Indonesia.

Bab 2 Landasan Kepustakaan membahas tentang kajian pustaka dan dasar teori. Kajian pustaka berisi referensi mengenai penelitian-penelitian sebelumnya yang terkait dengan SER, representasi *self-supervised*, dan *cross-lingual transfer*. Dasar teori membahas konsep-konsep yang mendasari metode yang digunakan, meliputi pembelajaran *self-supervised*, Wav2Vec2/XLSR, *cross-lingual transfer*, strategi *fine-tuning* dua tahap, *Low-Rank Adaptation* (LoRA), validasi silang k-fold dan pengujian signifikansi statistik, serta metrik evaluasi akurasi, F1-score, waktu pelatihan, dan penggunaan memori.

Bab 3 Metodologi Penelitian membahas tipe penelitian serta tahapan penelitian yang dilaksanakan mulai dari studi literatur, pengumpulan data, *fine-tuning* sumber, *fine-tuning* target, evaluasi k-fold, analisis kinerja komputasi, hingga analisis hasil dan penarikan kesimpulan.

Bab 4 Hasil menyajikan hasil pelaksanaan setiap strategi *fine-tuning* yang diuji, meliputi observasi akurasi dan F1-score per fold dari skema validasi silang k-fold untuk keempat kondisi eksperimen (Kondisi A–D, lihat Subbab 3.5), beserta hasil pengujian normalitas dan signifikansi statistiknya, serta hasil analisis kinerja komputasi (waktu pelatihan dan penggunaan memori).

Bab 5 Pembahasan menerjemahkan makna dari hasil yang diperoleh pada Bab 4 untuk menjawab rumusan masalah penelitian, mencakup interpretasi perbedaan performa antarstrategi *fine-tuning*, konsistensi hasil antar-fold, serta kaitannya dengan landasan teori dan penelitian terdahulu yang telah diuraikan pada Bab 2.

Bab 6 Penutup memuat kesimpulan yang menjawab rumusan masalah berdasarkan hasil dan pembahasan penelitian, serta saran untuk pengembangan penelitian selanjutnya, misalnya perluasan cakupan korpus sumber atau backbone model yang diuji.

1.8 Jadwal Penelitian

Penelitian ini dijadwalkan mengikuti tenggat resmi sistem akademik program studi, dengan empat periode acuan: Konsultasi Proposal (P0), Penilaian Kemajuan 1 (P1), Penilaian Kemajuan 2 (P2), dan Pendaftaran Seminar Hasil/Ujian. Tabel 1.1 merangkum tahapan penelitian terhadap keempat periode tersebut. Jadwal *fine-tuning* target (Tahap 5–6) bersifat perkiraan dan dapat disesuaikan berdasarkan hasil *pilot run* (Tahap 3), sedangkan penulisan laporan dikerjakan berjalan begitu hasil awal tersedia, bukan ditumpuk di akhir periode.

Tabel 1.1 Jadwal penelitian

Tahapan	s.d. 25 Sep 2026 (s.d. P0)	25 Sep–27 Okt 2026 (s.d. P1)	27 Okt–11 Des 2026 (s.d. P2)	11–22 Des 2026 (s.d. Semhas)
1. Studi Literatur	✓			
2. Pengumpulan & Praproses Data	✓			
3. Pilot Run (1 Kondisi × 1 Fold)	✓			
4. Fine-Tuning Sumber (sekali)		✓		
5. Fine-Tuning Target Kondisi A&B (Single-Stage)		✓		
6. Fine-Tuning Target Kondisi C&D (Two-Stage)			✓	
7. Evaluasi K-Fold & Uji Signifikansi Statistik			✓	✓
8. Analisis Kinerja Komputasi			✓	✓
9. Analisis Hasil dan Pembahasan				✓
10. Penulisan Laporan (Bab 4–6)		✓	✓	✓

BAB 2 LANDASAN KEPUSTAKAAN

2.1 Kajian Pustaka

Kajian pustaka berisi kajian-kajian penelitian terdahulu yang bertujuan untuk mendukung proses penelitian. Kajian pustaka dilakukan untuk mendapatkan informasi yang relevan dengan topik penelitian ini. Tabel 2.1 memaparkan penelitian-penelitian yang terkait dengan subjek yang diteliti.

Tabel 2.1 Daftar penelitian terdahulu

Judul Penelitian	Masalah	Metode	Hasil
Advancements in Speech Recognition: A Systematic Review of Deep Learning Transformer Models, Trends, Innovations, and Future Directions (Eljinini and Al-Momani, 2025)	Pergeseran paradigma dari fitur tangan (<i>hand-crafted features</i>) menuju representasi ucapan yang dipelajari langsung dari sinyal mentah belum ditinjau secara sistematis lintas 37 studi inti.	Tinjauan sistematis (<i>systematic review</i>) terhadap arsitektur transformer dan pembelajaran <i>self-supervised</i> pada pengenalan ucapan.	Transformer dan pembelajaran <i>self-supervised</i> terbukti meningkatkan akurasi pengenalan ucapan pada kondisi akustik menantang dibandingkan fitur tangan konvensional.
Advancing End-to-End Indonesian Speech Emotion Recognition Using XLSR-Wav2Vec2 (Nugroho et al., 2025)	Performa SER berbahasa Indonesia belum diketahui secara komparatif antara metode klasik dan representasi <i>self-supervised</i> multibahasa.	Perbandingan SVM, CNN, dan dua model dasar XLSR-Wav2Vec2 yang telah di- <i>fine-tune</i> untuk ucapan Indonesia (Common Voice, OpenSLR Jawa/Sunda), diuji pada dataset IndoWave-Sentiment.	Model dasar XLSR-Wav2Vec2 yang telah disesuaikan untuk ucapan Indonesia mencapai akurasi tertinggi sebesar 91,67%, mengungguli metode klasik.
Development of a Speech Emotion Recognition Dataset for Indonesian (Santoso, Budianto and Dutono, 2026)	Dataset SER berbahasa Indonesia dengan skema <i>fine-tuning</i> yang terdokumentasi masih terbatas.	Pengembangan dataset E-SERAVD melalui skema <i>fine-tuning</i> dua tahap.	Diperoleh akurasi 90% dan F1-score 86% pada satu konfigurasi <i>fine-tuning</i> dua tahap.
Indonesian Automatic Speech Recognition with XLSR-53 (Arisaputra and Zahra, 2023)	Ketersediaan data latih ASR berbahasa Indonesia terbatas dibandingkan bahasa besar.	<i>Cross-lingual transfer</i> menggunakan backbone XLSR-53 pada tugas ASR Indonesia.	<i>Word error rate</i> lebih rendah dicapai meski data latih lebih sedikit dibandingkan pelatihan dari awal.
End-to-End Transfer Learning for Speaker-Independent Cross-Language and Cross-Corpus Speech Emotion Recognition (Tang et al., 2023)	Generalisasi model SER antarbahasa dan antarkorpus belum banyak diuji dengan pendekatan <i>end-to-end</i> .	<i>Transfer learning end-to-end</i> yang bersifat <i>speaker-independent</i> , lintas bahasa, dan lintas korpus.	Menunjukkan potensi generalisasi model emosi antarbahasa melalui pendekatan <i>transfer learning</i> .

Berdasarkan kelima penelitian tersebut, dapat disimpulkan bahwa celah penelitian terletak pada belum adanya studi yang membandingkan strategi *fine-tuning* satu tahap versus dua tahap dan *full fine-tuning* versus LoRA pada SER berbahasa Indonesia secara sistematis dan teruji signifikansi statistiknya. Penelitian ini menempatkan diri pada celah tersebut dengan merancang perbandingan yang sistematis antara keempat kombinasi strategi tersebut, dievaluasi melalui skema validasi silang k-fold dan diuji signifikansi statistiknya.

Celah tersebut dapat disintesis dalam empat kelompok pembanding berdasarkan persamaan dan perbedaannya dengan penelitian ini. Pertama, Eljinini and Al-Momani (2025) meletakkan fondasi representasi *self-supervised* secara umum, namun tidak menyentuh domain emosi maupun bahasa Indonesia secara spesifik. Kedua, Nugroho et al. (2025) menerapkan representasi *self-supervised* untuk SER berbahasa Indonesia, tetapi model dasar yang mereka uji merupakan hasil *fine-tuning* untuk ucapan Indonesia secara umum, bukan hasil *fine-tuning* khusus dari korpus emosi berbahasa asing. Ketiga, Santoso, Budianto and Dutono (2026) menerapkan skema *fine-tuning* dua tahap, tetapi hanya melaporkan satu konfigurasi terbaik tanpa perbandingan sistematis maupun uji statistik. Keempat, Arisaputra and Zahra (2023) serta Tang et al. (2023) memanfaatkan *cross-lingual transfer*, tetapi tidak menyasar korpus emosi berbahasa Inggris ke data emosi berbahasa Indonesia secara spesifik. Sebagai penguat argumen *novelty* di level lokal, penelusuran terhadap 924 skripsi Teknik Informatika FILKOM UB yang tersedia secara *open-access* juga belum menemukan satu pun yang mengangkat SER berbasis audio.

2.2 Speech Emotion Recognition (SER)

Speech emotion recognition (SER) adalah bidang kajian yang berupaya mengenali kondisi emosi seseorang secara otomatis dari sinyal ucapannya, dengan memanfaatkan ciri-ciri akustik seperti intonasi, nada dasar (*pitch*), energi, dan ritme bicara yang secara empiris berkorelasi dengan keadaan emosional penutur (Dar and Delhibabu, 2024). Secara umum, sistem SER bekerja melalui tiga tahap utama: (1) ekstraksi representasi dari sinyal ucapan mentah, baik berupa fitur akustik tangan (*hand-crafted features*) maupun representasi yang dipelajari (*learned representations*); (2) pemetaan representasi tersebut ke ruang fitur yang relevan dengan kelas emosi; dan (3) klasifikasi ke salah satu kategori emosi yang telah ditentukan (mis. senang, sedih, marah, netral). Gambar 2.1 menggambarkan alur umum tersebut.




Gambar 2.1 Alur umum sistem speech emotion recognition

Cakupan penerapan SER terus meluas, mulai dari asisten virtual yang responsif terhadap keadaan pengguna, layanan pelanggan otomatis yang dapat mendeteksi frustrasi penelepon, hingga sistem pemantauan kesehatan mental yang menandai perubahan pola emosi dari waktu ke waktu. Perkembangan representasi *self-supervised* seperti Wav2Vec2/XLSR, yang dibahas pada Subbab 2.4, menjadi salah satu pendorong utama peningkatan akurasi SER dibandingkan pendekatan fitur tangan konvensional.

2.3 Pembelajaran Self-Supervised

Pembelajaran *self-supervised* adalah paradigma pembelajaran mesin yang melatih model pada data tanpa label dengan cara menciptakan sinyal pengawasan

(*supervision signal*) dari data itu sendiri, alih-alih memerlukan label yang dianotasi manusia (Liu et al., 2023). Model dilatih untuk menyelesaikan *pretext task*, yaitu tugas bantu yang dirancang agar penyelesaiannya mengharuskan model mempelajari struktur dan pola yang mendasari data, misalnya memprediksi bagian data yang disembunyikan dari bagian yang tersisa. Representasi yang dipelajari selama proses ini kemudian dapat digunakan atau diadaptasi (*fine-tuned*) untuk tugas hilir (*downstream task*) yang sesungguhnya, seperti klasifikasi emosi pada penelitian ini. Gambar 2.2 menggambarkan alur umum tersebut.




Gambar 2.2 Alur umum pembelajaran self-supervised

Keunggulan utama paradigma ini adalah kemampuannya memanfaatkan data tanpa label dalam jumlah besar, yang jauh lebih mudah dan murah diperoleh dibandingkan data berlabel. Karakteristik inilah yang mendasari penggunaannya secara luas pada domain ucapan, termasuk pada backbone Wav2Vec2/XLSR yang digunakan dalam penelitian ini, sebagaimana diuraikan pada Subbab 2.4.

2.4 Wav2Vec2/XLSR

Wav2Vec2 adalah arsitektur pembelajaran *self-supervised* untuk representasi ucapan yang dilatih pada volume data ucapan tanpa label berskala besar (Babevski et al., 2020). Arsitekturnya terdiri atas tiga komponen utama, sebagaimana digambarkan pada Gambar 2.3: (1) *feature encoder* berbasis *convolutional neural network* (CNN) yang mengubah gelombang ucapan mentah menjadi representasi laten Z pada resolusi waktu yang lebih rendah; (2) *context network* berbasis Transformer yang mengolah Z (dengan sebagian di antaranya disembunyikan/*masked*) menjadi representasi terkontekstualisasi C ; dan (3) modul kuantisasi yang mendiskretkan Z menjadi target kuantisasi Q , khusus digunakan pada tahap pra-latih untuk menghitung *contrastive loss* yang mendorong model membedakan representasi kuantisasi yang benar dari sejumlah pengganggu (*distractors*).




Gambar 2.3 Arsitektur Wav2Vec2

XLSR merupakan varian multibahasa dari Wav2Vec2 yang dilatih pada data ucapan tanpa label dari banyak bahasa sekaligus, menggunakan arsitektur dan tujuan pra-latih yang sama, namun dengan korpus pra-latih gabungan lintas bahasa (Conneau et al., 2021). Karena dilatih lintas bahasa, representasi yang dihasilkan XLSR cenderung menangkap struktur akustik yang lebih umum dan dapat menggeneralisasi lintas bahasa dibandingkan model yang hanya dilatih pada satu bahasa

saja. Karakteristik inilah yang mendasari pemilihan Wav2Vec2/XLSR sebagai backbone dalam penelitian ini, karena representasi C yang dihasilkan berpotensi menjadi titik awal (*initialization*) yang baik untuk *fine-tuning* lintas bahasa pada tugas SER, sebagaimana diuraikan pada Subbab 2.6.

2.5 Cross-Lingual Transfer pada Pemrosesan Ucapan

Cross-lingual transfer adalah strategi memindahkan pengetahuan yang dipelajari model dari bahasa bersumber daya besar ke bahasa bersumber daya terbatas (Wu et al., 2021). Strategi ini bekerja dengan memanfaatkan representasi yang telah dipelajari model pada data bahasa sumber sebagai titik awal, alih-alih melatih model dari awal (*from scratch*) pada data bahasa target yang terbatas jumlahnya. Gambar 2.4 menggambarkan alur umum tersebut: model dilatih terlebih dahulu pada bahasa sumber yang memiliki data melimpah, kemudian representasi yang dihasilkan diadaptasi ke bahasa target.



Gambar 2.4 Alur umum cross-lingual transfer

Pendekatan ini banyak ditempuh untuk mengatasi kesenjangan sumber daya pada bahasa yang kurang terwakili dalam teknologi bahasa, karena memungkinkan model memanfaatkan pola akustik atau linguistik yang telah dipelajari secara luas tanpa membangun ulang pembelajaran dari data yang masih terbatas pada bahasa target. Pada konteks penelitian ini, bahasa sumber adalah bahasa Inggris (dengan korpus emosi RAVDESS/CREMA-D yang tersedia luas) dan bahasa target adalah Bahasa Indonesia (dengan korpus emosi yang relatif terbatas), sebagaimana diuraikan lebih lanjut pada Subbab 2.6.

2.6 Strategi Fine-Tuning Dua Tahap


Strategi *fine-tuning* dua tahap merupakan bentuk penerapan *cross-lingual transfer* (Subbab 2.5) yang mengadaptasi model secara bertahap melalui dua kali proses *fine-tuning* berurutan, alih-alih satu kali *fine-tuning* langsung ke data target (Pan and Yang, 2010). Secara formal, jika θ_0 menyatakan bobot Wav2Vec2/XLSR hasil pra-latih (Subbab 2.4), maka tahap pertama melatih model pada korpus sumber D_{src} untuk memperoleh bobot antara sebagaimana Persamaan 2.1.

$$\theta_1 = \arg \min_{\theta} \mathcal{L}_{\text{src}}(\theta; D_{\text{src}}), \quad \theta \text{ diinisialisasi dari } \theta_0 \quad (2.1)$$

Tahap kedua kemudian mengadaptasi bobot antara θ_1 tersebut ke korpus target D_{tgt} untuk memperoleh bobot akhir sebagaimana Persamaan 2.2.

$$\theta_2 = \arg \min_{\theta} \mathcal{L}_{\text{tgt}}(\theta; D_{\text{tgt}}), \quad \theta \text{ diinisialisasi dari } \theta_1 \quad (2.2)$$

Gambar 2.5 menggambarkan alur dua tahap tersebut.



Gambar 2.5 Alur strategi fine-tuning dua tahap


Pendekatan bertahap ini diharapkan memungkinkan model mempelajari pola akustik emosi yang bersifat lebih umum pada tahap pertama, sebelum menyesuaikan pola tersebut dengan karakteristik spesifik Bahasa Indonesia pada tahap kedua. Sebagai pembandingan pada penelitian ini, disiapkan pula skema *single-stage* yang melewati tahap pertama dan langsung melatih θ_0 pada D_{tgt} , sebagaimana diuraikan pada Bab 3.

2.7 Low-Rank Adaptation (LoRA)

Low-Rank Adaptation (LoRA) adalah strategi *fine-tuning* efisien-parameter yang membekukan seluruh bobot model dasar W_0 dan hanya melatih sepasang matriks tambahan berperingkat rendah (*low-rank*) yang disisipkan secara paralel (Hu et al., 2022). Untuk suatu lapisan dengan bobot pra-latih $W_0 \in \mathbb{R}^{d \times k}$, LoRA merepresentasikan pembaruan bobot ΔW sebagai perkalian dua matriks berperingkat rendah $B \in \mathbb{R}^{d \times r}$ dan $A \in \mathbb{R}^{r \times k}$, dengan $r \ll \min(d, k)$, sehingga keluaran lapisan tersebut untuk masukan x dihitung sebagaimana Persamaan 2.3.

$$h = W_0x + \Delta Wx = W_0x + BAx \quad (2.3)$$

Gambar 2.6 menggambarkan arsitektur tersebut: masukan x diproses melalui dua jalur paralel, yaitu bobot dasar W_0 yang beku dan jalur berperingkat rendah A diikuti B , yang hasilnya dijumlahkan menjadi keluaran h .




Gambar 2.6 Arsitektur Low-Rank Adaptation (LoRA)

Karena jumlah parameter pada A dan B jauh lebih sedikit daripada jumlah parameter W_0 , LoRA menawarkan efisiensi komputasi dan memori yang signifikan dibandingkan *full fine-tuning*, yang memperbarui seluruh parameter W_0 secara langsung. Efisiensi ini relevan bagi penelitian dengan keterbatasan sumber daya komputasi, namun pengaruhnya terhadap akurasi klasifikasi emosi pada konteks SER berbahasa Indonesia belum banyak dikaji secara sistematis, sehingga menjadi salah satu perbandingan utama yang diuji dalam penelitian ini, sebagaimana diuraikan pada Bab 3.

2.8 Validasi Silang K-Fold dan Pengujian Signifikansi Statistik

Validasi silang k-fold adalah teknik evaluasi yang membagi data menjadi k bagian (*fold*) berukuran relatif sama, dengan setiap bagian secara bergantian digunakan sebagai data uji sementara $k - 1$ bagian lainnya digunakan sebagai data latih, sehingga setiap bagian data pernah menjadi data uji tepat satu kali (Kohavi, 1995). Gambar 2.7 menggambarkan skema tersebut untuk $k = 5$.



Gambar 2.7 Ilustrasi satu putaran validasi silang k-fold ($k = 5$); peran fold sebagai data uji bergantian pada setiap putaran hingga kelima fold pernah menjadi data uji

Teknik ini menghasilkan k observasi akurasi dan F1-score, satu untuk setiap fold, sehingga memungkinkan pengujian konsistensi performa antar-fold untuk setiap strategi yang diuji, bukan hanya satu nilai tunggal dari satu kali pengujian. Untuk menguji apakah perbedaan performa antarstrategi bersifat signifikan secara statistik, k observasi tersebut terlebih dahulu diuji normalitasnya menggunakan uji Shapiro-Wilk (Shapiro and Wilk, 1965). Apabila data berdistribusi normal, pengujian dilanjutkan dengan *paired t-test*, yang menghitung statistik uji t dari selisih berpasangan d_i antara dua strategi pada fold yang sama, sebagaimana Persamaan 2.4.

$$t = \frac{\bar{d}}{s_d / \sqrt{n}} \quad (2.4)$$

di mana $\bar{d}$ adalah rata-rata selisih berpasangan, s_d adalah simpangan baku selisih tersebut, dan n adalah jumlah fold. Apabila data tidak berdistribusi normal, digunakan *Wilcoxon signed-rank test* sebagai alternatif non-parametrik yang tidak mengasumsikan distribusi tertentu (Wilcoxon, 1945).

2.9 Metrik Evaluasi

Penelitian ini menggunakan dua kelompok metrik untuk mengevaluasi setiap strategi *fine-tuning* yang dibandingkan: metrik kualitas klasifikasi (akurasi, presisi, recall, dan F1-score) dan metrik efisiensi komputasi (waktu pelatihan dan penggunaan memori). Kelompok pertama menjawab Rumusan Masalah 1, sedangkan kelompok kedua melengkapi kelompok pertama dalam menjawab Rumusan Masalah 2 dari sisi efisiensi, karena LoRA diklaim unggul bukan semata dari kualitas prediksi tetapi juga efisiensi sumber daya dibandingkan *full fine-tuning*.

2.9.1 Akurasi, Presisi, Recall, dan F1-Score

Akurasi, presisi, recall, dan F1-score adalah empat metrik yang umum digunakan untuk mengevaluasi performa model klasifikasi (Powers, 2011). Akurasi

mengukur proporsi prediksi yang benar terhadap keseluruhan data uji, sehingga memberikan gambaran umum performa model, sebagaimana Persamaan 2.5.

$$\text{Akurasi} = \frac{TP + TN}{TP + TN + FP + FN} \quad (2.5)$$

di mana TP = True Positive, TN = True Negative, FP = False Positive, FN = False Negative.

Akan tetapi, pada data dengan sebaran kelas yang tidak seimbang, akurasi dapat memberikan gambaran yang menyesatkan, karena model yang selalu memprediksi kelas mayoritas tetap dapat memperoleh akurasi tinggi tanpa benar-benar mengenali kelas minoritas. Presisi mengukur proporsi prediksi positif yang benar-benar tepat, sebagaimana Persamaan 2.6.

$$\text{Presisi} = \frac{TP}{TP + FP} \quad (2.6)$$

Recall mengukur proporsi kasus positif yang berhasil dikenali model, sebagaimana Persamaan 2.7.

$$\text{Recall} = \frac{TP}{TP + FN} \quad (2.7)$$

Presisi dan recall sering kali saling bertukar (*trade-off*): menaikkan salah satu cenderung menurunkan yang lain. F1-score mengatasi keterbatasan ini dengan merepresentasikan rata-rata harmonis keduanya, sebagaimana Persamaan 2.8.

$$F_1 = 2 \cdot \frac{\text{Presisi} \times \text{Recall}}{\text{Presisi} + \text{Recall}} \quad (2.8)$$

Keempat metrik ini digunakan bersama dalam penelitian ini untuk memberikan gambaran performa yang lebih menyeluruh terhadap setiap strategi *fine-tuning* yang dibandingkan, mengingat skema kelas emosi yang digunakan berpotensi tidak seimbang antarkelas.


2.9.2 Waktu Pelatihan dan Penggunaan Memori

Selain kualitas klasifikasi, penelitian ini juga mengukur kinerja komputasi setiap strategi *fine-tuning*, mengingat salah satu motivasi utama LoRA adalah efisiensi sumber daya, bukan semata kualitas prediksi. Waktu pelatihan (*training time*) mengukur lama waktu yang dibutuhkan suatu strategi *fine-tuning* untuk mencapai model terlatih, dihitung dari awal hingga akhir proses pelatihan pada tiap fold. Penggunaan memori (VRAM) mengukur puncak alokasi memori GPU yang dibutuhkan selama pelatihan, yang mencerminkan kelayakan suatu strategi dijalankan pada perangkat keras dengan kapasitas terbatas – relevan langsung dengan lingkungan eksperimen penelitian ini (lihat Subbab 3.10.2). Kedua metrik ini dibandingkan secara deskriptif antarkondisi eksperimen (lihat Subbab 3.7), melengkapi akurasi dan F1-score dalam memberikan gambaran menyeluruh terhadap *trade-off* antara kualitas dan efisiensi setiap strategi *fine-tuning* yang diuji.

BAB 3 METODOLOGI PENELITIAN

3.1 Tipe Penelitian

Penelitian ini merupakan penelitian non-implementatif analitik dengan pendekatan kuantitatif, karena berfokus pada analisis pengaruh strategi *fine-tuning* terhadap akurasi klasifikasi emosi ucapan, bukan pada pengembangan sistem atau perangkat lunak siap pakai. Sifat analitik ditunjukkan melalui pengolahan data hasil observasi akurasi dan F1-score dari setiap strategi *fine-tuning* untuk mengkaji hubungan antara strategi yang diterapkan dan performa klasifikasi emosi yang dihasilkan. Pendekatan kuantitatif digunakan karena data berupa nilai numerik hasil evaluasi model yang dianalisis menggunakan metrik akurasi, F1-score, dan pengujian signifikansi statistik. Model-model yang di-*fine-tune* pada penelitian ini berfungsi sebagai instrumen untuk menghasilkan data observasi tersebut, bukan sebagai produk/artefak utama penelitian.



Gambar 3.1 Diagram alir metode penelitian

Diagram alir metode penelitian ini ditunjukkan pada Gambar 3.1. Tahap awal penelitian diawali dengan studi literatur, yang bertujuan untuk mengkaji teori, metode, serta penelitian terdahulu yang relevan dengan SER, pembelajaran *self-supervised*, dan *cross-lingual transfer*. Tahap berikutnya adalah pengumpulan data, yaitu proses pengumpulan korpus emosi berbahasa Inggris sebagai sumber dan dataset SER berbahasa Indonesia sebagai target. Data yang telah diperoleh selanjutnya diproses pada tahap *fine-tuning* sumber untuk melatih backbone *self-supervised* mengenali pola akustik emosi secara umum. Setelah itu dilakukan *fine-tuning* target untuk mengadaptasi model dasar ke data Indonesia melalui beberapa skema strategi. Tahap berikutnya adalah evaluasi k-fold untuk menilai performa setiap strategi menggunakan skema validasi silang dan pengujian signifikansi statistik, dilanjutkan analisis kinerja komputasi untuk membandingkan waktu pelatihan dan

penggunaan memori antarkondisi. Hasil kedua evaluasi tersebut kemudian digunakan sebagai dasar pada tahap analisis hasil, yang merangkum temuan penelitian serta menjawab rumusan masalah yang telah dipaparkan.

3.2 Studi Literatur

Studi literatur merupakan tahap awal penelitian yang bertujuan untuk mempelajari dan memahami teori, konsep, serta hasil penelitian terdahulu yang berkaitan dengan SER, pembelajaran *self-supervised*, representasi Wav2Vec2/XLSR, dan *cross-lingual transfer*. Pada tahap ini dilakukan pengkajian terhadap jurnal, prosiding konferensi, dan sumber ilmiah relevan untuk memastikan celah penelitian pada Bab 2 Landasan Kepustakaan belum terjawab oleh penelitian lain, sekaligus menentukan backbone model dan skema *fine-tuning* yang sesuai dengan tujuan penelitian.

3.3 Pengumpulan Data

Tahap ini mengumpulkan dua kelompok data, yaitu korpus emosi berbahasa Inggris sebagai sumber pada tahap *fine-tuning* pertama (RAVDESS/CREMA-D), dan dataset E-SERAVID (Santoso, Budianto and Dutono, 2026) sebagai target berbahasa Indonesia pada tahap *fine-tuning* kedua. Skema kelas emosi pada korpus sumber disesuaikan dengan skema empat kelas yang tersedia pada E-SERAVID (marah, senang, netral, sedih), sehingga perbandingan antarstrategi *fine-tuning* dapat dilakukan secara adil.

Karakteristik masing-masing korpus dijelaskan sebagai berikut. RAVDESS adalah korpus ucapan emosional berbahasa Inggris yang direkam oleh 24 aktor profesional (12 perempuan, 12 laki-laki), mencakup 8 kategori emosi (netral, tenang, senang, sedih, marah, takut, jijik, dan terkejut) (Livingstone and Russo, 2018). CREMA-D adalah korpus ucapan emosional berbahasa Inggris yang direkam oleh 91 aktor dengan latar belakang usia dan etnis yang beragam, mencakup 6 kategori emosi (marah, jijik, takut, senang, netral, dan sedih) (Cao et al., 2014). Kedua korpus ini dipilih sebagai sumber karena tersedia secara publik, telah banyak digunakan pada penelitian SER sebelumnya, dan mencakup kategori emosi yang secara umum beririsan dengan skema kelas pada dataset target. Tabel 3.1 merangkum karakteristik ketiga dataset yang digunakan.

Tabel 3.1 Karakteristik dataset yang digunakan

Dataset	Peran	Bahasa	Jumlah pel	Sam-	Jumlah Kelas
RAVDESS	Sumber	Inggris	1.440		8
CREMA-D	Sumber	Inggris	7.442		6
E-SERAVID	Target	Indonesia	~5.049		4

Jumlah sampel untuk RAVDESS dan CREMA-D di atas mengacu pada dokumentasi

resmi masing-masing korpus. E-SERAVD memiliki sekitar 5.049 sampel dengan distribusi 1.202 marah, 1.228 senang, 2.075 netral, dan 899 sedih (Santoso, Budianto and Dutono, 2026); angka ini masih perlu diverifikasi ulang terhadap dokumentasi resmi dataset sebelum benar-benar diperoleh. Dataset SER Indonesia lain seperti IndoWaveSentiment (Nugroho et al., 2025) tidak digunakan sebagai target pada penelitian ini karena skala dan skema kelasnya berbeda dari E-SERAVD, namun disebutkan kembali sebagai arah pengembangan pada Bab 6.

3.4 Fine-Tuning Sumber

Backbone yang digunakan adalah model dasar XLSR-53 (facebook/wav2vec2-large-xlsr-53) tanpa *fine-tuning* tambahan dari pihak lain untuk Bahasa Indonesia – berbeda dari pendekatan Nugroho et al. (2025) yang menguji model dasar XLSR-Wav2Vec2 yang sudah di-*fine-tune* untuk ucapan Indonesia (lihat Subbab 2.4). Pemilihan ini disengaja: dengan titik awal yang identik di keempat kondisi eksperimen (Subbab 3.5), perbedaan performa yang teramati dapat ditarik ke strategi *fine-tuning* yang diuji dalam penelitian ini, bukan tercampur dengan efek *fine-tuning* pihak lain yang sudah menempel pada checkpoint.

Tahap ini melatih backbone *self-supervised* (Wav2Vec2/XLSR-53) pada korpus emosi berbahasa Inggris agar model mampu mengenali pola akustik emosi secara umum, menghasilkan model dasar yang selanjutnya akan diadaptasi ke data target pada tahap berikutnya. Tahap ini dijalankan sekali saja; bobot hasilnya dipakai ulang sebagai titik awal untuk semua fold pada Kondisi C dan D (Subbab 3.5), bukan diulang per-fold, karena *fine-tuning* tahap sumber tidak bergantung pada pembagian fold data target.

3.5 Fine-Tuning Target

Tahap ini mengadaptasi model ke data Indonesia melalui dua axis desain yang independen: (1) *stage*, yaitu apakah model melalui *fine-tuning* dua tahap atau langsung dilatih pada data target (*single-stage*); dan (2) metode adaptasi, yaitu *full fine-tuning* yang memperbarui seluruh parameter model, atau LoRA yang hanya memperbarui parameter tambahan berjumlah kecil. Kombinasi kedua axis tersebut menghasilkan empat kondisi eksperimen sebagaimana dirangkum pada Tabel 3.2.

Tabel 3.2 Empat kondisi eksperimen (desain 2×2)

Kondisi	Stage	Metode Adaptasi
A	Single-stage	Full Fine-Tuning
B	Single-stage	LoRA
C	Two-stage	Full Fine-Tuning
D	Two-stage	LoRA

Backbone yang digunakan sama persis (XLSR-53, Subbab 3.4) di keempat kondisi – yang berbeda hanya resep *fine-tuning*-nya – supaya perbedaan hasil antarkondisi

dapat ditarik ke strategi *fine-tuning* yang diuji, bukan ke perbedaan arsitektur atau titik awal model. Kondisi A dan B tidak melalui tahap *fine-tuning* sumber (Subbab 3.4) dan langsung dilatih pada data target, sedangkan Kondisi C dan D memakai bobot hasil *fine-tuning* sumber sebagai titik awal. Validasi silang k-fold (Subbab 3.6) diterapkan pada level adaptasi target ini untuk keempat kondisi. Sebagai mitigasi risiko, direkomendasikan menjalankan *pilot run* (1 kondisi $\times$ 1 fold) pada perangkat keras sebenarnya sebelum menjalankan grid eksperimen penuh, untuk memverifikasi estimasi waktu dan VRAM pada Subbab 3.10.2 dengan data riil.

3.6 Evaluasi K-Fold

Tahap ini mengevaluasi setiap kondisi eksperimen menggunakan skema validasi silang k-fold, sehingga diperoleh beberapa observasi akurasi dan F1-score per fold untuk masing-masing kondisi. Data hasil observasi tersebut kemudian diuji normalitasnya menggunakan uji Shapiro-Wilk. Jika data berdistribusi normal, pengujian dilanjutkan dengan *paired t-test*; jika tidak, digunakan *Wilcoxon signed-rank test*. Pengujian ini bertujuan untuk mengetahui signifikansi statistik perbedaan performa antarkondisi, menjawab hipotesis yang telah dirumuskan pada Subbab 1.3.

3.7 Analisis Kinerja Komputasi

Tahap ini menganalisis kinerja komputasi setiap kondisi eksperimen (Kondisi A–D), meliputi waktu pelatihan dan penggunaan memori (VRAM) sebagaimana didefinisikan pada Subbab 2.9.2. Waktu pelatihan dicatat dari awal hingga akhir proses pelatihan pada tiap fold untuk tahap *fine-tuning* target (Subbab 3.5); durasi *fine-tuning* sumber (Subbab 3.4) dicatat terpisah karena hanya dijalankan sekali dan dipakai bersama oleh Kondisi C dan D. Penggunaan memori diukur sebagai puncak alokasi VRAM selama pelatihan pada tiap kondisi. Secara teknis, waktu pelatihan dicatat menggunakan `time.perf_counter()`, sedangkan puncak penggunaan VRAM dicatat menggunakan `torch.cuda.max_memory_allocated()` setelah `reset_peak_memory_stats()` dipanggil di awal tiap fold. Kedua metrik ini dibandingkan secara deskriptif antarkondisi, dengan perhatian khusus pada perbandingan Kondisi A vs B dan Kondisi C vs D (*axis full fine-tuning* vs LoRA) untuk menjawab Rumusan Masalah 2 dari sisi efisiensi, melengkapi pengujian signifikansi statistik akurasi dan F1-score pada Subbab 3.6.

3.8 Analisis Hasil

Tahap ini menafsirkan hasil pengujian signifikansi statistik dan analisis kinerja komputasi untuk menjawab rumusan masalah penelitian, serta menyusun rekomendasi strategi *fine-tuning* yang paling sesuai untuk pengembangan SER berbahasa Indonesia berdasarkan temuan yang diperoleh.

3.9 Kesimpulan dan Saran

Penarikan kesimpulan dilaksanakan setelah seluruh tahap evaluasi dan analisis hasil selesai. Kesimpulan memuat jawaban atas rumusan masalah yang telah dituliskan sebelumnya, mengacu pada hasil pengujian signifikansi statistik dari setiap strategi *fine-tuning* yang dibandingkan. Selain kesimpulan, disusun pula saran sebagai bahan pertimbangan dan perbaikan untuk penelitian selanjutnya, misalnya perluasan cakupan korpus sumber atau backbone model yang diuji.

3.10 Peralatan Pendukung

Peralatan pendukung yang digunakan dalam penelitian ini terdiri atas perangkat lunak (*software*) dan perangkat keras (*hardware*).

3.10.1 Perangkat Lunak (Software)

Perangkat lunak yang digunakan dalam mendukung penelitian ini sebagai berikut.

1. Bahasa pemrograman Python.
2. Kerangka kerja *deep learning* untuk pelatihan dan *fine-tuning* model Wav2Vec2/XLSR.
3. Pustaka untuk implementasi LoRA.
4. Pustaka optimizer 8-bit (*bitsandbytes*) untuk mitigasi VRAM pada kondisi *full fine-tuning*.
5. Pustaka statistik untuk pengujian normalitas dan uji signifikansi.
6. GitHub untuk pengelolaan versi kode sumber dan eksperimen.

3.10.2 Perangkat Keras (Hardware)

Perangkat keras yang digunakan dalam mendukung penelitian ini sebagai berikut.

1. 2 unit GPU NVIDIA GeForce RTX 3060 6GB (server lab, dipinjamkan).
2. RAM dan penyimpanan: [*diisi sesuai spesifikasi server lab yang sebenarnya dipakai*].

Kecukupan VRAM *per kartu* dianalisis terhadap ukuran backbone (sekitar 317 juta parameter), sebagaimana dirangkum pada Tabel 3.3.

Tabel 3.3 Estimasi kecukupan VRAM per kartu (6GB)

Komponen	Full-FT (naif)	Full-FT + 8-bit Adam	LoRA
Bobot + master + gradien + optimizer	~5 GB	~1,9 GB	~0,6–0,7 GB
Sisa untuk aktivasi (dari 6 GB)	~1 GB	~4 GB	~5,3 GB

Estimasi “naif” (optimizer Adam presisi-penuh standar) menyisakan hanya sekitar 1 GB untuk aktivasi – terlalu mepet untuk aman, karena *overhead* CUDA dan fragmen-tasi memori berisiko menghabiskan sisa tersebut sebelum sempat dipakai aktivasi. Mitigasi yang digunakan untuk Kondisi A dan C (*full fine-tuning*) adalah optimizer Adam 8-bit (*bitsandbytes*), yang memangkas kebutuhan memori optimizer menjadi sekitar 1,9 GB dan menyisakan sekitar 4 GB untuk aktivasi – jauh lebih aman. Dengan mitigasi ini, *full fine-tuning* diperkirakan tetap memerlukan *batch size* kecil (sekitar 1–2), dengan *gradient checkpointing* dan *gradient accumulation* sebagai cadangan opsional jika 4 GB masih belum cukup pada praktiknya. Skema LoRA (Kon-disi B dan D) memiliki ruang gerak yang jauh lebih longgar, dengan *batch size* 8–16 yang tetap realistis tanpa teknik tambahan. Keterbatasan ini sekaligus menjadi ilus-trasi konkret argumen efisiensi LoRA yang diuji dalam penelitian ini (Subbab 2.7): pada perangkat keras yang benar-benar terbatas, LoRA bukan hanya lebih hemat secara teoretis, tetapi menjadi opsi yang jauh lebih praktis dijalankan.

Strategi 2 GPU yang digunakan bukan *distributed training* (model sudah mu-at pada 1 kartu), melainkan 2 *run* independen paralel, satu per GPU (diatur lewat `CUDA_VISIBLE_DEVICES`), karena grid eksperimen (4 kondisi $\times$ k fold) bersifat *em-barrassingly parallel*.

Rekomendasi teknis lain: *mixed precision* (fp16/bf16) untuk mengurangi je-jak memori, serta membekukan *CNN feature extractor* (praktik standar pada *fine-tuning* wav2vec2). Dengan skala dataset target diperkirakan sekitar 5 ribu sampel (Subbab 3.3), estimasi kasar waktu per-*run* berkisar puluhan menit hingga bebera-pa jam – kemungkinan lebih lama untuk kondisi *full fine-tuning* karena *batch size* yang lebih kecil – sehingga total waktu penelitian ($k = 5$, sekitar 21 *run*) diperkirak-an selesai dalam hitungan hari dengan pemanfaatan 2 GPU secara paralel. Estimasi ini bersifat kasar dan perlu diverifikasi pada uji coba awal.

DAFTAR REFERENSI

- Arisaputra, P. and Zahra, A., 2023. Indonesian automatic speech recognition with XLSR-53. *arXiv:2308.11589 [cs.CL]*.
- Baevski, A., Zhou, H., Mohamed, A. and Auli, M., 2020. wav2vec 2.0: a framework for self-supervised learning of speech representations. *Advances in Neural Information Processing Systems (NeurIPS)*, 33, pp.12449-12460.
- Bella, G., Helm, P., Koch, G. and Giunchiglia, F., 2023. Towards bridging the digital language divide. *arXiv:2307.13405 [cs.CL]*.
- Cao, H., Cooper, D.G., Keutmann, M.K., Gur, R.C., Nenkova, A. and Verma, R., 2014. CREMA-D: crowd-sourced emotional multimodal actors dataset. *IEEE Transactions on Affective Computing*, 5(4), pp.377-390.
- Conneau, A., Baevski, A., Collobert, R., Mohamed, A. and Auli, M., 2021. Unsupervised cross-lingual representation learning for speech recognition. In: *Proceedings of Interspeech 2021*, pp.2426-2430.
- Dar, G.H.M. and Delhibabu, R., 2024. Speech databases, speech features, and classifiers in speech emotion recognition: a review. *IEEE Access*, 12, pp.151122-151152. <https://doi.org/10.1109/ACCESS.2024.3476960>
- Eljinini, M.A.H. and Al-Momani, W.E., 2025. Advancements in speech recognition: a systematic review of deep learning transformer models, trends, innovations, and future directions. *IEEE Access*. <https://doi.org/10.1109/ACCESS.2025.3550855>
- Hu, E.J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., Wang, L. and Chen, W., 2022. LoRA: low-rank adaptation of large language models. In: *International Conference on Learning Representations (ICLR)*.
- Kohavi, R., 1995. A study of cross-validation and bootstrap for accuracy estimation and model selection. In: *Proceedings of the 14th International Joint Conference on Artificial Intelligence (IJCAI)*, 2, pp.1137-1143.
- Liu, X., Zhang, F., Hou, Z., Mian, L., Wang, Z., Zhang, J. and Tang, J., 2023. Self-supervised learning: generative or contrastive. *IEEE Transactions on Knowledge and Data Engineering*, 35(1), pp.857-876.
- Livingstone, S.R. and Russo, F.A., 2018. The Ryerson Audio-Visual Database of Emotional Speech and Song (RAVDESS): a dynamic, multimodal set of facial and vocal expressions in North American English. *PLOS ONE*, 13(5), e0196391.
- Nugroho, K.S., Iriananda, S.W., Akbar, I., Isnain, M. and Pardamean, B., 2025. Advancing end-to-end Indonesian speech emotion recognition using XLSR-Wav2Vec2. In: *2025 International Conference on Information Technology Research and Innovation (ICITRI)*. IEEE. <https://doi.org/10.1109/ICITRI67507.2025.11232655>

Pan, S.J. and Yang, Q., 2010. A survey on transfer learning. *IEEE Transactions on Knowledge and Data Engineering*, 22(10), pp.1345-1359.

Powers, D.M.W., 2011. Evaluation: from precision, recall and F-measure to ROC, informedness, markedness and correlation. *Journal of Machine Learning Technologies*, 2(1), pp.37-63.

Santoso, T.B., Budianto, A.N. and Dutono, T., 2026. Development of a speech emotion recognition dataset for Indonesian. *IEEE Access*. <https://doi.org/10.1109/ACCESS.2026.3652377>

Shapiro, S.S. and Wilk, M.B., 1965. An analysis of variance test for normality (complete samples). *Biometrika*, 52(3-4), pp.591-611.

Tang, D., Kuppens, P., Geurts, L. and van Waterschoot, T., 2023. End-to-end transfer learning for speaker-independent cross-language and cross-corpus speech emotion recognition. *arXiv:2311.13678 [eess.AS]*.

Wilcoxon, F., 1945. Individual comparisons by ranking methods. *Biometrics Bulletin*, 1(6), pp.80-83.

Wu, P., Shi, J., Zhong, Y., Watanabe, S. and Black, A.W., 2021. Cross-lingual transfer for speech processing using acoustic language similarity. *arXiv:2111.01326 [eess.AS]*.

LAMPIRAN