

**Analisis Pengaruh Strategi Fine-Tuning Dua Tahap terhadap Akurasi Pengenalan
Emosi Ucapan Berbahasa Indonesia**

PROPOSAL SKRIPSI

Disusun oleh:

Gaung Taqwa Indraswara

NIM: 235150207111043



PROGRAM STUDI TEKNIK INFORMATIKA
DEPARTEMEN TEKNIK INFORMATIKA
FAKULTAS ILMU KOMPUTER
UNIVERSITAS BRAWIJAYA
MALANG
2026

DAFTAR ISI

1	Pendahuluan	1
1.1	Latar Belakang	1
1.2	Rumusan Masalah	2
1.3	Tujuan	2
1.4	Manfaat	3
1.5	Batasan Masalah	3
1.6	Sistematika Pembahasan	4
2	Landasan Kepustakaan	5
2.1	Kajian Pustaka	5
2.2	Speech Emotion Recognition (SER)	6
2.3	Pembelajaran Self-Supervised dan Wav2Vec2/XLSR	6
2.4	Cross-Lingual Transfer pada Pemrosesan Ucapan	6
2.5	Strategi Fine-Tuning Dua Tahap	6
2.6	Low-Rank Adaptation (LoRA)	7
2.7	Validasi Silang K-Fold dan Pengujian Signifikansi Statistik	7
2.8	Akurasi dan F1-Score	7
3	Metodologi Penelitian	9
3.1	Tipe Penelitian	9
3.2	Studi Literatur	10
3.3	Pengumpulan Data	10
3.4	Fine-Tuning Sumber	10
3.5	Fine-Tuning Target	11
3.6	Evaluasi K-Fold	11
3.7	Analisis Hasil	11
3.8	Kesimpulan dan Saran	11
3.9	Peralatan Pendukung	12
3.9.1	Perangkat Lunak (Software)	12
3.9.2	Perangkat Keras (Hardware)	12
	Daftar Referensi	13

DAFTAR GAMBAR

3.1	Diagram alir metode penelitian	9
-----	--	---

DAFTAR TABEL

2.1	Daftar penelitian terdahulu	5
-----	---------------------------------------	---

BAB 1 PENDAHULUAN

1.1 Latar Belakang

Emosi merupakan komponen mendasar yang menyertai hampir setiap bentuk komunikasi antarmanusia, karena emosi memungkinkan seseorang menyampaikan maksud dan keadaan batin secara lebih utuh daripada makna literal kata-kata. Melalui emosi, seseorang dapat menunjukkan empati dan menyesuaikan responsnya terhadap lawan bicara, sehingga interaksi menjadi lebih bermakna dan manusiawi. Dalam interaksi manusia dan mesin, pengenalan emosi dari sinyal ucapan memegang peranan penting bagi pengembangan komputasi afektif dan sistem interaktif yang mampu merespons pengguna secara lebih personal (Dar and Delhibabu, 2024). Tanpa kemampuan tersebut, sistem cenderung memperlakukan seluruh pengguna secara seragam, padahal keadaan emosional yang berbeda semestinya direspons secara berbeda pula. Oleh karena itu, kajian mengenai pengenalan emosi secara otomatis terus berkembang dan relevan lintas disiplin.

Di antara berbagai saluran ekspresi emosi seperti raut wajah, gestur tubuh, dan tulisan, suara manusia menempati posisi istimewa karena emosi dapat tersampaikan langsung melalui pola intonasi, tekanan, kecepatan, dan ritme saat seseorang berbicara. Ciri ini sering muncul spontan dan sulit disembunyikan, sehingga ucapan kerap dianggap sumber informasi emosi yang relatif jujur dibandingkan saluran ekspresi lain. Karakteristik inilah yang mendasari berkembangnya *speech emotion recognition* (SER), yaitu bidang kajian yang berupaya mengenali kondisi emosi seseorang secara otomatis dari sinyal ucapannya. Tinjauan pustaka Dar and Delhibabu (2024) menunjukkan bahwa SER telah menjadi perhatian penting dalam pengembangan sistem interaksi manusia-mesin dan komputasi afektif, dengan cakupan penerapan yang terus meluas. Luasnya cakupan tersebut menunjukkan bahwa SER bukan sekadar topik teoretis, melainkan teknologi berpotensi dampak nyata bagi interaksi manusia dengan sistem digital.

Meskipun signifikansinya diakui luas, perkembangan teknologi bahasa berbasis ucapan masih timpang antarbahasa, karena sebagian besar teknologi kecerdasan buatan terpusat pada sebagian kecil bahasa dengan sumber daya digital terbesar (Bella et al., 2023). Ketimpangan ini oleh Bella et al. (2023) disebut bias linguistik, yang membuat performa teknologi bahasa berbeda-beda secara tidak proporsional antarbahasa meski diuji pada kondisi setara. Bahasa Indonesia, meskipun dituturkan ratusan juta jiwa, termasuk kelompok bahasa yang sumber dayanya masih tertinggal dibandingkan bahasa besar seperti Inggris. Ketimpangan ini semakin terasa pada tugas SER, yang membutuhkan data ucapan beranotasi emosi dalam jumlah memadai, padahal pengumpulan dan anotasinya memerlukan biaya, waktu, dan tenaga ahli. Kesenjangan inilah yang menjadikan pengembangan SER berbahasa Indonesia sebagai permasalahan penelitian yang penting sekaligus menantang.

Salah satu arah yang banyak ditempuh untuk mengatasi kesenjangan sumber daya pada bahasa yang kurang terwakili adalah *cross-lingual transfer*, yaitu strategi memindahkan pengetahuan yang dipelajari model dari bahasa bersumber

daya besar ke bahasa bersumber daya terbatas (Wu et al., 2021). Strategi ini menjanjikan karena memungkinkan model memanfaatkan representasi ucapan yang telah dipelajari secara luas tanpa membangun ulang pembelajaran dari data Indonesia yang masih terbatas. Beberapa penelitian telah menunjukkan potensi arah ini: Nugroho et al. (2025) membuktikan bahwa checkpoint XLSR-Wav2Vec2 yang disesuaikan dengan karakteristik akustik Indonesia dapat mencapai akurasi SER hingga 91,67%, sementara Santoso, Budianto and Dutono (2026) menunjukkan bahwa skema *fine-tuning* dua tahap dapat menghasilkan akurasi 90% pada dataset SER Indonesia yang mereka kembangkan.

Akan tetapi, penerapan *cross-lingual transfer* secara spesifik pada SER berbahasa Indonesia masih belum menjawab secara sistematis seberapa jauh keterbatasan data dapat diatasi tanpa mengorbankan kualitas pengenalan emosi. Penelitian Santoso, Budianto and Dutono (2026) hanya melaporkan satu konfigurasi *fine-tuning* dua tahap terbaik tanpa membandingkannya dengan strategi lain seperti pelatihan satu tahap langsung pada data Indonesia, maupun tanpa menguji apakah perbedaan performa antarstrategi tersebut signifikan secara statistik. Demikian pula, belum ada kajian yang membandingkan *full fine-tuning* dengan *fine-tuning* efisien-parameter seperti *Low-Rank Adaptation* (LoRA) pada konteks SER Indonesia, padahal LoRA menjanjikan efisiensi komputasi yang relevan bagi peneliti dengan sumber daya terbatas. Berdasarkan uraian tersebut, diperlukan kajian analitik mengenai pengaruh strategi *fine-tuning* lintas bahasa terhadap akurasi klasifikasi emosi pada ucapan berbahasa Indonesia, yang akan dianalisis dalam skripsi ini.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah dipaparkan, maka permasalahan dalam penelitian ini dapat dirumuskan sebagai berikut.

1. Bagaimana perbedaan akurasi dan F1-score klasifikasi emosi antara model yang dilatih langsung (*single-stage*) pada dataset emosi berbahasa Indonesia dan model yang melalui *fine-tuning* dua tahap (pra-latih pada korpus emosi berbahasa Inggris, lalu diadaptasi ke data Indonesia)?
2. Apakah terdapat perbedaan performa yang signifikan secara statistik antara strategi *full fine-tuning* dan strategi *fine-tuning* efisien-parameter (LoRA) pada tahap adaptasi ke data target?
3. Bagaimana konsistensi hasil klasifikasi emosi antar-*fold* pada skema validasi silang untuk masing-masing strategi *fine-tuning* yang diuji?

1.3 Tujuan

Tujuan dari penelitian ini menjawab rumusan masalah yang telah dipaparkan, maka penelitian ini memiliki tujuan sebagai berikut.

1. Menganalisis perbedaan akurasi dan F1-score klasifikasi emosi antara model yang dilatih langsung pada data Indonesia (*single-stage*) dan model yang melalui *fine-tuning* dua tahap dari korpus emosi berbahasa Inggris ke data Indonesia.
2. Menguji signifikansi statistik perbedaan performa antara strategi *full fine-tuning* dan strategi *fine-tuning* efisien-parameter (LoRA) pada tahap adaptasi ke data target.
3. Mengevaluasi konsistensi hasil klasifikasi emosi antar-*fold* pada skema validasi silang untuk setiap strategi *fine-tuning* yang diuji.

1.4 Manfaat

Penelitian ini diharapkan dapat memberikan manfaat sebagai berikut.

1. Memberikan bukti empiris mengenai pengaruh strategi *fine-tuning* lintas bahasa terhadap akurasi SER berbahasa Indonesia, sehingga dapat menjadi rujukan bagi peneliti lain yang mengembangkan sistem pengenalan emosi ucapan pada bahasa dengan sumber daya terbatas.
2. Memberikan gambaran perbandingan yang teruji secara statistik antara strategi *full fine-tuning* dan LoRA, sehingga dapat membantu peneliti maupun praktisi dalam memilih strategi adaptasi model yang efisien dari segi sumber daya komputasi tanpa mengorbankan akurasi secara signifikan.
3. Berkontribusi pada pengembangan riset komputasi cerdas berbahasa Indonesia, khususnya pada bidang pemrosesan sinyal ucapan yang masih relatif terbatas jumlah kajiannya.

1.5 Batasan Masalah

Batasan masalah yang membatasi penulis dalam melakukan penelitian ini adalah sebagai berikut.

1. Backbone *self-supervised* yang digunakan dibatasi pada keluarga Wav2Vec2/XLSR-53.
2. Korpus sumber pada tahap *fine-tuning* dibatasi pada korpus emosi berbahasa Inggris (RAVDESS/CREMA-D), sedangkan korpus target dibatasi pada dataset emosi berbahasa Indonesia (E-SERAVD/IndoWaveSentiment).
3. Skema kelas emosi yang dibandingkan disamakan antarkorpus agar konsisten, sehingga kelas emosi yang tidak beririsan antara korpus sumber dan target tidak dianalisis lebih lanjut.
4. Evaluasi performa dibatasi pada metrik akurasi dan F1-score yang diuji melalui skema validasi silang k-fold, dengan pengujian signifikansi statistik menggunakan uji Shapiro-Wilk untuk normalitas, dilanjutkan uji *paired t-test* atau *Wilcoxon signed-rank test* sesuai hasil uji normalitas tersebut.

1.6 Sistematika Pembahasan

Bab 1 Pendahuluan membahas mengenai latar belakang penelitian ini diangkat, rumusan masalah yang terdapat pada penelitian, tujuan dan manfaat penelitian, batasan masalah pada penelitian, serta sistematika pembahasan penulisan penelitian yang berjudul Analisis Pengaruh Strategi Fine-Tuning Dua Tahap terhadap Akurasi Pengenalan Emosi Ucapan Berbahasa Indonesia.

Bab 2 Landasan Kepustakaan membahas tentang kajian pustaka dan dasar teori. Kajian pustaka berisi referensi mengenai penelitian-penelitian sebelumnya yang terkait dengan SER, representasi *self-supervised*, dan *cross-lingual transfer*. Dasar teori membahas konsep-konsep yang mendasari metode yang digunakan, meliputi Wav2Vec2/XLSR, strategi *fine-tuning* dua tahap, *Low-Rank Adaptation* (LoRA), serta metrik evaluasi akurasi dan F1-score.

Bab 3 Metodologi Penelitian membahas tipe penelitian serta tahapan penelitian yang dilaksanakan mulai dari studi literatur, pengumpulan data, *fine-tuning* sumber, *fine-tuning* target, evaluasi k-fold, hingga analisis hasil dan penarikan kesimpulan.

BAB 2 LANDASAN KEPUSTAKAAN

2.1 Kajian Pustaka

Kajian pustaka berisi kajian-kajian penelitian terdahulu yang bertujuan untuk mendukung proses penelitian. Kajian pustaka dilakukan untuk mendapatkan informasi yang relevan dengan topik penelitian ini. Tabel 2.1 memaparkan penelitian-penelitian yang terkait dengan subjek yang diteliti.

Tabel 2.1 Daftar penelitian terdahulu

Judul Penelitian	Masalah	Metode	Hasil
Advancements in Speech Recognition: A Systematic Review of Deep Learning Transformer Models, Trends, Innovations, and Future Directions (Eljinini and Al-Momani, 2025)	Pergeseran paradigma dari fitur tangan (<i>hand-crafted features</i>) menuju representasi ucapan yang dipelajari langsung dari sinyal mentah belum ditinjau secara sistematis lintas 37 studi inti.	Tinjauan sistematis (<i>systematic review</i>) terhadap arsitektur transformer dan pembelajaran <i>self-supervised</i> pada pengenalan ucapan.	Transformer dan pembelajaran <i>self-supervised</i> terbukti meningkatkan akurasi pengenalan ucapan pada kondisi akustik menantang dibandingkan fitur tangan konvensional.
Advancing End-to-End Indonesian Speech Emotion Recognition Using XLSR-Wav2Vec2 (Nugroho et al., 2025)	Performa SER berbahasa Indonesia belum diketahui secara komparatif antara metode klasik dan representasi <i>self-supervised</i> multibahasa.	Perbandingan SVM, CNN, dan XLSR-Wav2Vec2 pada dataset IndoWaveSentiment.	Checkpoint monolingual Indonesia mencapai akurasi tertinggi sebesar 91,67%, mengungguli metode klasik.
Development of a Speech Emotion Recognition Dataset for Indonesian (Santoso, Budianto and Dutono, 2026)	Dataset SER berbahasa Indonesia dengan skema <i>fine-tuning</i> yang terdokumentasi masih terbatas.	Pengembangan dataset E-SERAVD melalui skema <i>fine-tuning</i> dua tahap.	Diperoleh akurasi 90% dan F1-score 86% pada satu konfigurasi <i>fine-tuning</i> dua tahap.
Indonesian Automatic Speech Recognition with XLSR-53 (Arisaputra and Zahra, 2023)	Ketersediaan data latih ASR berbahasa Indonesia terbatas dibandingkan bahasa besar.	<i>Cross-lingual transfer</i> menggunakan backbone XLSR-53 pada tugas ASR Indonesia.	<i>Word error rate</i> lebih rendah dicapai meski data latih lebih sedikit dibandingkan pelatihan dari awal.
End-to-End Transfer Learning for Speaker-Independent Cross-Language and Cross-Corpus Speech Emotion Recognition (Tang et al., 2023)	Generalisasi model SER antarbahasa dan antarkorpus belum banyak diuji dengan pendekatan <i>end-to-end</i> .	<i>Transfer learning end-to-end</i> yang bersifat <i>speaker-independent</i> , lintas bahasa, dan lintas korpus.	Menunjukkan potensi generalisasi model emosi antarbahasa melalui pendekatan <i>transfer learning</i> .

Berdasarkan kelima penelitian tersebut, dapat disimpulkan bahwa celah penelitian terletak pada belum adanya studi yang membandingkan strategi *fine-tuning* satu tahap versus dua tahap dan *full fine-tuning* versus LoRA pada SER berbahasa Indonesia secara sistematis dan teruji signifikansi statistiknya. Penelitian ini menempatkan diri pada celah tersebut dengan merancang perbandingan yang sistematis antara keempat kombinasi strategi tersebut, dievaluasi melalui skema validasi silang k-fold dan diuji signifikansi statistiknya.

2.2 Speech Emotion Recognition (SER)

Speech emotion recognition (SER) adalah bidang kajian yang berupaya mengenali kondisi emosi seseorang secara otomatis dari sinyal ucapannya. Dar and Delhibabu (2024) melakukan tinjauan sistematis terhadap basis data ucapan, fitur ucapan, dan pengklasifikasi yang umum digunakan dalam SER, dan menunjukkan bahwa bidang ini telah menjadi perhatian penting dalam pengembangan sistem interaksi manusia-mesin dan komputasi afektif, dengan cakupan penerapan yang terus meluas mulai dari asisten virtual, layanan pelanggan otomatis, hingga sistem kesehatan mental.

2.3 Pembelajaran Self-Supervised dan Wav2Vec2/XLSR

Perkembangan pengenalan ucapan berbasis transformer dan pembelajaran *self-supervised* telah menggeser paradigma dari ekstraksi fitur tangan (*hand-crafted features*) menuju representasi yang dipelajari langsung dari sinyal mentah (Eljinini and Al-Momani, 2025). Wav2Vec2 adalah model *self-supervised* yang dilatih pada volume data ucapan tanpa label berskala besar, sehingga menghasilkan representasi akustik yang kaya dan dapat diadaptasi ke berbagai tugas hilir (*downstream task*). XLSR merupakan varian multibahasa dari Wav2Vec2 yang dilatih pada data ucapan dari banyak bahasa sekaligus, sehingga representasinya lebih mampu menggeneralisasi lintas bahasa dibandingkan model yang hanya dilatih pada satu bahasa saja. Karakteristik inilah yang mendasari pemilihan Wav2Vec2/XLSR sebagai backbone dalam penelitian ini, karena representasi yang dihasilkan berpotensi menjadi dasar yang baik untuk *fine-tuning* lintas bahasa pada tugas SER.

2.4 Cross-Lingual Transfer pada Pemrosesan Ucapan

Cross-lingual transfer adalah strategi memindahkan pengetahuan yang dipelajari model dari bahasa bersumber daya besar ke bahasa bersumber daya terbatas (Wu et al., 2021). Strategi ini banyak ditempuh untuk mengatasi kesenjangan sumber daya pada bahasa yang kurang terwakili dalam teknologi bahasa, karena memungkinkan model memanfaatkan representasi ucapan yang telah dipelajari secara luas tanpa membangun ulang pembelajaran dari data yang masih terbatas pada bahasa target. Arisaputra and Zahra (2023) membuktikan bahwa penerapan strategi ini pada tugas *automatic speech recognition* (ASR) berbahasa Indonesia menghasilkan *word error rate* yang lebih rendah meski data latihnya lebih sedikit dibandingkan pelatihan dari awal, yang menunjukkan bahwa representasi lintas bahasa dapat mengurangi kebutuhan data pada bahasa target.

2.5 Strategi Fine-Tuning Dua Tahap

Strategi *fine-tuning* dua tahap merupakan pendekatan yang mengadaptasi model secara bertahap, yaitu dengan melatih model terlebih dahulu pada korpus sumber yang berbeda bahasa namun memiliki tugas serupa (dalam hal ini, klasifikasi emosi), sebelum diadaptasi lebih lanjut ke data target berbahasa Indonesia. Pendekatan

ini diharapkan memungkinkan model mempelajari pola akustik emosi yang bersifat lebih umum pada tahap pertama, sebelum menyesuaikan pola tersebut dengan karakteristik spesifik Bahasa Indonesia pada tahap kedua. Tang et al. (2023) menunjukkan bahwa pendekatan *transfer learning end-to-end* yang bersifat *speaker-independent*, lintas bahasa, dan lintas korpus memiliki potensi generalisasi yang baik untuk tugas SER, yang mendukung kelayakan skema dua tahap sebagai strategi adaptasi lintas bahasa.

2.6 Low-Rank Adaptation (LoRA)

Low-Rank Adaptation (LoRA) adalah strategi *fine-tuning* efisien-parameter yang bekerja dengan hanya memperbarui sejumlah kecil parameter tambahan berupa matriks berperingkat rendah (*low-rank*), sementara sebagian besar parameter model dasar dibekukan. Berbeda dengan *full fine-tuning* yang memperbarui seluruh parameter model, LoRA menawarkan efisiensi komputasi yang signifikan karena jumlah parameter yang dilatih jauh lebih sedikit. Efisiensi ini relevan bagi penelitian yang memiliki keterbatasan sumber daya komputasi, namun pengaruhnya terhadap akurasi klasifikasi emosi pada konteks SER berbahasa Indonesia belum banyak dikaji secara sistematis, sehingga menjadi salah satu perbandingan utama yang diuji dalam penelitian ini.

2.7 Validasi Silang K-Fold dan Pengujian Signifikansi Statistik

Validasi silang k-fold adalah teknik evaluasi yang membagi data menjadi k bagian (*fold*), dengan setiap bagian secara bergantian digunakan sebagai data uji sementara bagian lainnya digunakan sebagai data latih. Teknik ini menghasilkan beberapa observasi akurasi dan F1-score per fold untuk setiap strategi yang diuji, sehingga memungkinkan pengujian konsistensi performa antar-fold, bukan hanya satu nilai tunggal dari satu kali pengujian. Untuk menguji apakah perbedaan performa antarstrategi bersifat signifikan secara statistik, observasi tersebut terlebih dahulu diuji normalitasnya menggunakan uji Shapiro-Wilk. Apabila data berdistribusi normal, pengujian dilanjutkan dengan *paired t-test*; apabila tidak, digunakan *Wilcoxon signed-rank test* sebagai alternatif non-parametrik.

2.8 Akurasi dan F1-Score

Akurasi dan F1-score adalah dua metrik yang umum digunakan untuk mengevaluasi performa model klasifikasi. Akurasi mengukur proporsi prediksi yang benar terhadap keseluruhan data uji, sehingga memberikan gambaran umum performa model, sebagaimana Persamaan 2.1.

$$\text{Akurasi} = \frac{TP + TN}{TP + TN + FP + FN} \quad (2.1)$$

di mana TP = True Positive, TN = True Negative, FP = False Positive, FN = False Negative.

Akan tetapi, pada data dengan sebaran kelas yang tidak seimbang, akurasi dapat memberikan gambaran yang menyesatkan. F1-score mengatasi keterbatasan tersebut dengan merepresentasikan rata-rata harmonis antara presisi dan recall, sebagaimana Persamaan 2.2.


$$F_1 = 2 \cdot \frac{\text{Presisi} \times \text{Recall}}{\text{Presisi} + \text{Recall}} \quad (2.2)$$

Kedua metrik ini digunakan bersama dalam penelitian ini untuk memberikan gambaran performa yang lebih menyeluruh terhadap setiap strategi *fine-tuning* yang dibandingkan.

BAB 3 METODOLOGI PENELITIAN

3.1 Tipe Penelitian

Penelitian ini merupakan penelitian non-implementatif analitik dengan pendekatan kuantitatif, karena berfokus pada analisis pengaruh strategi *fine-tuning* terhadap akurasi klasifikasi emosi ucapan, bukan pada pengembangan sistem atau perangkat lunak siap pakai. Sifat analitik ditunjukkan melalui pengolahan data hasil observasi akurasi dan F1-score dari setiap strategi *fine-tuning* untuk mengkaji hubungan antara strategi yang diterapkan dan performa klasifikasi emosi yang dihasilkan. Pendekatan kuantitatif digunakan karena data berupa nilai numerik hasil evaluasi model yang dianalisis menggunakan metrik akurasi, F1-score, dan pengujian signifikansi statistik. Model-model yang di-*fine-tune* pada penelitian ini berfungsi sebagai instrumen untuk menghasilkan data observasi tersebut, bukan sebagai produk/artefak utama penelitian.



Gambar 3.1 Diagram alir metode penelitian

Diagram alir metode penelitian ini ditunjukkan pada Gambar 3.1. Tahap awal penelitian diawali dengan studi literatur, yang bertujuan untuk mengkaji teori, metode, serta penelitian terdahulu yang relevan dengan SER, pembelajaran *self-supervised*, dan *cross-lingual transfer*. Tahap berikutnya adalah pengumpulan data, yaitu proses pengumpulan korpus emosi berbahasa Inggris sebagai sumber dan dataset SER berbahasa Indonesia sebagai target. Data yang telah diperoleh selanjutnya diproses pada tahap *fine-tuning* sumber untuk melatih backbone *self-supervised* mengenali pola akustik emosi secara umum. Setelah itu dilakukan *fine-tuning* target untuk mengadaptasi model dasar ke data Indonesia melalui beberapa skema strategi. Tahap berikutnya adalah evaluasi k-fold untuk menilai performa setiap strategi menggunakan skema validasi silang dan pengujian signifikansi statistik. Hasil evaluasi tersebut kemudian digunakan sebagai dasar pada tahap analisis hasil, yang merangkum temuan penelitian serta menjawab rumusan masalah yang telah dipaparkan.

3.2 Studi Literatur

Studi literatur merupakan tahap awal penelitian yang bertujuan untuk mempelajari dan memahami teori, konsep, serta hasil penelitian terdahulu yang berkaitan dengan SER, pembelajaran *self-supervised*, representasi Wav2Vec2/XLSR, dan *cross-lingual transfer*. Pada tahap ini dilakukan pengkajian terhadap jurnal, prosiding konferensi, dan sumber ilmiah relevan untuk memastikan celah penelitian pada Bab 2 Landasan Kepustakaan belum terjawab oleh penelitian lain, sekaligus menentukan backbone model dan skema *fine-tuning* yang sesuai dengan tujuan penelitian.

3.3 Pengumpulan Data

Tahap ini mengumpulkan dua kelompok data, yaitu korpus emosi berbahasa Inggris sebagai sumber pada tahap *fine-tuning* pertama (RAVDESS/CREMA-D), dan dataset SER berbahasa Indonesia sebagai target pada tahap *fine-tuning* kedua (E-SERAVD/IndoWaveSentiment). Skema kelas emosi pada kedua kelompok data disamakan terlebih dahulu agar konsisten antarkorpus, sehingga perbandingan antarstrategi *fine-tuning* dapat dilakukan secara adil.

3.4 Fine-Tuning Sumber

Tahap ini melatih backbone *self-supervised* (Wav2Vec2/XLSR-53) pada korpus emosi berbahasa Inggris agar model mampu mengenali pola akustik emosi secara umum, menghasilkan model dasar yang selanjutnya akan diadaptasi ke data target pada tahap berikutnya.

3.5 Fine-Tuning Target

Tahap ini mengadaptasi model dasar ke data Indonesia melalui dua skema, yaitu *full fine-tuning* yang memperbarui seluruh parameter model, dan LoRA yang hanya memperbarui parameter tambahan berjumlah kecil. Sebagai pembandingan, disiapkan pula model tahap tunggal (*single-stage*) yang dilatih langsung pada data Indonesia tanpa melalui tahap sumber, sehingga diperoleh empat kombinasi strategi yang akan dibandingkan performanya:

1. *Single-stage*, dilatih langsung pada data Indonesia.
2. Dua tahap dengan *full fine-tuning* pada tahap adaptasi target.
3. Dua tahap dengan LoRA pada tahap adaptasi target.
4. *Single-stage* dengan LoRA, sebagai pembandingan tambahan untuk mengisolasi pengaruh LoRA di luar skema dua tahap.

3.6 Evaluasi K-Fold

Tahap ini mengevaluasi setiap strategi *fine-tuning* menggunakan skema validasi silang k-fold, sehingga diperoleh beberapa observasi akurasi dan F1-score per fold untuk masing-masing strategi. Data hasil observasi tersebut kemudian diuji normalitasnya menggunakan uji Shapiro-Wilk. Jika data berdistribusi normal, pengujian dilanjutkan dengan *paired t-test*; jika tidak, digunakan *Wilcoxon signed-rank test*. Pengujian ini bertujuan untuk mengetahui signifikansi statistik perbedaan performa antarstrategi *fine-tuning* yang dibandingkan.

3.7 Analisis Hasil

Tahap ini menafsirkan hasil pengujian signifikansi statistik untuk menjawab rumusan masalah penelitian, serta menyusun rekomendasi strategi *fine-tuning* yang paling sesuai untuk pengembangan SER berbahasa Indonesia berdasarkan temuan yang diperoleh.

3.8 Kesimpulan dan Saran

Penarikan kesimpulan dilaksanakan setelah seluruh tahap evaluasi dan analisis hasil selesai. Kesimpulan memuat jawaban atas rumusan masalah yang telah dituliskan sebelumnya, mengacu pada hasil pengujian signifikansi statistik dari setiap strategi *fine-tuning* yang dibandingkan. Selain kesimpulan, disusun pula saran sebagai bahan pertimbangan dan perbaikan untuk penelitian selanjutnya, misalnya perluasan cakupan korpus sumber atau backbone model yang diuji.

3.9 Peralatan Pendukung

Peralatan pendukung yang digunakan dalam penelitian ini terdiri atas perangkat lunak (*software*) dan perangkat keras (*hardware*).

3.9.1 Perangkat Lunak (Software)

Perangkat lunak yang digunakan dalam mendukung penelitian ini sebagai berikut.

1. Bahasa pemrograman Python.
2. Kerangka kerja *deep learning* untuk pelatihan dan *fine-tuning* model Wav2Vec2/XLSR.
3. Pustaka untuk implementasi LoRA.
4. Pustaka statistik untuk pengujian normalitas dan uji signifikansi.
5. GitHub untuk pengelolaan versi kode sumber dan eksperimen.

3.9.2 Perangkat Keras (Hardware)

Perangkat keras yang digunakan dalam mendukung penelitian ini sebagai berikut.

1. *[Perlu diisi sesuai spesifikasi GPU/komputasi yang sebenarnya digunakan, mis. tipe GPU, kapasitas VRAM, RAM, dan penyimpanan.]*

DAFTAR REFERENSI

- Arisaputra, P. and Zahra, A., 2023. Indonesian automatic speech recognition with XLSR-53. *arXiv:2308.11589 [cs.CL]*.
- Bella, G., Helm, P., Koch, G. and Giunchiglia, F., 2023. Towards bridging the digital language divide. *arXiv:2307.13405 [cs.CL]*.
- Dar, G.H.M. and Delhibabu, R., 2024. Speech databases, speech features, and classifiers in speech emotion recognition: a review. *IEEE Access*, 12, pp.151122-151152. <https://doi.org/10.1109/ACCESS.2024.3476960>
- Eljinini, M.A.H. and Al-Momani, W.E., 2025. Advancements in speech recognition: a systematic review of deep learning transformer models, trends, innovations, and future directions. *IEEE Access*. <https://doi.org/10.1109/ACCESS.2025.3550855>
- Nugroho, K.S., Iriananda, S.W., Akbar, I., Isnain, M. and Pardamean, B., 2025. Advancing end-to-end Indonesian speech emotion recognition using XLSR-Wav2Vec2. In: *2025 International Conference on Information Technology Research and Innovation (ICITRI)*. IEEE. <https://doi.org/10.1109/ICITRI67507.2025.11232655>
- Santoso, T.B., Budianto, A.N. and Dutono, T., 2026. Development of a speech emotion recognition dataset for Indonesian. *IEEE Access*. <https://doi.org/10.1109/ACCESS.2026.3652377>
- Tang, D., Kuppens, P., Geurts, L. and van Waterschoot, T., 2023. End-to-end transfer learning for speaker-independent cross-language and cross-corpus speech emotion recognition. *arXiv:2311.13678 [eess.AS]*.
- Wu, P., Shi, J., Zhong, Y., Watanabe, S. and Black, A.W., 2021. Cross-lingual transfer for speech processing using acoustic language similarity. *arXiv:2111.01326 [eess.AS]*.