

**Analisis Pengaruh Strategi Fine-Tuning Dua Tahap dan Metode
Adaptasi Parameter terhadap Akurasi Pengenalan Emosi Ucapan
Berbahasa Indonesia**

PROPOSAL SKRIPSI

Disusun oleh:

Gaung Taqwa Indraswara

NIM: 235150207111043



PROGRAM STUDI TEKNIK INFORMATIKA
DEPARTEMEN TEKNIK INFORMATIKA
FAKULTAS ILMU KOMPUTER
UNIVERSITAS BRAWIJAYA
MALANG
2026

DAFTAR ISI

Daftar Gambar	ii
Daftar Tabel	iii
1 Pendahuluan	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	2
1.3 Tujuan	2
1.4 Manfaat	3
1.5 Batasan Masalah	3
1.6 Sistematika Pembahasan	4
2 Landasan Kepustakaan	5
2.1 Kajian Pustaka	5
2.2 Speech Emotion Recognition (SER)	6
2.3 Pembelajaran Self-Supervised	7
2.4 Wav2Vec2/XLSR	8
2.5 Cross-Lingual Transfer pada Pemrosesan Ucapan	8
2.6 Strategi Fine-Tuning Dua Tahap	9
2.7 Low-Rank Adaptation (LoRA)	9
2.8 Validasi Silang K-Fold dan Pengujian Signifikansi Statistik	10
2.9 Akurasi, Presisi, Recall, dan F1-Score	11
3 Metodologi Penelitian	12
3.1 Tipe Penelitian	12
3.2 Studi Literatur	13
3.3 Pengumpulan Data	13
3.4 Fine-Tuning Sumber	14
3.5 Fine-Tuning Target	14
3.6 Evaluasi K-Fold	15
3.7 Analisis Hasil	15
3.8 Kesimpulan dan Saran	15
3.9 Peralatan Pendukung	16
3.9.1 Perangkat Lunak (Software)	16
3.9.2 Perangkat Keras (Hardware)	16
Daftar Referensi	18
Lampiran	20

DAFTAR GAMBAR

2.1	Alur umum sistem speech emotion recognition	7
2.2	Alur umum pembelajaran self-supervised	7
2.3	Arsitektur Wav2Vec2	8
2.4	Alur umum cross-lingual transfer	8
2.5	Alur strategi fine-tuning dua tahap	9
2.6	Arsitektur Low-Rank Adaptation (LoRA)	10
2.7	Ilustrasi satu putaran validasi silang k-fold ($k = 5$); peran fold sebagai data uji bergantian pada setiap putaran hingga kelima fold pernah menjadi data uji	10
3.1	Diagram alir metode penelitian	12

DAFTAR TABEL

2.1	Daftar penelitian terdahulu	5
3.1	Karakteristik dataset yang digunakan	14
3.2	Empat kondisi eksperimen (desain 2×2)	15
3.3	Estimasi kecukupan VRAM per kartu (6GB)	16

BAB 1 PENDAHULUAN

1.1 Latar Belakang

Emosi merupakan komponen mendasar yang menyertai hampir setiap bentuk komunikasi antarmanusia, karena emosi memungkinkan seseorang menyampaikan maksud dan keadaan batin secara lebih utuh daripada makna literal kata-kata. Melalui emosi, seseorang dapat menunjukkan empati dan menyesuaikan responsnya terhadap lawan bicara, sehingga interaksi menjadi lebih bermakna dan manusiawi. Dalam interaksi manusia dan mesin, pengenalan emosi dari sinyal ucapan memegang peranan penting bagi pengembangan komputasi afektif dan sistem interaktif yang mampu merespons pengguna secara lebih personal (Dar and Delhibabu, 2024). Tanpa kemampuan tersebut, sistem cenderung memperlakukan seluruh pengguna secara seragam, padahal keadaan emosional yang berbeda semestinya direspons secara berbeda pula. Di antara berbagai saluran ekspresi emosi seperti raut wajah, gestur tubuh, dan tulisan, suara manusia menempati posisi istimewa karena emosi dapat tersampaikan langsung melalui pola intonasi, tekanan, kecepatan, dan ritme saat seseorang berbicara. Ciri ini sering muncul spontan dan sulit disembunyikan, sehingga ucapan kerap dianggap sumber informasi emosi yang relatif jujur dibandingkan saluran ekspresi lain. Karakteristik inilah yang mendasari berkembangnya *speech emotion recognition* (SER), yaitu bidang kajian yang berupaya mengenali kondisi emosi seseorang secara otomatis dari sinyal ucapannya. Tinjauan pustaka Dar and Delhibabu (2024) menunjukkan bahwa SER telah menjadi perhatian penting dalam pengembangan sistem interaksi manusia-mesin dan komputasi afektif, dengan cakupan penerapan yang terus meluas. Luasnya cakupan tersebut menunjukkan bahwa SER bukan sekadar topik teoretis, melainkan teknologi berpotensi dampak nyata bagi interaksi manusia dengan sistem digital.

Meskipun signifikansinya diakui luas, perkembangan teknologi bahasa berbasis ucapan masih timpang antarbahasa, karena sebagian besar teknologi kecerdasan buatan terpusat pada sebagian kecil bahasa dengan sumber daya digital terbesar (Bella et al., 2023). Ketimpangan ini oleh Bella et al. (2023) disebut bias linguistik, yang membuat performa teknologi bahasa berbeda-beda secara tidak proporsional antarbahasa meski diuji pada kondisi setara. Bahasa Indonesia, meskipun dituturkan ratusan juta jiwa, termasuk kelompok bahasa yang sumber dayanya masih tertinggal dibandingkan bahasa besar seperti Inggris. Ketimpangan ini semakin terasa pada tugas SER, yang membutuhkan data ucapan beranotasi emosi dalam jumlah memadai, padahal pengumpulan dan anotasinya memerlukan biaya, waktu, dan tenaga ahli. Kesenjangan inilah yang menjadikan pengembangan SER berbahasa Indonesia sebagai permasalahan penelitian yang penting sekaligus menantang.

Salah satu arah yang banyak ditempuh untuk mengatasi kesenjangan sumber daya pada bahasa yang kurang terwakili adalah *cross-lingual transfer*, yaitu strategi memindahkan pengetahuan yang dipelajari model dari bahasa bersumber daya besar ke bahasa bersumber daya terbatas (Wu et al., 2021). Strategi ini menjanjikan karena memungkinkan model memanfaatkan representasi ucapan yang telah

dipelajari secara luas tanpa membangun ulang pembelajaran dari data Indonesia yang masih terbatas. Beberapa penelitian telah menunjukkan potensi arah ini: Nugroho et al. (2025) menunjukkan bahwa model-model dasar XLSR-Wav2Vec2 yang telah di-*fine-tune* untuk ucapan Indonesia – memanfaatkan data Mozilla Common Voice serta OpenSLR berbahasa Jawa dan Sunda – dapat mencapai akurasi SER hingga 91,67%, sementara Santoso, Budianto and Dutono (2026) menetapkan *baseline* performa 90% akurasi dan 86% F1-score pada dataset E-SERAVD menggunakan model CNN konvensional dengan fitur MFCC, tanpa melibatkan representasi *self-supervised* lintas bahasa.

Akan tetapi, penerapan *cross-lingual transfer* secara spesifik pada SER berbahasa Indonesia masih belum menjawab secara sistematis seberapa jauh keterbatasan data dapat diatasi tanpa mengorbankan kualitas pengenalan emosi. Penelitian Santoso, Budianto and Dutono (2026) baru menetapkan *baseline* performa pada dataset E-SERAVD menggunakan model konvensional tanpa representasi *self-supervised* atau *cross-lingual transfer* apa pun, sehingga potensi pendekatan seperti XLSR-53 – apalagi dengan skema *fine-tuning* dua tahap – pada dataset ini belum diuji sama sekali. Demikian pula, belum ada kajian yang membandingkan *full fine-tuning* dengan *fine-tuning* efisien-parameter seperti *Low-Rank Adaptation* (LoRA) pada konteks SER Indonesia, padahal LoRA menjanjikan efisiensi komputasi yang relevan bagi peneliti dengan sumber daya terbatas. Berdasarkan uraian tersebut, diperlukan kajian analitik mengenai pengaruh strategi *fine-tuning* lintas bahasa terhadap akurasi klasifikasi emosi pada ucapan berbahasa Indonesia, yang akan dianalisis dalam skripsi ini.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah dipaparkan, maka permasalahan dalam penelitian ini dapat dirumuskan sebagai berikut.

1. Bagaimana pengaruh strategi *fine-tuning* (*single-stage* dibandingkan *fine-tuning* dua tahap, yaitu pra-latih pada korpus emosi berbahasa Inggris lalu diadaptasi ke data Indonesia) terhadap performa klasifikasi emosi ucapan berbahasa Indonesia?
2. Bagaimana pengaruh metode adaptasi (*full fine-tuning* dibandingkan LoRA) terhadap performa klasifikasi emosi pada tahap adaptasi ke data target, baik pada skema *single-stage* maupun *two-stage*?
3. Bagaimana konsistensi hasil klasifikasi emosi antar-*fold* pada skema validasi silang untuk masing-masing strategi *fine-tuning* yang diuji?

1.3 Tujuan

Tujuan dari penelitian ini menjawab rumusan masalah yang telah dipaparkan, maka penelitian ini memiliki tujuan sebagai berikut.

1. Menganalisis pengaruh strategi *fine-tuning* (*single-stage* dibandingkan dua tahap) terhadap performa klasifikasi emosi, diukur melalui akurasi, presisi, recall, dan F1-score.
2. Menganalisis pengaruh metode adaptasi (*full fine-tuning* dibandingkan LoRA) terhadap performa klasifikasi emosi pada tahap adaptasi ke data target.
3. Mengevaluasi konsistensi hasil klasifikasi emosi antar-*fold* pada skema validasi silang untuk setiap strategi *fine-tuning* yang diuji.

1.4 Manfaat

Penelitian ini diharapkan dapat memberikan manfaat sebagai berikut.

1. Memberikan bukti empiris mengenai pengaruh strategi *fine-tuning* lintas bahasa terhadap akurasi SER berbahasa Indonesia, sehingga dapat menjadi rujukan bagi peneliti lain yang mengembangkan sistem pengenalan emosi ucapan pada bahasa dengan sumber daya terbatas.
2. Memberikan gambaran perbandingan yang teruji secara statistik antara strategi *full fine-tuning* dan LoRA, sehingga dapat membantu peneliti maupun praktisi dalam memilih strategi adaptasi model yang efisien dari segi sumber daya komputasi tanpa mengorbankan akurasi secara signifikan.
3. Berkontribusi pada pengembangan riset komputasi cerdas berbahasa Indonesia, khususnya pada bidang pemrosesan sinyal ucapan yang masih relatif terbatas jumlah kajiannya.

1.5 Batasan Masalah

Batasan masalah yang membatasi penulis dalam melakukan penelitian ini adalah sebagai berikut.

1. Backbone *self-supervised* yang digunakan dibatasi pada keluarga Wav2Vec2/XLSR-53.
2. Korpus sumber pada tahap *fine-tuning* dibatasi pada korpus emosi berbahasa Inggris (RAVDESS/CREMA-D), sedangkan korpus target dibatasi pada dataset emosi berbahasa Indonesia (E-SERAVD).
3. Skema kelas emosi yang dibandingkan disamakan antarkorpus agar konsisten, sehingga kelas emosi yang tidak beririsan antara korpus sumber dan target tidak dianalisis lebih lanjut.
4. Evaluasi performa dibatasi pada metrik kualitas klasifikasi – akurasi, presisi, recall, dan F1-score – yang diuji melalui skema validasi silang k-fold dan pengujian signifikansi statistik menggunakan uji Shapiro-Wilk untuk normalitas, dilanjutkan uji *paired t-test* atau *Wilcoxon signed-rank test* sesuai hasil uji normalitas tersebut.

5. Eksperimen dijalankan pada 2 unit GPU NVIDIA RTX 3060 6GB, sehingga konfigurasi batch size dan teknik optimasi memori (misalnya *gradient checkpointing*) disesuaikan dengan kapasitas tersebut.

1.6 Sistematika Pembahasan

Bab 1 Pendahuluan membahas mengenai latar belakang penelitian ini diangkat, rumusan masalah, tujuan dan manfaat penelitian, batasan masalah, serta sistematika pembahasan penulisan penelitian yang berjudul Analisis Pengaruh Strategi Fine-Tuning Dua Tahap dan Metode Adaptasi Parameter terhadap Akurasi Pengenalan Emosi Ucapan Berbahasa Indonesia.

Bab 2 Landasan Kepustakaan membahas tentang kajian pustaka dan dasar teori. Kajian pustaka berisi referensi mengenai penelitian-penelitian sebelumnya yang terkait dengan SER, representasi *self-supervised*, dan *cross-lingual transfer*. Dasar teori membahas konsep-konsep yang mendasari metode yang digunakan, meliputi pembelajaran *self-supervised*, Wav2Vec2/XLSR, *cross-lingual transfer*, strategi *fine-tuning* dua tahap, *Low-Rank Adaptation* (LoRA), validasi silang k-fold dan pengujian signifikansi statistik, serta metrik evaluasi akurasi, presisi, recall, dan F1-score.

Bab 3 Metodologi Penelitian membahas tipe penelitian serta tahapan penelitian yang dilaksanakan mulai dari studi literatur, pengumpulan data, *fine-tuning* sumber, *fine-tuning* target, evaluasi k-fold, hingga analisis hasil dan penarikan kesimpulan.

Bab 4 Hasil menyajikan hasil pelaksanaan setiap strategi *fine-tuning* yang diuji, meliputi observasi akurasi, presisi, recall, dan F1-score per fold dari skema validasi silang k-fold untuk keempat kondisi eksperimen (Kondisi A–D, lihat Subbab 3.5), beserta hasil pengujian normalitas dan signifikansi statistiknya.

Bab 5 Pembahasan menerjemahkan makna dari hasil yang diperoleh pada Bab 4 untuk menjawab rumusan masalah penelitian, mencakup interpretasi perbedaan performa antarstrategi *fine-tuning*, konsistensi hasil antar-fold, serta kaitannya dengan landasan teori dan penelitian terdahulu yang telah diuraikan pada Bab 2.

Bab 6 Penutup memuat kesimpulan yang menjawab rumusan masalah berdasarkan hasil dan pembahasan penelitian, serta saran untuk pengembangan penelitian selanjutnya, misalnya perluasan cakupan korpus sumber atau backbone model yang diuji.

BAB 2 LANDASAN KEPUSTAKAAN

2.1 Kajian Pustaka

Kajian pustaka berisi kajian-kajian penelitian terdahulu yang bertujuan untuk mendukung proses penelitian. Kajian pustaka dilakukan untuk mendapatkan informasi yang relevan dengan topik penelitian ini. Tabel 2.1 memaparkan penelitian-penelitian yang terkait dengan subjek yang diteliti.

Tabel 2.1 Daftar penelitian terdahulu

Judul Penelitian	Masalah	Metode	Hasil
Advancements in Speech Recognition: A Systematic Review of Deep Learning Transformer Models, Trends, Innovations, and Future Directions (Eljinini and Al-Momani, 2025)	Pergeseran paradigma dari fitur tangan (<i>hand-crafted features</i>) menuju representasi ucapan yang dipelajari langsung dari sinyal mentah belum ditinjau secara sistematis lintas 37 studi in-ti.	Tinjauan sistematis (<i>systematic review</i>) terhadap arsitektur transformer dan pembelajaran <i>self-supervised</i> pada pengenalan ucapan.	Transformer dan pembelajaran <i>self-supervised</i> terbukti meningkatkan akurasi pengenalan ucapan pada kondisi akustik menantang dibandingkan fitur tangan konvensional.
Advancing End-to-End Indonesian Speech Emotion Recognition Using XLSR-Wav2Vec2 (Nugroho et al., 2025)	Performa SER berbahasa Indonesia belum diketahui secara komparatif antara metode klasik dan representasi <i>self-supervised</i> multibahasa.	Perbandingan SVM, CNN, dan dua model dasar XLSR-Wav2Vec2 yang telah di- <i>fine-tune</i> untuk ucapan Indonesia (Common Voice, OpenSLR Jawa/Sunda), diuji pada dataset IndoWave-Sentiment.	Model dasar XLSR-Wav2Vec2 yang telah disesuaikan untuk ucapan Indonesia mencapai akurasi tertinggi sebesar 91,67%, mengungguli metode klasik.
Development of a Speech Emotion Recognition Dataset for Indonesian (Santoso, Budianto and Dutono, 2026)	Dataset SER berbahasa Indonesia dengan <i>baseline</i> performa yang terdokumentasi masih terbatas.	Pengembangan dataset E-SERAVD; performa dasar diuji menggunakan model CNN dengan fitur MFCC (bukan model pra-latih <i>self-supervised</i>).	Model CNN dasar mencapai akurasi 90% dan F1-score 86% pada subset seimbang (1.000 sampel, 250/kelas).
Indonesian Automatic Speech Recognition with XLSR-53 (Arisaputra and Zahra, 2023)	Ketersediaan data latih ASR berbahasa Indonesia terbatas dibandingkan bahasa besar.	<i>Cross-lingual transfer</i> menggunakan backbone XLSR-53 pada tugas ASR Indonesia.	<i>Word error rate</i> lebih rendah dicapai meski data latih lebih sedikit dibandingkan pelatihan dari awal.
End-to-End Transfer Learning for Speaker-Independent Cross-Language and Cross-Corpus Speech Emotion Recognition (Tang et al., 2023)	Generalisasi model SER antarbahasa dan antarkorpus belum banyak diuji dengan pendekatan <i>end-to-end</i> .	<i>Transfer learning end-to-end</i> yang bersifat <i>speaker-independent</i> , lintas bahasa, dan lintas korpus.	Menunjukkan potensi generalisasi model emosi antarbahasa melalui pendekatan <i>transfer learning</i> .

Berdasarkan kelima penelitian tersebut, dapat disimpulkan bahwa celah penelitian terletak pada belum adanya studi yang membandingkan strategi *fine-tuning* satu tahap versus dua tahap dan *full fine-tuning* versus LoRA pada SER berbahasa Indonesia secara sistematis dan teruji signifikansi statistiknya. Penelitian ini menempatkan diri pada celah tersebut dengan merancang perbandingan yang sistematis antara keempat kombinasi strategi tersebut, dievaluasi melalui skema

validasi silang k-fold dan diuji signifikansi statistiknya.

Celah tersebut dapat disintesis dalam empat kelompok pembandingan berdasarkan persamaan dan perbedaannya dengan penelitian ini. Pertama, Eljinini and Al-Momani (2025) meletakkan fondasi representasi *self-supervised* secara umum, namun tidak menyentuh domain emosi maupun bahasa Indonesia secara spesifik. Kedua, Nugroho et al. (2025) menerapkan representasi *self-supervised* untuk SER berbahasa Indonesia, tetapi model dasar yang mereka uji merupakan hasil *fine-tuning* untuk ucapan Indonesia secara umum, bukan hasil *fine-tuning* khusus dari korpus emosi berbahasa asing. Ketiga, Santoso, Budianto and Dutono (2026) menyediakan dataset E-SERAVID dan menetapkan *baseline* performa menggunakan CNN konvensional tanpa representasi *self-supervised* lintas bahasa; performa pendekatan seperti XLSR-53 – apalagi dengan skema dua tahap – belum diuji pada dataset ini sama sekali. Keempat, Arisaputra and Zahra (2023) serta Tang et al. (2023) memanfaatkan *cross-lingual transfer*, tetapi tidak menyoroti korpus emosi berbahasa Inggris ke data emosi berbahasa Indonesia secara spesifik. Sebagai penguat argumen *novelty* di level lokal, penelusuran terhadap 924 skripsi Teknik Informatika FILKOM UB yang tersedia secara *open-access* juga belum menemukan satu pun yang mengangkat SER berbasis audio.

Karena tidak ada satu pun penelitian yang menguji kombinasi persis backbone XLSR-53, arah lintas bahasa Inggris ke Indonesia, dan tugas SER sekaligus, gap argument ini perlu dirangkai secara eksplisit dari bukti-bukti berdekatan, supaya celah penelitian terasa *well-motivated* dan bukan muncul tiba-tiba. Pada axis pertama (*single-stage* dibandingkan *two-stage*), Wu et al. (2021) menunjukkan bahwa *cross-lingual transfer* efektif secara teoretis untuk pemrosesan ucapan secara umum; Arisaputra and Zahra (2023), pada backbone dan bahasa target yang sama persis dengan penelitian ini (XLSR-53, Indonesia), membuktikan bahwa transfer lintas bahasa menurunkan *word error rate* pada tugas ASR (berbeda tugas dari SER); dan Tang et al. (2023), pada tugas yang sama (SER), menunjukkan potensi generalisasi transfer lintas bahasa meski pada pasangan bahasa yang berbeda dari Inggris-Indonesia. Pada axis kedua (*full fine-tuning* dibandingkan LoRA), Hu et al. (2022) menunjukkan bahwa LoRA menyamai atau mengungguli *full fine-tuning* pada model bahasa besar dengan parameter yang dilatih jauh lebih sedikit, dan temuan serupa juga dilaporkan pada model ucapan (*speech*) berskala besar secara umum (Ou et al., 2024) – di domain suara, bukan cuma teks. Kombinasi kedua axis ini diuji bersamaan (bukan salah satu saja) karena, begitu axis pertama (staging) terbukti membantu, pertanyaan lanjutan seberapa murah cara memperoleh manfaat tersebut muncul dari logika internal kombinasinya sendiri – relevan langsung bagi peneliti dengan sumber daya terbatas, motivasi awal penelitian ini. Dengan demikian, penelitian ini menguji hipotesis yang didukung bukti tidak langsung pada kombinasi yang belum pernah diuji secara langsung, bukan sekadar melengkapi temuan yang sudah ada.

2.2 Speech Emotion Recognition (SER)

Speech emotion recognition (SER) adalah bidang kajian yang berupaya mengenali kondisi emosi seseorang secara otomatis dari sinyal ucapannya, dengan

memanfaatkan ciri-ciri akustik seperti intonasi, nada dasar (*pitch*), energi, dan ritme bicara yang secara empiris berkorelasi dengan keadaan emosional penutur (Dar and Delhibabu, 2024). Secara umum, sistem SER bekerja melalui tiga tahap utama: (1) ekstraksi representasi dari sinyal ucapan mentah, baik berupa fitur akustik tangan (*hand-crafted features*) maupun representasi yang dipelajari (*learned representations*); (2) pemetaan representasi tersebut ke ruang fitur yang relevan dengan kelas emosi; dan (3) klasifikasi ke salah satu kategori emosi yang telah ditentukan (mis. senang, sedih, marah, netral). Gambar 2.1 menggambarkan alur umum tersebut.




Gambar 2.1 Alur umum sistem speech emotion recognition

Cakupan penerapan SER terus meluas, mulai dari asisten virtual yang responsif terhadap keadaan pengguna, layanan pelanggan otomatis yang dapat mendeteksi frustrasi penelepon, hingga sistem pemantauan kesehatan mental yang menandai perubahan pola emosi dari waktu ke waktu. Perkembangan representasi *self-supervised* seperti Wav2Vec2/XLSR, yang dibahas pada Subbab 2.4, menjadi salah satu pendorong utama peningkatan akurasi SER dibandingkan pendekatan fitur tangan konvensional.

2.3 Pembelajaran Self-Supervised

Pembelajaran *self-supervised* adalah paradigma pembelajaran mesin yang melatih model pada data tanpa label dengan cara menciptakan sinyal pengawasan (*supervision signal*) dari data itu sendiri, alih-alih memerlukan label yang dianotasi manusia (Liu et al., 2023). Model dilatih untuk menyelesaikan *pretext task*, yaitu tugas bantu yang dirancang agar penyelesaiannya mengharuskan model mempelajari struktur dan pola yang mendasari data, misalnya memprediksi bagian data yang disembunyikan dari bagian yang tersisa. Representasi yang dipelajari selama proses ini kemudian dapat digunakan atau diadaptasi (*fine-tuned*) untuk tugas hilir (*downstream task*) yang sesungguhnya, seperti klasifikasi emosi pada penelitian ini. Gambar 2.2 menggambarkan alur umum tersebut.




Gambar 2.2 Alur umum pembelajaran self-supervised

Keunggulan utama paradigma ini adalah kemampuannya memanfaatkan data tanpa label dalam jumlah besar, yang jauh lebih mudah dan murah diperoleh dibandingkan data berlabel. Karakteristik inilah yang mendasari penggunaannya secara luas pada domain ucapan, termasuk pada backbone Wav2Vec2/XLSR yang digunakan dalam penelitian ini, sebagaimana diuraikan pada Subbab 2.4.

2.4 Wav2Vec2/XLSR

Wav2Vec2 adalah arsitektur pembelajaran *self-supervised* untuk representasi ucapan yang dilatih pada volume data ucapan tanpa label berskala besar (Babevski et al., 2020). Arsitekturnya terdiri atas tiga komponen utama, sebagaimana digambarkan pada Gambar 2.3: (1) *feature encoder* berbasis *convolutional neural network* (CNN) yang mengubah gelombang ucapan mentah menjadi representasi laten Z pada resolusi waktu yang lebih rendah; (2) *context network* berbasis Transformer yang mengolah Z (dengan sebagian di antaranya disembunyikan/*masked*) menjadi representasi terkontekstualisasi C ; dan (3) modul kuantisasi yang mendiskretkan Z menjadi target kuantisasi Q , khusus digunakan pada tahap pra-latih untuk menghitung *contrastive loss* yang mendorong model membedakan representasi kuantisasi yang benar dari sejumlah pengganggu (*distractors*).




Gambar 2.3 Arsitektur Wav2Vec2

XLSR merupakan varian multibahasa dari Wav2Vec2 yang dilatih pada data ucapan tanpa label dari banyak bahasa sekaligus, menggunakan arsitektur dan tujuan pra-latih yang sama, namun dengan korpus pra-latih gabungan lintas bahasa (Conneau et al., 2021). Karena dilatih lintas bahasa, representasi yang dihasilkan XLSR cenderung menangkap struktur akustik yang lebih umum dan dapat menggeneralisasi lintas bahasa dibandingkan model yang hanya dilatih pada satu bahasa saja. Karakteristik inilah yang mendasari pemilihan Wav2Vec2/XLSR sebagai backbone dalam penelitian ini, karena representasi C yang dihasilkan berpotensi menjadi titik awal (*initialization*) yang baik untuk *fine-tuning* lintas bahasa pada tugas SER, sebagaimana diuraikan pada Subbab 2.6.

2.5 Cross-Lingual Transfer pada Pemrosesan Ucapan

Cross-lingual transfer adalah strategi memindahkan pengetahuan yang dipelajari model dari bahasa bersumber daya besar ke bahasa bersumber daya terbatas (Wu et al., 2021). Strategi ini bekerja dengan memanfaatkan representasi yang telah dipelajari model pada data bahasa sumber sebagai titik awal, alih-alih melatih model dari awal (*from scratch*) pada data bahasa target yang terbatas jumlahnya. Gambar 2.4 menggambarkan alur umum tersebut: model dilatih terlebih dahulu pada bahasa sumber yang memiliki data melimpah, kemudian representasi yang dihasilkan diadaptasi ke bahasa target.



Gambar 2.4 Alur umum cross-lingual transfer

Pendekatan ini banyak ditempuh untuk mengatasi kesenjangan sumber data pada bahasa yang kurang terwakili dalam teknologi bahasa, karena memungkinkan model memanfaatkan pola akustik atau linguistik yang telah dipelajari secara luas tanpa membangun ulang pembelajaran dari data yang masih terbatas pada bahasa target. Pada konteks penelitian ini, bahasa sumber adalah bahasa Inggris (dengan korpus emosi RAVDESS/CREMA-D yang tersedia luas) dan bahasa target adalah Bahasa Indonesia (dengan korpus emosi yang relatif terbatas), sebagaimana diuraikan lebih lanjut pada Subbab 2.6.

2.6 Strategi Fine-Tuning Dua Tahap


Strategi *fine-tuning* dua tahap merupakan bentuk penerapan *cross-lingual transfer* (Subbab 2.5) yang mengadaptasi model secara bertahap melalui dua kali proses *fine-tuning* berurutan, alih-alih satu kali *fine-tuning* langsung ke data target (Pan and Yang, 2010). Secara formal, jika θ_0 menyatakan bobot Wav2Vec2/XLSR hasil pra-latih (Subbab 2.4), maka tahap pertama melatih model pada korpus sumber D_{src} untuk memperoleh bobot antara sebagaimana Persamaan 2.1.

$$\theta_1 = \arg \min_{\theta} \mathcal{L}_{src}(\theta; D_{src}), \quad \theta \text{ diinisialisasi dari } \theta_0 \quad (2.1)$$

Tahap kedua kemudian mengadaptasi bobot antara θ_1 tersebut ke korpus target D_{tgt} untuk memperoleh bobot akhir sebagaimana Persamaan 2.2.

$$\theta_2 = \arg \min_{\theta} \mathcal{L}_{tgt}(\theta; D_{tgt}), \quad \theta \text{ diinisialisasi dari } \theta_1 \quad (2.2)$$

Gambar 2.5 menggambarkan alur dua tahap tersebut.



Gambar 2.5 Alur strategi fine-tuning dua tahap


Pendekatan bertahap ini diharapkan memungkinkan model mempelajari pola akustik emosi yang bersifat lebih umum pada tahap pertama, sebelum menyesuaikan pola tersebut dengan karakteristik spesifik Bahasa Indonesia pada tahap kedua. Sebagai pembandingan pada penelitian ini, disiapkan pula skema *single-stage* yang melewati tahap pertama dan langsung melatih θ_0 pada D_{tgt} , sebagaimana diuraikan pada Bab 3.

2.7 Low-Rank Adaptation (LoRA)

Low-Rank Adaptation (LoRA) adalah strategi *fine-tuning* efisien-parameter yang membekukan seluruh bobot model dasar W_0 dan hanya melatih sepasang matriks tambahan berperingkat rendah (*low-rank*) yang disisipkan secara paralel (Hu et al., 2022). Untuk suatu lapisan dengan bobot pra-latih $W_0 \in \mathbb{R}^{d \times k}$, LoRA merepresentasikan pembaruan bobot ΔW sebagai perkalian dua matriks berperingkat rendah $B \in \mathbb{R}^{d \times r}$ dan $A \in \mathbb{R}^{r \times k}$, dengan $r \ll \min(d, k)$, sehingga keluaran lapisan tersebut untuk masukan x dihitung sebagaimana Persamaan 2.3.

$$h = W_0x + \Delta Wx = W_0x + BAx \quad (2.3)$$

Gambar 2.6 menggambarkan arsitektur tersebut: masukan x diproses melalui dua jalur paralel, yaitu bobot dasar W_0 yang beku dan jalur berperingkat rendah A diikuti B , yang hasilnya dijumlahkan menjadi keluaran h .




Gambar 2.6 Arsitektur Low-Rank Adaptation (LoRA)

Karena jumlah parameter pada A dan B jauh lebih sedikit daripada jumlah parameter W_0 , LoRA menawarkan efisiensi komputasi dan memori yang signifikan dibandingkan *full fine-tuning*, yang memperbarui seluruh parameter W_0 secara langsung. Efisiensi ini relevan bagi penelitian dengan keterbatasan sumber daya komputasi, namun pengaruhnya terhadap akurasi klasifikasi emosi pada konteks SER berbahasa Indonesia belum banyak dikaji secara sistematis, sehingga menjadi salah satu perbandingan utama yang diuji dalam penelitian ini, sebagaimana diuraikan pada Bab 3.

2.8 Validasi Silang K-Fold dan Pengujian Signifikansi Statistik

Validasi silang k-fold adalah teknik evaluasi yang membagi data menjadi k bagian (*fold*) berukuran relatif sama, dengan setiap bagian secara bergantian digunakan sebagai data uji sementara $k - 1$ bagian lainnya digunakan sebagai data latih, sehingga setiap bagian data pernah menjadi data uji tepat satu kali (Kohavi, 1995). Gambar 2.7 menggambarkan skema tersebut untuk $k = 5$.



Gambar 2.7 Ilustrasi satu putaran validasi silang k-fold ($k = 5$); peran fold sebagai data uji bergantian pada setiap putaran hingga kelima fold pernah menjadi data uji

Teknik ini menghasilkan k observasi akurasi dan F1-score, satu untuk setiap fold, sehingga memungkinkan pengujian konsistensi performa antar-fold untuk setiap strategi yang diuji, bukan hanya satu nilai tunggal dari satu kali pengujian. Untuk menguji apakah perbedaan performa antarstrategi bersifat signifikan secara statistik, k observasi tersebut terlebih dahulu diuji normalitasnya menggunakan

uji Shapiro-Wilk (Shapiro and Wilk, 1965). Apabila data berdistribusi normal, pengujian dilanjutkan dengan *paired t-test*, yang menghitung statistik uji t dari selisih berpasangan d_i antara dua strategi pada fold yang sama, sebagaimana Persamaan 2.4.

$$t = \frac{\bar{d}}{s_d / \sqrt{n}} \quad (2.4)$$

di mana $\bar{d}$ adalah rata-rata selisih berpasangan, s_d adalah simpangan baku selisih tersebut, dan n adalah jumlah fold. Apabila data tidak berdistribusi normal, digunakan *Wilcoxon signed-rank test* sebagai alternatif non-parametrik yang tidak mengasumsikan distribusi tertentu (Wilcoxon, 1945).

2.9 Akurasi, Presisi, Recall, dan F1-Score

Akurasi, presisi, recall, dan F1-score adalah empat metrik yang umum digunakan untuk mengevaluasi performa model klasifikasi (Powers, 2011). Akurasi mengukur proporsi prediksi yang benar terhadap keseluruhan data uji, sehingga memberikan gambaran umum performa model, sebagaimana Persamaan 2.5.

$$\text{Akurasi} = \frac{TP + TN}{TP + TN + FP + FN} \quad (2.5)$$

di mana $TP = \text{True Positive}$, $TN = \text{True Negative}$, $FP = \text{False Positive}$, $FN = \text{False Negative}$.

Akan tetapi, pada data dengan sebaran kelas yang tidak seimbang, akurasi dapat memberikan gambaran yang menyesatkan, karena model yang selalu memprediksi kelas mayoritas tetap dapat memperoleh akurasi tinggi tanpa benar-benar mengenali kelas minoritas. Presisi mengukur proporsi prediksi positif yang benar-benar tepat, sebagaimana Persamaan 2.6.

$$\text{Presisi} = \frac{TP}{TP + FP} \quad (2.6)$$

Recall mengukur proporsi kasus positif yang berhasil dikenali model, sebagaimana Persamaan 2.7.

$$\text{Recall} = \frac{TP}{TP + FN} \quad (2.7)$$

Presisi dan recall sering kali saling bertukar (*trade-off*): menaikkan salah satu cenderung menurunkan yang lain. F1-score mengatasi keterbatasan ini dengan merepresentasikan rata-rata harmonis keduanya, sebagaimana Persamaan 2.8.


$$F_1 = 2 \cdot \frac{\text{Presisi} \times \text{Recall}}{\text{Presisi} + \text{Recall}} \quad (2.8)$$

Keempat metrik ini digunakan bersama dalam penelitian ini untuk memberikan gambaran performa yang lebih menyeluruh terhadap setiap strategi *fine-tuning* yang dibandingkan, mengingat skema kelas emosi yang digunakan berpotensi tidak seimbang antarkelas.

BAB 3 METODOLOGI PENELITIAN

3.1 Tipe Penelitian

Penelitian ini merupakan penelitian non-implementatif analitik dengan pendekatan kuantitatif, karena berfokus pada analisis pengaruh strategi *fine-tuning* terhadap akurasi klasifikasi emosi ucapan, bukan pada pengembangan sistem atau perangkat lunak siap pakai. Sifat analitik ditunjukkan melalui pengolahan data hasil observasi akurasi dan F1-score dari setiap strategi *fine-tuning* untuk mengkaji hubungan antara strategi yang diterapkan dan performa klasifikasi emosi yang dihasilkan. Pendekatan kuantitatif digunakan karena data berupa nilai numerik hasil evaluasi model yang dianalisis menggunakan metrik akurasi, F1-score, dan pengujian signifikansi statistik. Model-model yang di-*fine-tune* pada penelitian ini berfungsi sebagai instrumen untuk menghasilkan data observasi tersebut, bukan sebagai produk/artefak utama penelitian.



Gambar 3.1 Diagram alir metode penelitian

Diagram alir metode penelitian ini ditunjukkan pada Gambar 3.1. Tahap awal penelitian diawali dengan studi literatur, yang bertujuan untuk mengkaji teori, metode, serta penelitian terdahulu yang relevan dengan SER, pembelajaran *self-supervised*, dan *cross-lingual transfer*. Tahap berikutnya adalah pengumpulan data, yaitu proses pengumpulan korpus emosi berbahasa Inggris sebagai sumber dan dataset SER berbahasa Indonesia sebagai target. Data yang telah diperoleh selanjutnya diproses pada tahap *fine-tuning* sumber untuk melatih backbone *self-supervised* mengenali pola akustik emosi secara umum. Setelah itu dilakukan *fine-tuning* target untuk mengadaptasi model dasar ke data Indonesia melalui beberapa skema strategi. Tahap berikutnya adalah evaluasi k-fold untuk menilai performa setiap strategi menggunakan skema validasi silang dan pengujian signifikansi statistik. Hasil evaluasi tersebut kemudian digunakan sebagai dasar pada tahap analisis hasil, yang merangkum temuan penelitian serta menjawab rumusan masalah yang telah dipaparkan.

3.2 Studi Literatur

Studi literatur merupakan tahap awal penelitian yang bertujuan untuk mempelajari dan memahami teori, konsep, serta hasil penelitian terdahulu yang berkaitan dengan SER, pembelajaran *self-supervised*, representasi Wav2Vec2/XLSR, dan *cross-lingual transfer*. Pada tahap ini dilakukan pengkajian terhadap jurnal, prosiding konferensi, dan sumber ilmiah relevan untuk memastikan celah penelitian pada Bab 2 Landasan Kepustakaan belum terjawab oleh penelitian lain, sekaligus menentukan backbone model dan skema *fine-tuning* yang sesuai dengan tujuan penelitian.

3.3 Pengumpulan Data

Tahap ini mengumpulkan dua kelompok data, yaitu korpus emosi berbahasa Inggris sebagai sumber pada tahap *fine-tuning* pertama (RAVDESS/CREMA-D), dan dataset E-SERAVD (Santoso, Budianto and Dutono, 2026) sebagai target berbahasa Indonesia pada tahap *fine-tuning* kedua. Skema kelas emosi pada korpus sumber disesuaikan dengan skema empat kelas yang tersedia pada E-SERAVD (marah, senang, netral, sedih), sehingga perbandingan antarstrategi *fine-tuning* dapat dilakukan secara adil.

Karakteristik masing-masing korpus dijelaskan sebagai berikut. RAVDESS adalah korpus ucapan emosional berbahasa Inggris yang direkam oleh 24 aktor profesional (12 perempuan, 12 laki-laki), mencakup 8 kategori emosi (netral, tenang, senang, sedih, marah, takut, jijik, dan terkejut) (Livingstone and Russo, 2018). CREMA-D adalah korpus ucapan emosional berbahasa Inggris yang direkam oleh 91 aktor dengan latar belakang usia dan etnis yang beragam, mencakup 6 kategori emosi (marah, jijik, takut, senang, netral, dan sedih) (Cao et al., 2014). Kedua korpus ini dipilih sebagai sumber karena tersedia secara publik, telah banyak digunakan pada penelitian SER sebelumnya, dan mencakup kategori emosi yang secara umum beririsan dengan skema kelas pada dataset target. Tabel 3.1 merangkum karakteristik ketiga dataset yang digunakan.

Tabel 3.1 Karakteristik dataset yang digunakan

Dataset	Peran	Bahasa	Jumlah pel	Sam- pel	Jumlah Kelas
RAVDESS	Sumber	Inggris	1.440		8
CREMA-D	Sumber	Inggris	7.442		6
E-SERAVD	Target	Indonesia	~5.049		4

Jumlah sampel untuk RAVDESS dan CREMA-D di atas mengacu pada dokumentasi resmi masing-masing korpus. E-SERAVD memiliki sekitar 5.049 sampel dengan distribusi 1.202 marah, 1.228 senang, 2.075 netral, dan 899 sedih (Santoso, Budianto and Dutono, 2026); angka ini masih perlu diverifikasi ulang terhadap dokumentasi resmi dataset sebelum benar-benar diperoleh. Dataset SER Indonesia lain seperti IndoWaveSentiment (Nugroho et al., 2025) tidak digunakan sebagai target pada penelitian ini karena skala dan skema kelasnya berbeda dari E-SERAVD, namun disebutkan kembali sebagai arah pengembangan pada Bab 6.

3.4 Fine-Tuning Sumber

Backbone yang digunakan adalah model dasar XLSR-53 (facebook/wav2vec2-large-xlsr-53) tanpa *fine-tuning* tambahan dari pihak lain untuk Bahasa Indonesia – berbeda dari pendekatan Nugroho et al. (2025) yang menguji model dasar XLSR-Wav2Vec2 yang sudah di-*fine-tune* untuk ucapan Indonesia (lihat Subbab 2.4). Pemilihan ini disengaja: dengan titik awal yang identik di keempat kondisi eksperimen (Subbab 3.5), perbedaan performa yang teramati dapat ditarik ke strategi *fine-tuning* yang diuji dalam penelitian ini, bukan tercampur dengan efek *fine-tuning* pihak lain yang sudah menempel pada checkpoint.

Tahap ini melatih backbone *self-supervised* (Wav2Vec2/XLSR-53) pada korpus emosi berbahasa Inggris agar model mampu mengenali pola akustik emosi secara umum, menghasilkan model dasar yang selanjutnya akan diadaptasi ke data target pada tahap berikutnya. Tahap ini dijalankan sekali saja; bobot hasilnya dipakai ulang sebagai titik awal untuk semua fold pada Kondisi C dan D (Subbab 3.5), bukan diulang per-fold, karena *fine-tuning* tahap sumber tidak bergantung pada pembagian fold data target.

3.5 Fine-Tuning Target

Tahap ini mengadaptasi model ke data Indonesia melalui dua axis desain yang independen: (1) *stage*, yaitu apakah model melalui *fine-tuning* dua tahap atau langsung dilatih pada data target (*single-stage*); dan (2) metode adaptasi, yaitu *full fine-tuning* yang memperbarui seluruh parameter model, atau LoRA yang hanya memperbarui parameter tambahan berjumlah kecil. Kombinasi kedua axis tersebut menghasilkan empat kondisi eksperimen sebagaimana dirangkum pada Tabel 3.2.

Tabel 3.2 Empat kondisi eksperimen (desain 2×2)

Kondisi	Stage	Metode Adaptasi
A	Single-stage	Full Fine-Tuning
B	Single-stage	LoRA
C	Two-stage	Full Fine-Tuning
D	Two-stage	LoRA

Backbone yang digunakan sama persis (XLSR-53, Subbab 3.4) di keempat kondisi – yang berbeda hanya resep *fine-tuning*-nya – supaya perbedaan hasil antarkondisi dapat ditarik ke strategi *fine-tuning* yang diuji, bukan ke perbedaan arsitektur atau titik awal model. Kondisi A dan B tidak melalui tahap *fine-tuning* sumber (Subbab 3.4) dan langsung dilatih pada data target, sedangkan Kondisi C dan D memakai bobot hasil *fine-tuning* sumber sebagai titik awal. Validasi silang k-fold (Subbab 3.6) diterapkan pada level adaptasi target ini untuk keempat kondisi. Sebagai mitigasi risiko, direkomendasikan menjalankan *pilot run* ($1 \text{ kondisi} \times 1 \text{ fold}$) pada perangkat keras sebenarnya sebelum menjalankan grid eksperimen penuh, untuk memverifikasi estimasi waktu dan VRAM pada Subbab 3.9.2 dengan data riil.

3.6 Evaluasi K-Fold

Tahap ini mengevaluasi setiap kondisi eksperimen menggunakan skema validasi silang k-fold, sehingga diperoleh beberapa observasi akurasi dan F1-score per fold untuk masing-masing kondisi. Data hasil observasi tersebut kemudian diuji normalitasnya menggunakan uji Shapiro-Wilk. Jika data berdistribusi normal, pengujian dilanjutkan dengan *paired t-test*; jika tidak, digunakan *Wilcoxon signed-rank test*. Pengujian ini bertujuan untuk mengetahui signifikansi statistik perbedaan performa antarkondisi eksperimen.

3.7 Analisis Hasil

Tahap ini menafsirkan hasil pengujian signifikansi statistik untuk menjawab rumusan masalah penelitian, serta menyusun rekomendasi strategi *fine-tuning* yang paling sesuai untuk pengembangan SER berbahasa Indonesia berdasarkan temuan yang diperoleh.

3.8 Kesimpulan dan Saran

Penarikan kesimpulan dilaksanakan setelah seluruh tahap evaluasi dan analisis hasil selesai. Kesimpulan memuat jawaban atas rumusan masalah yang telah dituliskan sebelumnya, mengacu pada hasil pengujian signifikansi statistik dari setiap strategi *fine-tuning* yang dibandingkan. Selain kesimpulan, disusun pula saran sebagai bahan pertimbangan dan perbaikan untuk penelitian selanjutnya, misalnya perluasan cakupan korpus sumber atau backbone model yang diuji.

3.9 Peralatan Pendukung

Peralatan pendukung yang digunakan dalam penelitian ini terdiri atas perangkat lunak (*software*) dan perangkat keras (*hardware*).

3.9.1 Perangkat Lunak (Software)

Perangkat lunak yang digunakan dalam mendukung penelitian ini sebagai berikut.

1. Bahasa pemrograman Python.
2. Kerangka kerja *deep learning* untuk pelatihan dan *fine-tuning* model Wav2Vec2/XLSR.
3. Pustaka untuk implementasi LoRA.
4. Pustaka optimizer 8-bit (*bitsandbytes*) untuk mitigasi VRAM pada kondisi *full fine-tuning*.
5. Pustaka statistik untuk pengujian normalitas dan uji signifikansi.
6. GitHub untuk pengelolaan versi kode sumber dan eksperimen.

3.9.2 Perangkat Keras (Hardware)

Perangkat keras yang digunakan dalam mendukung penelitian ini sebagai berikut.

1. 2 unit GPU NVIDIA GeForce RTX 3060 6GB (server lab, dipinjamkan).
2. RAM dan penyimpanan: [*diisi sesuai spesifikasi server lab yang sebenarnya dipakai*].

Kecukupan VRAM *per kartu* dianalisis terhadap ukuran backbone (sekitar 317 juta parameter), sebagaimana dirangkum pada Tabel 3.3.

Tabel 3.3 Estimasi kecukupan VRAM per kartu (6GB)

Komponen	Full-FT (naif)	Full-FT + 8-bit Adam	LoRA
Bobot + master + gradien + optimizer	~5 GB	~1,9 GB	~0,6–0,7 GB
Sisa untuk aktivasi (dari 6 GB)	~1 GB	~4 GB	~5,3 GB

Estimasi “naif” (optimizer Adam presisi-penuh standar) menyisakan hanya sekitar 1 GB untuk aktivasi – terlalu mepet untuk aman, karena *overhead* CUDA dan fragmen-tasi memori berisiko menghabiskan sisa tersebut sebelum sempat dipakai aktivasi. Mitigasi yang digunakan untuk Kondisi A dan C (*full fine-tuning*) adalah optimizer Adam 8-bit (*bitsandbytes*), yang memangkas kebutuhan memori optimizer menjadi sekitar 1,9 GB dan menyisakan sekitar 4 GB untuk aktivasi – jauh lebih aman.

Dengan mitigasi ini, *full fine-tuning* diperkirakan tetap memerlukan *batch size* kecil (sekitar 1–2), dengan *gradient checkpointing* dan *gradient accumulation* sebagai cadangan opsional jika 4 GB masih belum cukup pada praktiknya. Skema LoRA (Kondisi B dan D) memiliki ruang gerak yang jauh lebih longgar, dengan *batch size* 8–16 yang tetap realistis tanpa teknik tambahan. Keterbatasan ini sekaligus menjadi ilustrasi konkret argumen efisiensi LoRA yang diuji dalam penelitian ini (Subbab 2.7): pada perangkat keras yang benar-benar terbatas, LoRA bukan hanya lebih hemat secara teoretis, tetapi menjadi opsi yang jauh lebih praktis dijalankan.

Strategi 2 GPU yang digunakan bukan *distributed training* (model sudah muat pada 1 kartu), melainkan 2 *run* independen paralel, satu per GPU (diatur lewat `CUDA_VISIBLE_DEVICES`), karena grid eksperimen ($4 \text{ kondisi} \times k \text{ fold}$) bersifat *embarrassingly parallel*.

Rekomendasi teknis lain: *mixed precision* (fp16/bf16) untuk mengurangi jejak memori, serta membekukan *CNN feature extractor* (praktik standar pada *fine-tuning* wav2vec2). Dengan skala dataset target diperkirakan sekitar 5 ribu sampel (Subbab 3.3), estimasi kasar waktu per-*run* berkisar puluhan menit hingga beberapa jam – kemungkinan lebih lama untuk kondisi *full fine-tuning* karena *batch size* yang lebih kecil – sehingga total waktu penelitian ($k = 5$, sekitar 21 *run*) diperkirakan selesai dalam hitungan hari dengan pemanfaatan 2 GPU secara paralel. Estimasi ini bersifat kasar dan perlu diverifikasi pada uji coba awal.

DAFTAR REFERENSI

- Arisaputra, P. and Zahra, A., 2023. Indonesian automatic speech recognition with XLSR-53. *arXiv:2308.11589 [cs.CL]*.
- Baevski, A., Zhou, H., Mohamed, A. and Auli, M., 2020. wav2vec 2.0: a framework for self-supervised learning of speech representations. *Advances in Neural Information Processing Systems (NeurIPS)*, 33, pp.12449-12460.
- Bella, G., Helm, P., Koch, G. and Giunchiglia, F., 2023. Towards bridging the digital language divide. *arXiv:2307.13405 [cs.CL]*.
- Cao, H., Cooper, D.G., Keutmann, M.K., Gur, R.C., Nenkova, A. and Verma, R., 2014. CREMA-D: crowd-sourced emotional multimodal actors dataset. *IEEE Transactions on Affective Computing*, 5(4), pp.377-390.
- Conneau, A., Baevski, A., Collobert, R., Mohamed, A. and Auli, M., 2021. Unsupervised cross-lingual representation learning for speech recognition. In: *Proceedings of Interspeech 2021*, pp.2426-2430.
- Dar, G.H.M. and Delhibabu, R., 2024. Speech databases, speech features, and classifiers in speech emotion recognition: a review. *IEEE Access*, 12, pp.151122-151152. <https://doi.org/10.1109/ACCESS.2024.3476960>
- Eljinini, M.A.H. and Al-Momani, W.E., 2025. Advancements in speech recognition: a systematic review of deep learning transformer models, trends, innovations, and future directions. *IEEE Access*. <https://doi.org/10.1109/ACCESS.2025.3550855>
- Hu, E.J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., Wang, L. and Chen, W., 2022. LoRA: low-rank adaptation of large language models. In: *International Conference on Learning Representations (ICLR)*.
- Kohavi, R., 1995. A study of cross-validation and bootstrap for accuracy estimation and model selection. In: *Proceedings of the 14th International Joint Conference on Artificial Intelligence (IJCAI)*, 2, pp.1137-1143.
- Liu, X., Zhang, F., Hou, Z., Mian, L., Wang, Z., Zhang, J. and Tang, J., 2023. Self-supervised learning: generative or contrastive. *IEEE Transactions on Knowledge and Data Engineering*, 35(1), pp.857-876.
- Livingstone, S.R. and Russo, F.A., 2018. The Ryerson Audio-Visual Database of Emotional Speech and Song (RAVDESS): a dynamic, multimodal set of facial and vocal expressions in North American English. *PLOS ONE*, 13(5), e0196391.
- Nugroho, K.S., Iriananda, S.W., Akbar, I., Isnain, M. and Pardamean, B., 2025. Advancing end-to-end Indonesian speech emotion recognition using XLSR-Wav2Vec2. In: *2025 International Conference on Information Technology Research and Innovation (ICITRI)*. IEEE. <https://doi.org/10.1109/ICITRI67507.2025.11232655>

- Ou, L. et al., 2024. Parameter-efficient fine-tuning large speech model based on LoRA. IEEE. *[Rujukan belum lengkap – nama depan penulis, detail prosiding/jurnal, volume, dan halaman perlu diverifikasi dan dilengkapi sebelum submit; urutan nama depan/belakang penulis pertama juga belum dipastikan.]*
- Pan, S.J. and Yang, Q., 2010. A survey on transfer learning. *IEEE Transactions on Knowledge and Data Engineering*, 22(10), pp.1345-1359.
- Powers, D.M.W., 2011. Evaluation: from precision, recall and F-measure to ROC, informedness, markedness and correlation. *Journal of Machine Learning Technologies*, 2(1), pp.37-63.
- Santoso, T.B., Budianto, A.N. and Dutono, T., 2026. Development of a speech emotion recognition dataset for Indonesian. *IEEE Access*. <https://doi.org/10.1109/ACCESS.2026.3652377>
- Shapiro, S.S. and Wilk, M.B., 1965. An analysis of variance test for normality (complete samples). *Biometrika*, 52(3-4), pp.591-611.
- Tang, D., Kuppens, P., Geurts, L. and van Waterschoot, T., 2023. End-to-end transfer learning for speaker-independent cross-language and cross-corpus speech emotion recognition. *arXiv:2311.13678 [eess.AS]*.
- Wilcoxon, F., 1945. Individual comparisons by ranking methods. *Biometrics Bulletin*, 1(6), pp.80-83.
- Wu, P., Shi, J., Zhong, Y., Watanabe, S. and Black, A.W., 2021. Cross-lingual transfer for speech processing using acoustic language similarity. *arXiv:2111.01326 [eess.AS]*.

LAMPIRAN