

**Pengaruh Skema Pembagian Data Berbasis Film pada
Dataset E-SERAVD terhadap Performa Klasifikasi
Pengenalan Emosi Ucapan Berbahasa Indonesia**

PROPOSAL SKRIPSI

Disusun oleh:

Gaung Taqwa Indraswara

NIM: 235150207111043



PROGRAM STUDI TEKNIK INFORMATIKA
DEPARTEMEN TEKNIK INFORMATIKA
FAKULTAS ILMU KOMPUTER
UNIVERSITAS BRAWIJAYA
MALANG
2026

DAFTAR ISI

DAFTAR ISI	i
DAFTAR GAMBAR	ii
DAFTAR TABEL	iii
BAB 1 PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	2
1.3 Tujuan	2
1.4 Manfaat	3
1.5 Batasan Masalah	3
1.6 Sistematika Pembahasan	4
BAB 2 LANDASAN KEPUSTAKAAN	5
2.1 Kajian Pustaka	5
2.2 Speech Emotion Recognition (SER)	7
2.3 Data Leakage / Group Leakage	8
2.4 Fitur Hand-Crafted	8
2.5 Mel-Frequency Cepstral Coefficients (MFCC)	9
2.6 Convolutional Neural Network (CNN)	10
2.7 Pembelajaran Self-Supervised	11
2.8 Wav2Vec2	12
2.9 XLSR-53	13
2.10 Low-Rank Adaptation (LoRA)	13
2.11 Evaluasi Model	15
2.12 Validasi Silang K-Fold	16
2.13 Pengujian Signifikansi Statistik	16
BAB 3 METODOLOGI PENELITIAN	18
3.1 Tipe Penelitian	18
3.2 Studi Literatur	19
3.3 Pengumpulan Data	19
3.4 Perancangan Algoritma	21

3.5	Evaluasi K-Fold.....	21
3.6	Analisis Hasil	22
3.7	Kesimpulan dan Saran	22
DAFTAR REFERENSI		23

DAFTAR GAMBAR

2.1	Cakupan basis data, fitur, dan <i>classifier</i> pada SER	7
2.2	Pipeline ekstraksi Mel-Frequency Cepstral Coefficients (MFCC)	10
2.3	Arsitektur umum Convolutional Neural Network (CNN)	11
2.4	Alur umum pembelajaran Self-Supervised	12
2.5	Arsitektur Wav2Vec2	13
2.6	Perbandingan full fine-tuning dan LoRA	14
2.7	Ilustrasi mekanisme validasi silang k-fold	16
3.1	Diagram alir metode penelitian	18

DAFTAR TABEL

2.1	Daftar penelitian terdahulu	5
3.1	Karakteristik dataset E-SERA VD v1.1	19
3.2	Distribusi jumlah klip per film dan kelas emosi	20
3.3	Empat kondisi eksperimen (desain 2×2)	21

BAB 1 PENDAHULUAN

1.1 Latar Belakang

Emosi merupakan komponen mendasar dalam komunikasi antarmanusia, karena emosi memungkinkan seseorang menyampaikan maksud dan keadaan batin secara lebih utuh daripada makna literal kata-kata. Dalam interaksi manusia dan mesin, pengenalan emosi dari sinyal ucapan memegang peranan penting bagi pengembangan komputasi afektif dan sistem interaktif yang mampu merespons pengguna secara lebih personal (Dar and Delhibabu, 2024). Karakteristik inilah yang mendasari berkembangnya *speech emotion recognition* (SER), yaitu bidang kajian yang berupaya mengenali kondisi emosi seseorang secara otomatis dari sinyal ucapannya, dengan cakupan penerapan yang terus meluas. Meskipun signifikansinya diakui luas, perkembangan teknologi bahasa berbasis ucapan masih timpang antarbahasa, karena sebagian besar teknologi kecerdasan buatan terpusat pada sebagian kecil bahasa dengan sumber daya digital terbesar (Bella et al., 2023). Bahasa Indonesia, meskipun dituturkan ratusan juta jiwa, termasuk kelompok bahasa yang sumber dayanya masih tertinggal, sehingga data ucapan beranotasi emosi dalam jumlah memadai masih sulit diperoleh. Kesenjangan inilah yang menjadikan pengembangan SER berbahasa Indonesia sebagai permasalahan penelitian yang penting sekaligus menantang.

Menjawab kesenjangan tersebut, Santoso, Budianto and Dutono (2026) mengembangkan E-SERAVID, dataset SER berbahasa Indonesia yang bersumber dari dialog rekaman film Indonesia, sekaligus menetapkan *baseline* performa 86% akurasi dan 86% F1-macro menggunakan model CNN konvensional dengan fitur *hand-crafted* MFCC. *Baseline* tersebut, meskipun berguna, dilaporkan tanpa menyebutkan kontrol terhadap sumber film pada pembagian data latih dan uji. Padahal, E-SERAVID terbukti memiliki sebaran film yang tidak merata antarkelas emosi. Terdapat 106 dari 300 klip kelas sedih berasal dari satu film yang sama, dan 147 dari 300 klip kelas bahagia berasal dari dua film yang sama. Apabila pembagian data latih dan uji dilakukan secara acak tanpa mengontrol sumber film, klip dari film yang sama berisiko muncul pada kedua sisi sekaligus, sehingga model berpotensi mempelajari ciri produksi atau karakteristik rekaman film tertentu sebagai proxy kelas emosi, bukan pola akustik emosi secara umum.

Risiko tersebut dikenal sebagai kebocoran data (*data leakage*) (Kapoor and Narayanan, 2023), dan berpotensi membuat performa yang dilaporkan terlihat lebih baik daripada performa sesungguhnya pada data yang benar-benar baru. Pada domain SER secara spesifik, kegagalan mengontrol tumpang tindih identitas penutur antara data latih dan uji telah terbukti menghasilkan estimasi performa yang lebih optimistis dibandingkan skema evaluasi yang independen (Antoniou et al., 2023). Pada domain SER secara umum, kegagalan mengontrol kebocoran semacam ini dilaporkan memengaruhi sebagian besar penelitian yang diterbitkan. Lebih dari 80% studi SER tidak dapat direproduksi secara memadai, dan skema partisi data yang tidak terkontrol dilaporkan menghasilkan peningkatan performa semu hingga sekitar 4% (Wu et al., 2024).

Di sisi lain, representasi *self-supervised* kini banyak dianggap sebagai pendekatan performa terbaik (*state-of-the-art*) untuk SER, termasuk untuk bahasa Indonesia. Atmaja and Sasou (2022) menunjukkan bahwa representasi *self-supervised* secara konsisten mengungguli fitur *hand-crafted* pada lima dataset SER berbahasa Inggris dan Jepang, dengan signifikansi statistik yang kuat, meskipun XLSR-53 secara spesifik sempat berperforma lebih rendah dibandingkan model monolingual berbahasa Inggris pada studi yang sama. Pada konteks SER berbahasa Indonesia secara spesifik, Nugroho et al. (2025) menunjukkan bahwa model dasar XLSR-Wav2Vec2 yang telah di-*fine-tune* untuk ucapan Indonesia dapat mencapai akurasi SER hingga 91,67%, mengungguli metode klasik berbasis fitur *hand-crafted*. Bukti-bukti ini menempatkan XLSR-53 sebagai backbone *self-supervised* yang paling relevan untuk diadaptasi pada tugas SER berbahasa Indonesia saat ini. Akan tetapi, belum ada studi yang menguji ketahanan algoritma *baseline* (CNN+MFCC) maupun algoritma SOTA (XLSR-53 yang diadaptasi dengan LoRA) terhadap risiko kebocoran data berbasis film yang terbukti ada pada E-SERAVID.

Berdasarkan uraian diatas, diperlukan kajian analitik mengenai pengaruh skema pembagian data berbasis film terhadap akurasi pengenalan emosi ucapan berbahasa Indonesia, serta apakah pengaruh tersebut konsisten pada algoritma berbasis fitur *hand-crafted* maupun algoritma berbasis representasi *self-supervised*, yang akan dianalisis dalam skripsi ini.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah dipaparkan, maka permasalahan dalam penelitian ini dapat dirumuskan sebagai berikut.

1. Bagaimana pengaruh skema pembagian data berbasis film (*random* dibandingkan *movie-independent*) pada dataset E-SERAVID terhadap performa klasifikasi pengenalan emosi ucapan berbahasa Indonesia?
2. Apakah pengaruh tersebut konsisten pada algoritma berbasis fitur *hand-crafted* (MFCC+CNN) maupun algoritma berbasis representasi *self-supervised* (XLSR-53)?

1.3 Tujuan

Tujuan dari penelitian ini menjawab rumusan masalah yang telah dipaparkan, maka penelitian ini memiliki tujuan sebagai berikut.

1. Mengetahui pengaruh skema pembagian data berbasis film (*random* dibandingkan *movie-independent*) terhadap performa klasifikasi pengenalan emosi ucapan berbahasa Indonesia.
2. Menganalisis konsistensi pengaruh skema pembagian data berbasis film (*random split* dibandingkan *movie-independent split*) terhadap akurasi

pengenalan emosi ucapan berbahasa Indonesia pada algoritma berbasis fitur *hand-crafted* (MFCC+CNN) dan algoritma berbasis representasi *self-supervised* (XLSR-53).

1.4 Manfaat

Penelitian ini diharapkan dapat memberikan manfaat sebagai berikut.

1. Memberikan bukti empiris mengenai validitas *baseline* performa yang telah dilaporkan pada dataset E-SERAVD terhadap risiko kebocoran data, sehingga dapat menjadi rekomendasi metodologis bagi peneliti lain yang menggunakan dataset ini pada penelitian selanjutnya.
2. Memberikan bukti empiris mengenai ketahanan algoritma berbasis representasi *self-supervised* dibandingkan algoritma berbasis fitur *hand-crafted* terhadap skema pembagian data yang lebih ketat, sehingga dapat membantu peneliti maupun praktisi dalam memilih algoritma yang lebih andal untuk SER berbahasa Indonesia.
3. Berkontribusi pada pengembangan riset komputasi cerdas berbahasa Indonesia, khususnya pada bidang pemrosesan sinyal ucapan yang masih relatif terbatas jumlah kajiannya.

1.5 Batasan Masalah

Batasan masalah yang membatasi penulis dalam melakukan penelitian ini adalah sebagai berikut.

1. Dataset dibatasi pada E-SERAVD v1.1, mencakup 1.200 klip ucapan emosional berbahasa Indonesia dari 6 film sumber, dengan 4 kelas emosi (marah, sedih, netral, bahagia).
2. Algoritma *baseline* dibatasi pada CNN dengan fitur *hand-crafted* MFCC, mengikuti pendekatan Santoso, Budianto and Dutono (2026).
3. Algoritma pembandingan dibatasi pada backbone XLSR-53 yang diadaptasi menggunakan LoRA (*Low-Rank Adaptation*), bukan *full fine-tuning* pada seluruh parameter backbone.
4. Skema pembagian data dibatasi pada dua skema: *random* dan *movie-independent*, keduanya menggunakan $k = 6$ fold.
5. Evaluasi performa dibatasi pada metrik kualitas klasifikasi yaitu akurasi, presisi, recall, dan F1-score.
6. Signifikansi statistik diuji menggunakan uji Shapiro-Wilk untuk normalitas, dilanjutkan uji *paired t-test* atau *Wilcoxon signed-rank test* sesuai hasil uji normalitas tersebut.

1.6 Sistematika Pembahasan

Bab 1 Pendahuluan

Membahas mengenai latar belakang penelitian ini diangkat, rumusan masalah, tujuan dan manfaat penelitian, batasan masalah, serta sistematika pembahasan penulisan penelitian yang berjudul Pengaruh Skema Pembagian Data Berbasis Film pada Dataset E-SERAVID terhadap Performa Klasifikasi Pengenalan Emosi Ucapan Berbahasa Indonesia.

Bab 2 Landasan Kepustakaan

Membahas tentang kajian pustaka dan dasar teori. Kajian pustaka berisi referensi mengenai penelitian-penelitian sebelumnya yang terkait dengan SER dan kebocoran data pada skema evaluasi. Dasar teori membahas konsep-konsep yang mendasari metode yang digunakan.

Bab 3 Metodologi Penelitian

Membahas tipe penelitian serta tahapan penelitian yang dilaksanakan mulai dari studi literatur, pengumpulan data, perancangan algoritma, evaluasi k-fold, hingga analisis hasil dan penarikan kesimpulan.

Bab 4 Perancangan

Membahas perancangan sistem serta algoritme yang digunakan dalam eksperimen penelitian ini, meliputi rancangan sistem klasifikasi untuk algoritma *baseline* dan algoritma pembandingan, rancangan keempat kondisi eksperimen, serta rancangan skema validasi silang k-fold.

Bab 5 Implementasi

Membahas implementasi kode-kode esensial dari perancangan yang telah diuraikan pada Bab sebelumnya, meliputi implementasi ekstraksi fitur, pelatihan model, dan pengujian signifikansi statistik.

Bab 6 Hasil dan Pembahasan

Menyajikan hasil pelaksanaan keempat kondisi eksperimen, meliputi observasi akurasi, presisi, recall, dan F1-score per fold, beserta hasil pengujian normalitas dan signifikansi statistiknya, serta pembahasan yang menerjemahkan makna hasil tersebut untuk menjawab rumusan masalah penelitian.

Bab 7 Penutup

Memuat kesimpulan yang menjawab rumusan masalah berdasarkan hasil dan pembahasan penelitian, serta saran untuk pengembangan penelitian selanjutnya.

BAB 2 LANDASAN KEPUSTAKAAN

2.1 Kajian Pustaka

Kajian pustaka berisi kajian-kajian penelitian terdahulu yang bertujuan untuk mendukung proses penelitian. Kajian pustaka dilakukan untuk mendapatkan informasi yang relevan dengan topik penelitian ini. Tabel 2.1 memaparkan penelitian-penelitian yang terkait dengan subjek yang diteliti.


Tabel 2.1 Daftar penelitian terdahulu

Judul Penelitian	Masalah	Metode	Hasil
Development of a Speech Emotion Recognition Dataset for Indonesian (Santoso, Budianto and Dutono, 2026)	Dataset publik SER berbahasa Indonesia untuk penelitian masih sangat terbatas, dataset yang tersedia tidak mengakomodasi intonasi lokal, berskala kecil, terfragmentasi dan di rekam secara tidak natural.	Pembuatan dataset E-SERAVD melalui ekstraksi dan pembersihan audio dialog dari film komersial Indonesia, yang kemudian divalidasi ke dalam empat kelas emosi dasar oleh tiga penilai manusia. Dataset tersebut selanjutnya diproses menggunakan ekstraksi fitur MFCC dan dievaluasi kinerjanya menggunakan model CNN, tanpa melibatkan kontrol eksplisit terhadap sumber film pada pembagian data latih dan uji.	Dataset memiliki kualitas anotasi yang kuat. Model CNN dasar mencapai akurasi dan F1-score sebesar 86% pada subset seimbang (1.000 sampel, 250/kelas), dengan emosi yg paling benar diprediksi adalah "Sedih"
End-to-End Transfer Learning for Speaker-Independent Cross-Language and Cross-Corpus Speech Emotion Recognition (Tang et al., 2023)	Evaluasi model SER yang tidak mengontrol kebocoran identitas penutur antara data latih dan uji berisiko melebihi performa generalisasi model.	Skema evaluasi <i>speaker-independent</i> yang memas-tikan penutur pada data uji tidak pernah muncul pada data latih. Skema ini diterapkan pada <i>transfer learning end-to-end</i> lintas bahasa dan lintas korpus, dibandingkan dengan skema evaluasi konvensional yang tidak mengontrol identitas penutur.	Skema evaluasi <i>speaker-independent</i> menghasilkan estimasi performa yang lebih andal dibandingkan skema yang tidak mengontrol identitas penutur.

Judul Penelitian	Masalah	Metode	Hasil
Designing and Evaluating Speech Emotion Recognition Systems: A Reality Check Case Study with IEMOCAP (Antoniou et al., 2023)	Belum ada konsensus protokol evaluasi SER pada IEMOCAP, khususnya terkait kontrol identitas penutur antara data latih dan uji, sehingga performa antar-penelitian sulit dibandingkan secara adil.	Tinjauan kritis dan kompilasi hasil dari sejumlah publikasi SER pada IEMOCAP, membandingkan performa yang dilaporkan di bawah skema <i>Speaker-Dependent</i> (SD, pembagian data acak) dengan skema <i>Speaker-Independent</i> (SI, <i>leave-one-speaker/session-out</i>).	Skema SD secara konsisten dilaporkan menghasilkan performa lebih tinggi dibandingkan skema SI pada metode yang sebanding; satu model HuBERT pada penelitian yang sama melaporkan 79,58% (SD) berbanding 73,01% (SI) pada metrik <i>weighted accuracy</i> .
Evaluating Self-Supervised Speech Representations for Speech Emotion Recognition (Atmaja and Sasou, 2022)	Belum diketahui apakah keunggulan representasi <i>self-supervised</i> atas fitur <i>hand-crafted</i> pada SER berlaku universal lintas model dan bahasa.	Evaluasi sistematis 19 representasi <i>self-supervised</i> dan 1 fitur <i>hand-crafted</i> (filterbank) pada 5 dataset SER berbahasa Inggris dan Jepang. Setiap representasi diuji dengan <i>classifier feed-forward</i> yang identik, kemudian signifikansi antarrepresentasi diuji memakai uji Friedman dan dihitung <i>effect size</i> -nya.	Representasi <i>self-supervised</i> unggul signifikan (filterbank rank terakhir dari 20), namun XLSR-53 spesifik kalah dari model monolingual Inggris; tidak ada dataset Indonesia diuji.
Advancing End-to-End Indonesian Speech Emotion Recognition Using XLSR-Wav2Vec2 (Nugroho et al., 2025)	Performa SER berbahasa Indonesia belum diketahui secara komparatif antara metode klasik dan representasi <i>self-supervised</i> multibahasa.	Perbandingan SVM, CNN, dan dua model dasar XLSR-Wav2Vec2 yang telah di- <i>fine-tune</i> untuk ucapan Indonesia menggunakan data Mozilla Common Voice serta OpenSLR berbahasa Jawa dan Sunda. Keempat model diuji pada dataset IndoWaveSentiment untuk membandingkan performa metode klasik dan representasi <i>self-supervised</i> multibahasa.	Model dasar XLSR-Wav2Vec2 yang telah disesuaikan untuk ucapan Indonesia mencapai akurasi tertinggi sebesar 91,67%, mengungguli metode klasik.

2.2 Speech Emotion Recognition (SER)

Speech emotion recognition (SER) adalah bidang kajian yang berupaya mengenali kondisi emosi seseorang secara otomatis dari sinyal ucapannya, dengan memanfaatkan ciri-ciri akustik seperti intonasi, nada dasar (*pitch*), energi, dan ritme bicara yang secara empiris berkorelasi dengan keadaan emosional penutur (Dar and Delhibabu, 2024). Gambar 2.1 merangkum cakupan bidang SER dari tiga sisi utama, yaitu sumber data, jenis fitur, dan jenis *classifier* yang digunakan. Dari sisi sumber data, rekaman ucapan emosional dapat diperoleh secara *acted* (diperankan aktor mengikuti skenario emosi tertentu), *elicited* (dipancing muncul secara spontan melalui stimulus atau situasi tertentu), maupun *natural* (diambil langsung dari situasi nyata tanpa rekayasa, misalnya dari dialog film seperti yang digunakan pada penelitian ini). Dari sisi fitur, representasi yang diekstraksi dari sinyal ucapan terbagi menjadi fitur akustik (*acoustic*, mis. *prosodic*, spektral, dan kualitas suara) dan fitur non-akustik (*non-acoustic*, mis. linguistik, wacana, serta ekspresi wajah dan gestur pada modalitas multimodal). Dari sisi *classifier*, metode yang digunakan terbagi menjadi metode pembelajaran mesin konvensional (*machine learning based*, mis. SVM, HMM, KNN) dan metode pembelajaran mendalam (*deep learning based*, mis. CNN, RNN, LSTM). Penelitian ini berada pada irisan data *natural* berbasis film, fitur akustik, dan *classifier* berbasis pembelajaran mendalam.



Gambar 2.1 Cakupan basis data, fitur, dan *classifier* pada SER

Sumber : Dar and Delhibabu (2024)

Cakupan penerapan SER terus meluas, mulai dari asisten virtual yang responsif terhadap keadaan pengguna, layanan pelanggan otomatis yang dapat mendeteksi frustrasi penelepon, hingga sistem pemantauan kesehatan mental yang menandai perubahan pola emosi dari waktu ke waktu. Perkembangan representasi *self-supervised* seperti Wav2Vec2 dan XLSR-53 menjadi salah satu pendorong utama peningkatan akurasi SER dibandingkan pendekatan fitur *hand-crafted* konvensional.

2.3 Data Leakage / Group Leakage

Kebocoran data (*data leakage*) (Kapoor and Narayanan, 2023) adalah kondisi ketika informasi dari data uji secara tidak sengaja ikut memengaruhi proses pelatihan model, sehingga performa yang terukur pada data uji tidak lagi mencerminkan kemampuan generalisasi model yang sesungguhnya pada data baru. Salah satu bentuk kebocoran data yang sering luput diperhatikan adalah *group leakage*, yaitu kebocoran yang terjadi ketika beberapa sampel data memiliki keterkaitan atau berasal dari satu sumber/kelompok yang sama (dikategorikan sebagai *nonindependence* antara sampel latih dan uji oleh Kapoor and Narayanan, 2023) – misalnya beberapa klip ucapan yang berasal dari rekaman film yang sama – namun sampel-sampel berkelompok tersebut tersebar ke sisi latih dan uji sekaligus akibat pembagian data yang dilakukan secara acak murni terhadap satuan sampel individual (skema *random*). Ketika hal ini terjadi, model berpotensi mempelajari ciri-ciri spesifik kelompok tersebut – misalnya gaya produksi, karakteristik rekaman, atau suara latar khas suatu film – sebagai jalan pintas untuk memprediksi label, alih-alih benar-benar mempelajari pola yang ingin dikenali (dalam konteks penelitian ini, pola akustik emosi). Akibatnya, performa yang dilaporkan pada skema *random* cenderung terlihat lebih tinggi daripada performa sesungguhnya yang akan diperoleh model pada data dari sumber yang benar-benar baru.

Skema pembagian data *movie-independent* (satu ragam *grouped split*) mengatasi risiko *group leakage* tersebut dengan menjaga agar seluruh klip yang berasal dari film yang sama selalu berada pada sisi *fold* yang sama – tidak pernah ada satu film yang klipnya tersebar ke sisi latih dan uji sekaligus. Dengan demikian, ketika suatu film digunakan sebagai data uji, model benar-benar belum pernah “melihat” karakteristik rekaman film tersebut selama pelatihan, sehingga performa yang terukur mencerminkan kemampuan generalisasi model pada sumber rekaman yang genuinely baru. Preseden penerapan skema *grouped* semacam ini pada SER dilaporkan oleh Tang et al. (2023), yang menerapkan skema evaluasi *speaker-independent* – varian *grouped split* berdasarkan identitas penutur, bukan berdasarkan film – untuk mencegah model mempelajari isyarat spesifik penutur alih-alih pola emosi yang genuinely general. Penelitian ini menerapkan prinsip yang sama pada satuan film, karena unit kebocoran yang relevan pada dataset yang digunakan adalah sumber film, bukan identitas penutur individual.

Penelitian ini membandingkan performa algoritma yang diuji di bawah kedua skema tersebut – *random* dan *movie-independent* – untuk mengukur secara langsung seberapa besar performa yang dilaporkan berpotensi terinflasi oleh *group leakage* berbasis film, dan apakah besar inflasi tersebut berbeda antara algoritma berbasis fitur *hand-crafted* dan algoritma berbasis representasi *self-supervised*.

2.4 Fitur Hand-Crafted

Fitur *hand-crafted* adalah representasi sinyal yang diekstraksi secara manual melalui rangkaian transformasi sinyal yang telah ditentukan terlebih dahulu (*fi-*

ted) berdasarkan teori dan pengetahuan domain, alih-alih dipelajari otomatis oleh model dari data. Pada domain pemrosesan ucapan, fitur *hand-crafted* umumnya dirancang untuk menangkap karakteristik akustik yang secara teoretis relevan dengan tugas yang ingin diselesaikan, misalnya intonasi, energi, nada dasar (*pitch*), atau distribusi frekuensi sinyal. Karena rangkaian transformasinya sudah ditentukan sejak awal, fitur *hand-crafted* tidak memerlukan data berlabel maupun proses pembelajaran untuk diperoleh, berbeda dengan representasi yang dipelajari model dari data (*learned representations*) yang parameternya disesuaikan melalui proses pelatihan.

Pendekatan fitur *hand-crafted* banyak digunakan pada penelitian SER sebelum berkembangnya representasi yang dipelajari model, karena tidak memerlukan data pra-latih berskala besar dan relatif murah secara komputasi untuk diekstraksi. Salah satu fitur *hand-crafted* yang paling umum digunakan pada pemrosesan ucapan adalah Mel-Frequency Cepstral Coefficients (MFCC), yang digunakan sebagai representasi fitur *hand-crafted* pada penelitian ini.


2.5 Mel-Frequency Cepstral Coefficients (MFCC)

Mel-Frequency Cepstral Coefficients (MFCC) adalah representasi fitur akustik *hand-crafted* yang secara luas digunakan pada tugas pemrosesan ucapan, dirancang untuk meniru cara sistem pendengaran manusia mempersepsikan frekuensi bunyi secara tidak linear (Davis and Mermelstein, 1980). Alih-alih menggunakan skala frekuensi linear (Hz), MFCC memetakan spektrum sinyal ke skala mel, yang lebih sensitif terhadap perbedaan pada frekuensi rendah dibandingkan frekuensi tinggi, sebagaimana Persamaan 2.1.

$$m = 2595 \log_{10} \left(1 + \frac{f}{700} \right) \quad (2.1)$$

di mana f adalah frekuensi dalam Hz dan m adalah frekuensi terskala mel yang bersesuaian.

Ekstraksi MFCC dari sinyal ucapan mentah dilakukan melalui serangkaian tahap sebagaimana digambarkan pada Gambar 2.2. Sinyal terlebih dahulu melalui *pre-emphasis* untuk menguatkan komponen frekuensi tinggi, kemudian dibagi menjadi bingkai-bingkai pendek (*framing*) yang tumpang tindih dan dikalikan fungsi jendela (*windowing*) untuk mengurangi efek diskontinuitas di tepi bingkai. Setiap bingkai kemudian ditransformasi ke domain frekuensi menggunakan *Fast Fourier Transform* (FFT) untuk memperoleh spektrum daya, yang selanjutnya difilter menggunakan sekumpulan filter *bank* berskala mel (Persamaan 2.1) untuk memperoleh energi pada tiap pita frekuensi mel. Energi tersebut diambil logaritmanya untuk mendekati persepsi kenyaringan manusia yang bersifat logaritmik, kemudian ditransformasi menggunakan *Discrete Cosine Transform* (DCT) untuk mendekorelasi energi antarpita dan menghasilkan koefisien cepstral akhir.




Gambar 2.2 Pipeline ekstraksi Mel-Frequency Cepstral Coefficients (MFCC)

Sumber : Alashban and Alotaibi (2023)

Berbeda dengan representasi yang dipelajari model dari data (*learned representations*), MFCC dihitung langsung dari sinyal melalui rangkaian transformasi sinyal yang telah ditentukan (*fixed*), tanpa proses pembelajaran. Karakteristik inilah yang mendasari penggunaan MFCC sebagai fitur *hand-crafted* pada algoritma *baseline* dalam penelitian ini.

2.6 Convolutional Neural Network (CNN)

Convolutional neural network (CNN) adalah arsitektur jaringan saraf tiruan yang dirancang untuk memproses data yang memiliki struktur grid, seperti citra dua dimensi atau spektrogram ucapan, dengan memanfaatkan operasi konvolusi untuk mengekstraksi pola-pola lokal secara bertingkat (LeCun et al., 1998). Arsitektur CNN umumnya terdiri atas tiga jenis lapisan utama, sebagaimana digambarkan pada Gambar 2.3: (1) lapisan konvolusi (*convolutional layer*), yang menerapkan sejumlah filter/*kernel* berukuran kecil secara bergeser di sepanjang data masukan untuk mendeteksi pola lokal seperti tepi atau tekstur pada tahap awal, dan pola yang lebih kompleks pada lapisan berikutnya; (2) lapisan *pooling*, yang mereduksi dimensi spasial representasi sambil mempertahankan informasi penting, sehingga jaringan lebih tahan terhadap pergeseran kecil pada data masukan dan lebih efisien secara komputasi; dan (3) lapisan terhubung penuh (*fully-connected layer*), yang menggabungkan seluruh fitur yang telah diekstraksi untuk menghasilkan keluaran akhir, misalnya probabilitas kelas pada tugas klasifikasi. Secara garis besar, lapisan konvolusi dan *pooling* membentuk tahap ekstraksi fitur (*feature extraction*), sedangkan lapisan terhubung penuh membentuk tahap klasifikasi (*classification*), sebagaimana ditunjukkan pada Gambar 2.3.




Gambar 2.3 Arsitektur umum Convolutional Neural Network (CNN)

Sumber : Phung and Rhee (2019)

Kemampuan lapisan konvolusi mendeteksi pola lokal menjadikan CNN cocok untuk memproses fitur MFCC, yang berbentuk grid dua dimensi berupa koefisien cepstral pada sumbu vertikal dan bingkai waktu pada sumbu horizontal – pola akustik emosi yang relevan seringkali muncul sebagai struktur lokal pada grid tersebut, misalnya perubahan energi pada rentang waktu dan pita frekuensi tertentu. Karakteristik inilah yang mendasari penggunaan CNN sebagai *classifier* pada algoritma *baseline* dalam penelitian ini, mengikuti pendekatan yang sudah banyak digunakan pada penelitian SER berbasis fitur *hand-crafted*.

2.7 Pembelajaran Self-Supervised

Pembelajaran *self-supervised* adalah paradigma pembelajaran mesin yang melatih model pada data tanpa label dengan cara menciptakan sinyal pengawasan (*supervision signal*) dari data itu sendiri, alih-alih memerlukan label yang dianotasi manusia (Liu et al., 2023). Model dilatih untuk menyelesaikan *pretext task*, yaitu tugas bantu yang dirancang agar penyelesaiannya mengharuskan model mempelajari struktur dan pola yang mendasari data, misalnya memprediksi bagian data yang disembunyikan dari bagian yang tersisa. Sebagaimana ditunjukkan pada Gambar 2.4, bobot *encoder* yang telah dilatih pada *pretext task* menggunakan data tanpa label kemudian ditransfer (*transfer weights*) sebagai titik awal model pada tugas hilir (*downstream task*) yang sesungguhnya, sebelum diadaptasi lebih lanjut (*fine-tuned*) menggunakan data berlabel, seperti klasifikasi emosi pada penelitian ini.




Gambar 2.4 Alur umum pembelajaran Self-Supervised

Sumber : Del Pup and Atzori (2023)

Keunggulan utama paradigma ini adalah kemampuannya memanfaatkan data tanpa label dalam jumlah besar, yang jauh lebih mudah dan murah diperoleh dibandingkan data berlabel. Karakteristik inilah yang mendasari penggunaannya secara luas pada domain ucapan, termasuk pada backbone Wav2Vec2 dan XLSR-53 yang digunakan dalam penelitian ini.

2.8 Wav2Vec2

Wav2Vec2 adalah arsitektur pembelajaran *self-supervised* untuk representasi ucapan yang dilatih pada volume data ucapan tanpa label berskala besar (Babevski et al., 2020). Arsitekturnya terdiri atas tiga komponen utama, sebagaimana digambarkan pada Gambar 2.5: (1) *feature encoder* berbasis *convolutional neural network* (CNN) yang mengubah gelombang ucapan mentah menjadi representasi laten Z pada resolusi waktu yang lebih rendah; (2) *context network* berbasis Transformer yang mengolah Z (dengan sebagian di antaranya disembunyikan/*masked*) menjadi representasi terkontekstualisasi C ; dan (3) modul kuantisasi yang mendiskretkan Z menjadi target kuantisasi Q , khusus digunakan pada tahap pra-latih untuk menghitung *contrastive loss* yang mendorong model membedakan representasi kuantisasi yang benar dari sejumlah pengganggu (*distractors*).



Gambar 2.5 Arsitektur Wav2Vec2
 Sumber : Ovalle et al. (2024)

Representasi $\mathcal{C}$ yang dihasilkan oleh *context network* inilah yang menjadi keluaran utama Wav2Vec2 untuk dimanfaatkan pada tugas hilir (*downstream task*), termasuk SER pada penelitian ini.

2.9 XLSR-53

XLSR merupakan varian multibahasa dari Wav2Vec2 yang dilatih pada data ucapan tanpa label dari banyak bahasa sekaligus, menggunakan arsitektur dan tujuan pra-latih yang sama, namun dengan korpus pra-latih gabungan lintas bahasa (Conneau et al., 2021). Karena dilatih lintas bahasa, representasi yang dihasilkan XLSR cenderung menangkap struktur akustik yang lebih umum dan dapat menggeneralisasi lintas bahasa dibandingkan model yang hanya dilatih pada satu bahasa saja. XLSR-53 adalah varian XLSR yang dilatih pada korpus gabungan dari 53 bahasa. Karakteristik inilah yang mendasari pemilihan XLSR-53 sebagai backbone algoritma SOTA dalam penelitian ini: bobot dasar backbone tetap dibekukan (*frozen*), namun diberi matriks adaptasi tambahan berperingkat rendah (LoRA) yang dilatih untuk menyesuaikan representasi ke tugas SER, alih-alih memperbarui seluruh parameter backbone secara langsung.


2.10 Low-Rank Adaptation (LoRA)

Low-Rank Adaptation (LoRA) adalah strategi *fine-tuning* efisien-parameter yang membekukan seluruh bobot model dasar W_0 dan hanya melatih sepasang ma-

triks tambahan berperingkat rendah (*low-rank*) yang disisipkan secara paralel (Hu et al., 2022). Untuk suatu lapisan dengan bobot pra-latih $W_0 \in \mathbb{R}^{d \times k}$, LoRA merepresentasikan pembaruan bobot ΔW sebagai perkalian dua matriks berperingkat rendah $B \in \mathbb{R}^{d \times r}$ dan $A \in \mathbb{R}^{r \times k}$, dengan $r \ll \min(d, k)$, sehingga keluaran lapisan tersebut untuk masukan x dihitung sebagaimana Persamaan 2.2.

$$h = W_0x + \Delta Wx = W_0x + BAx \quad (2.2)$$

Gambar 2.6 membandingkan skema tersebut dengan *full fine-tuning* konvensional. Pada *full fine-tuning* (kiri), pembaruan bobot ΔW dilatih penuh sebagai satu matriks padat berukuran sama dengan W_0 . Pada LoRA (kanan), bobot dasar W_0 dibekukan (ditandai ikon salju) sementara hanya matriks A dan B berperingkat rendah yang dilatih (ditandai ikon api), sebelum hasil keduanya dijumlahkan menjadi keluaran h .



Gambar 2.6 Perbandingan full fine-tuning dan LoRA

Sumber : Lu et al. (2024)

Karena jumlah parameter pada A dan B jauh lebih sedikit daripada jumlah parameter W_0 , LoRA menawarkan efisiensi komputasi dan memori yang signifikan dibandingkan *full fine-tuning*, yang memperbarui seluruh parameter W_0 secara langsung. Efisiensi ini relevan bagi penelitian dengan keterbatasan sumber daya komputasi. Efektivitas LoRA pada arsitektur berbasis Wav2Vec2 secara spesifik telah dibuktikan pada tugas deteksi audio sintesis, di mana LoRA mencapai performa setara dengan *full fine-tuning* sekaligus mengurangi jumlah parameter yang dilatih hingga 198 kali lipat (Wang et al., 2023). Pada tugas SER secara lebih spesifik, kombinasi LoRA dengan metode *parameter-efficient fine-tuning* lainnya terbukti melampaui performa *full fine-tuning* pada backbone Wav2Vec2 dan HuBERT, sekaligus hanya melatih sekitar 2–3% dari total parameter (Lashkarashvili et al., 2024). Karakteristik inilah yang mendasari penggunaan LoRA untuk mengadaptasi backbone XLSR-53 pada algoritma SOTA dalam penelitian ini, alih-alih memperbarui seluruh parameter backbone secara langsung.

2.11 Evaluasi Model

Akurasi, presisi, recall, dan F1-score adalah empat metrik yang umum digunakan untuk mengevaluasi performa model klasifikasi (Powers, 2011). Akurasi mengukur proporsi prediksi yang benar terhadap keseluruhan data uji, sehingga memberikan gambaran umum performa model, sebagaimana Persamaan 2.3.

$$\text{Akurasi} = \frac{TP + TN}{TP + TN + FP + FN} \quad (2.3)$$

di mana $TP = \text{True Positive}$, $TN = \text{True Negative}$, $FP = \text{False Positive}$, $FN = \text{False Negative}$.

Akan tetapi, pada data dengan sebaran kelas yang tidak seimbang, akurasi dapat memberikan gambaran yang menyesatkan, karena model yang selalu memprediksi kelas mayoritas tetap dapat memperoleh akurasi tinggi tanpa benar-benar mengenali kelas minoritas. Presisi mengukur proporsi prediksi positif yang benar-benar tepat, sebagaimana Persamaan 2.4.

$$\text{Presisi} = \frac{TP}{TP + FP} \quad (2.4)$$

Recall mengukur proporsi kasus positif yang berhasil dikenali model, sebagaimana Persamaan 2.5.

$$\text{Recall} = \frac{TP}{TP + FN} \quad (2.5)$$

Presisi dan recall sering kali saling bertukar (*trade-off*): menaikkan salah satu cenderung menurunkan yang lain. F1-score mengatasi keterbatasan ini dengan merepresentasikan rata-rata harmonis keduanya, sebagaimana Persamaan 2.6.

$$F_1 = 2 \cdot \frac{\text{Presisi} \times \text{Recall}}{\text{Presisi} + \text{Recall}} \quad (2.6)$$

Keempat metrik ini digunakan bersama dalam penelitian ini untuk memberikan gambaran performa yang lebih menyeluruh terhadap setiap kondisi yang dibandingkan. Meskipun skema kelas emosi pada dataset yang digunakan dalam penelitian ini seimbang antarkelas, akurasi saja tidak menunjukkan pola kesalahan per kelas, sedangkan presisi, recall, dan F1-score memberikan gambaran lebih rinci mengenai kelas emosi mana yang lebih sering tertukar atau lebih sulit dikenali model.

2.12 Validasi Silang K-Fold

Validasi silang k-fold adalah teknik evaluasi yang membagi data menjadi k bagian (*fold*) berukuran relatif sama, dengan setiap bagian secara bergantian digunakan sebagai data uji sementara $k - 1$ bagian lainnya digunakan sebagai data latih, sehingga setiap bagian data pernah menjadi data uji tepat satu kali (Kohavi, 1995). Gambar 2.7 mengilustrasikan mekanisme umum tersebut: *fold* uji (biru) berpindah bergiliran pada tiap iterasi sementara *fold* sisanya berperan sebagai data latih, dengan hasil evaluasi E_i dari tiap iterasi dirata-ratakan menjadi estimasi performa akhir E . Penelitian ini secara spesifik menggunakan $k = 6$.



Gambar 2.7 Ilustrasi mekanisme validasi silang k-fold

Sumber : Ashfaque and Iqbal (2019)

Teknik ini menghasilkan k observasi akurasi dan F1-score, satu untuk setiap fold, sehingga memungkinkan pengujian konsistensi performa antar-fold untuk setiap kondisi yang diuji, bukan hanya satu nilai tunggal dari satu kali pengujian.

2.13 Pengujian Signifikansi Statistik

Untuk menguji apakah perbedaan performa antarkondisi hasil validasi silang k-fold bersifat signifikan secara statistik, k observasi yang diperoleh terlebih dahulu diuji normalitasnya menggunakan uji Shapiro-Wilk, yang menghitung statistik W sebagaimana Persamaan 2.7 (Shapiro and Wilk, 1965).

$$W = \frac{(\sum_{i=1}^n a_i x_{(i)})^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \quad (2.7)$$

di mana $x_{(i)}$ adalah nilai observasi ke- i setelah diurutkan menaik (statistik urutan), $\bar{x}$ adalah rata-rata observasi, n adalah jumlah observasi (jumlah fold), dan a_i adalah konstanta yang diturunkan dari rata-rata, ragam, dan kovarians statistik urutan sampel berdistribusi normal berukuran n . Nilai W yang mendekati 1 mengindikasikan data mendekati distribusi normal.

Apabila data berdistribusi normal, pengujian dilanjutkan dengan *paired t-test*, yang menghitung statistik uji t dari selisih berpasangan d_i antara dua kondisi pada fold yang sama, sebagaimana Persamaan 2.8.

$$t = \frac{\bar{d}}{s_d/\sqrt{n}} \quad (2.8)$$

di mana $\bar{d}$ adalah rata-rata selisih berpasangan, s_d adalah simpangan baku selisih tersebut, dan n adalah jumlah fold. Apabila data tidak berdistribusi normal, digunakan *Wilcoxon signed-rank test* sebagai alternatif non-parametrik yang tidak mengasumsikan distribusi tertentu, dengan statistik uji W sebagaimana Persamaan 2.9 (Wilcoxon, 1945).


$$W = \sum_{i=1}^n \text{sgn}(d_i) R_i \quad (2.9)$$

di mana d_i adalah selisih berpasangan pada fold ke- i , R_i adalah peringkat (*rank*) dari $|d_i|$ di antara seluruh selisih mutlak $|d_1|, \dots, |d_n|$, dan $\text{sgn}(d_i)$ bernilai $+1$ apabila $d_i > 0$ dan -1 apabila $d_i < 0$.

BAB 3 METODOLOGI PENELITIAN

3.1 Tipe Penelitian

Penelitian ini merupakan penelitian non-implementatif analitik dengan pendekatan kuantitatif, karena berfokus pada analisis pengaruh skema pembagian data terhadap akurasi klasifikasi emosi ucapan, bukan pada pengembangan sistem atau perangkat lunak siap pakai. Sifat analitik ditunjukkan melalui pengolahan data hasil observasi akurasi dan F1-score dari setiap kondisi eksperimen untuk mengkaji hubungan antara skema pembagian data yang digunakan dan performa klasifikasi emosi yang dihasilkan. Pendekatan kuantitatif digunakan karena data berupa nilai numerik hasil evaluasi model yang dianalisis menggunakan metrik akurasi, F1-score, dan pengujian signifikansi statistik. Model-model yang dilatih pada penelitian ini berfungsi sebagai instrumen untuk menghasilkan data observasi tersebut, bukan sebagai produk/artefak utama penelitian.



Gambar 3.1 Diagram alir metode penelitian

Diagram alir metode penelitian ini ditunjukkan pada Gambar 3.1. Tahap awal penelitian diawali dengan studi literatur, yang bertujuan untuk mengkaji teori, metode, serta penelitian terdahulu yang relevan dengan SER dan kebocoran data

pada skema evaluasi. Tahap berikutnya adalah pengumpulan data, yaitu proses pengumpulan dataset SER berbahasa Indonesia yang digunakan dalam penelitian ini. Data yang telah diperoleh selanjutnya diproses pada tahap perancangan algoritma, yaitu merancang algoritma *baseline* berbasis fitur *hand-crafted* dan algoritma SO-TA berbasis representasi *self-supervised*. Tahap berikutnya adalah evaluasi k-fold untuk menilai performa setiap kondisi eksperimen menggunakan skema validasi silang dan pengujian signifikansi statistik. Hasil evaluasi tersebut kemudian digunakan sebagai dasar pada tahap analisis hasil, yang merangkum temuan penelitian serta menjawab rumusan masalah yang telah dipaparkan.

3.2 Studi Literatur

Studi literatur merupakan tahap awal penelitian yang bertujuan untuk mempelajari dan memahami teori, konsep, serta hasil penelitian terdahulu yang berkaitan dengan SER, kebocoran data pada skema evaluasi, fitur *hand-crafted* MFCC, *convolutional neural network*, representasi *self-supervised* Wav2Vec2/XLSR-53, dan *Low-Rank Adaptation* (LoRA). Pada tahap ini dilakukan pengkajian terhadap jurnal, prosiding konferensi, dan sumber ilmiah relevan untuk memastikan celah penelitian pada Bab 2 Landasan Kepustakaan belum terjawab oleh penelitian lain, sekaligus menentukan algoritma dan skema pembagian data yang sesuai dengan tujuan penelitian.

3.3 Pengumpulan Data

Tahap ini mengumpulkan dataset E-SERAVID v1.1 (Santoso, Budianto and Dutono, 2026), yaitu dataset SER berbahasa Indonesia yang bersumber dari 6 judul film Indonesia: Ada Apa Dengan Cinta (AADC), Dilan 1990 (D1990), Dua Hati Biru (DHB), Habibie & Ainun 3 (HA3), Home Sweet Loan (HSL), dan The Architecture of Love (TAOL). Dataset ini terdiri atas 1.200 klip ucapan emosional, seimbang sempurna pada 4 kelas emosi (marah, sedih, netral, bahagia) dengan 300 klip per kelas. Durasi klip berkisar 0,83–6,87 detik dengan rata-rata sekitar 2,6 detik, dalam format audio 44.100 Hz, 32-bit float, 2 channel. Tabel 3.1 merangkum karakteristik dataset tersebut.

Tabel 3.1 Karakteristik dataset E-SERAVID v1.1

Atribut	Nilai
Bahasa	Indonesia
Jumlah klip	1.200
Jumlah kelas emosi	4 (marah, sedih, netral, bahagia)
Sampel per kelas	300

Atribut	Nilai
Jumlah film sumber	6
Durasi klip	0,83–6,87 detik (rata-rata $\sim$ 2,6 detik)
Format audio	44.100 Hz, 32-bit float, 2 channel

Dataset E-SERAVD memiliki 3 versi berbeda. Versi v1.0 (PENS-SER Dataset) dan versi v1.1 (E-SERAVD) identik secara *byte-for-byte*, keduanya berisi 1.200 klip dengan 4 kelas dan 6 film yang sama. Versi v1.2 merupakan versi lebih baru yang mengklaim 3.000 klip pada 6 kelas emosi (menambahkan kelas jijik dan takut) dari 11 film, tetapi ditemukan anomali pada tabel Fleiss Kappa dalam dokumentasinya yang secara matematis tidak konsisten dengan jumlah klip tervalidasi yang diklaim, sehingga validitas anotasinya belum dapat dipastikan. Penelitian ini menggunakan v1.1 karena identik dengan v1.0 yang telah diverifikasi langsung terhadap dokumentasi spesifikasinya, dan sesuai dengan dataset yang digunakan Santoso, Budianto and Dutono (2026) untuk menetapkan *baseline* yang direplikasi pada penelitian ini.

E-SERAVD v1.1 tidak menyediakan fitur akustik siap pakai, sehingga koefisien MFCC diekstraksi langsung dari berkas audio pada penelitian ini. Dataset SER Indonesia lain seperti IndoWaveSentiment (Nugroho et al., 2025) tidak digunakan pada penelitian ini karena skala dan skema kelasnya berbeda dari E-SERAVD, namun disebutkan kembali sebagai arah pengembangan pada Bab 6.

Sebaran film sumber pada dataset ini tidak merata antarkelas emosi, sebagaimana dirangkum pada Tabel 3.2.

Tabel 3.2 Distribusi jumlah klip per film dan kelas emosi

Kelas	AADC	D1990	DHB	HA3	HSL	TAOL
Netral	50	50	50	50	50	50
Marah	54	35	54	51	53	53
Sedih	58	7	106	32	55	42
Bahagia	12	74	41	73	64	36

Kelas netral tersebar rata sempurna antarfilm, tetapi kelas sedih didominasi oleh film DHB (106 dari 300 klip, 35%) dan kelas bahagia didominasi oleh film D1990 dan HA3 (147 dari 300 klip, 49%). Apabila pembagian data latih dan uji dilakukan secara acak murni, klip dari film yang sama berisiko muncul pada kedua sisi sekaligus, sehingga model berpotensi mempelajari gaya produksi atau karakteristik rekaman film tertentu sebagai proxy kelas emosi, bukan pola akustik emosi yang genuinely general. Risiko ini menjadi dasar bagi penelitian ini untuk menguji secara eksplisit pengaruh skema pembagian data – *random* dibandingkan *movie-independent* – terhadap performa klasifikasi emosi.

3.4 Perancangan Algoritma

Tahap ini merancang dua algoritma yang dibandingkan pada penelitian ini dari dataset yang sama, masing-masing mengikuti pendekatan aslinya, supaya Kondisi A menjadi replikasi yang setia terhadap konfigurasi Santoso, Budianto and Dutono (2026).

Algoritma *baseline* mengekstraksi koefisien MFCC dari klip audio, kemudian mengklasifikasikannya menggunakan *convolutional neural network* (CNN) yang dilatih dari nol, mengikuti pendekatan Santoso, Budianto and Dutono (2026).

Algoritma SOTA mengekstraksi representasi dari backbone XLSR-53 (facebook/wav2vec2-large-xlsr-53), dengan bobot dasar backbone dibekukan (*frozen*) dan matriks adaptasi berperingkat rendah (LoRA) disisipkan pada lapisan-lapisan Transformer-nya. Matriks adaptasi tersebut dilatih bersama *classification head* secara *end-to-end* pada data target, berbeda dari pendekatan Nugroho et al. (2025) yang menguji model dasar XLSR-Wav2Vec2 yang sudah di-*fine-tune* penuh untuk ucapan Indonesia oleh pihak lain.

Kedua algoritma ini dirancang dan dilatih secara independen di bawah dua skema pembagian data, menghasilkan empat kondisi eksperimen sebagaimana dirangkum pada Tabel 3.3.

Tabel 3.3 Empat kondisi eksperimen (desain 2×2)

Kondisi	Algoritma	Skema Pembagian Data
A	CNN + MFCC	Random
B	CNN + MFCC	Movie-Independent
C	XLSR-53 + LoRA	Random
D	XLSR-53 + LoRA	Movie-Independent

Kondisi A berfungsi sebagai replikasi konfigurasi Santoso, Budianto and Dutono (2026); performa yang mendekati *baseline* 86% akurasi dan 86% F1-macro pada kondisi ini menjadi indikator bahwa metodologi replikasi telah dilakukan secara benar. Selisih performa antara Kondisi B dan A, serta antara Kondisi D dan C, masing-masing mengukur besar penurunan performa akibat skema pembagian data yang lebih ketat untuk algoritma *baseline* dan algoritma SOTA. Perbandingan kedua selisih tersebut menjawab pertanyaan inti penelitian: apakah algoritma SOTA lebih tahan terhadap kebocoran data dibandingkan algoritma *baseline*.

3.5 Evaluasi K-Fold

Tahap ini mengevaluasi keempat kondisi eksperimen menggunakan dua skema pembagian data. Skema *random* membagi seluruh klip secara acak ke dalam

$k = 6$ *fold* tanpa mempertimbangkan sumber film. Skema *movie-independent* membagi klip berdasarkan film sumber, dengan $k = 6$ – satu film sebagai *fold* uji secara bergantian, sedangkan kelima film lainnya digunakan sebagai data latih; skema ini dipilih karena persis 6 film tersedia pada dataset, sehingga setiap film dapat menjadi *fold* tersendiri tanpa perlu menggabungkan beberapa film secara arbitrer. Jumlah *fold* yang sama ($k = 6$) digunakan pada kedua skema, supaya perbedaan hasil yang teramati dapat ditarik ke skema pembagian data yang diuji, bukan ke perbedaan granularitas *fold*. Tahap ini menghasilkan beberapa observasi akurasi dan F1-score per fold untuk masing-masing kondisi.

3.6 Analisis Hasil

Data hasil observasi dari validasi silang k-fold terlebih dahulu diuji normalitasnya menggunakan uji Shapiro-Wilk. Jika data berdistribusi normal, pengujian dilanjutkan dengan *paired t-test*; jika tidak, digunakan *Wilcoxon signed-rank test*. Pengujian signifikansi dilakukan pada dua tingkat: pertama, antara Kondisi A dan B, serta antara Kondisi C dan D, untuk mengetahui pengaruh skema pembagian data terhadap performa pada masing-masing algoritma (Rumusan Masalah 1); kedua, dengan membandingkan besar selisih performa Kondisi B terhadap A dengan besar selisih performa Kondisi D terhadap C, untuk mengetahui apakah pengaruh tersebut konsisten antaralgoritma (Rumusan Masalah 2).

Tahap ini kemudian menafsirkan hasil pengujian signifikansi statistik tersebut untuk menjawab rumusan masalah penelitian, serta menyusun rekomendasi metodologis dan algoritma yang paling sesuai untuk pengembangan SER berbahasa Indonesia berdasarkan temuan yang diperoleh.

3.7 Kesimpulan dan Saran

Penarikan kesimpulan dilaksanakan setelah seluruh tahap evaluasi dan analisis hasil selesai. Kesimpulan memuat jawaban atas rumusan masalah yang telah dituliskan sebelumnya, mengacu pada hasil pengujian signifikansi statistik atas pengaruh skema pembagian data dan konsistensinya antaralgoritma yang dibandingkan. Selain kesimpulan, disusun pula saran sebagai bahan pertimbangan dan perbaikan untuk penelitian selanjutnya, misalnya augmentasi data atau pengujian algoritma lain di luar CNN+MFCC dan XLSR-53+LoRA.

DAFTAR REFERENSI

- Alashban, A.A. and Alotaibi, Y.A., 2023. A deep learning approach for identifying and discriminating spoken Arabic among other languages. *IEEE Access*, 11, pp.11613-11628. <https://doi.org/10.1109/ACCESS.2023.3241855>
- Antoniou, N., Katsamanis, A., Giannakopoulos, T. and Narayanan, S., 2023. Designing and evaluating speech emotion recognition systems: a reality check case study with IEMOCAP. In: *2023 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. IEEE, pp.1-5. <https://doi.org/10.1109/ICASSP49357.2023.10096808>
- Ashfaq, J.M. and Iqbal, A., 2019. Introduction to support vector machines and kernel methods. *Preprint*, pp.1-9.
- Atmaja, B.T. and Sasou, A., 2022. Evaluating self-supervised speech representations for speech emotion recognition. *IEEE Access*, 10, pp.124396-124407. <https://doi.org/10.1109/ACCESS.2022.3225198>
- Baevski, A., Zhou, H., Mohamed, A. and Auli, M., 2020. wav2vec 2.0: a framework for self-supervised learning of speech representations. *Advances in Neural Information Processing Systems (NeurIPS)*, 33, pp.12449-12460.
- Bella, G., Helm, P., Koch, G. and Giunchiglia, F., 2023. Towards bridging the digital language divide. *arXiv:2307.13405 [cs.CL]*.
- Conneau, A., Baevski, A., Collobert, R., Mohamed, A. and Auli, M., 2021. Unsupervised cross-lingual representation learning for speech recognition. In: *Proceedings of Interspeech 2021*, pp.2426-2430.
- Dar, G.H.M. and Delhibabu, R., 2024. Speech databases, speech features, and classifiers in speech emotion recognition: a review. *IEEE Access*, 12, pp.151122-151152. <https://doi.org/10.1109/ACCESS.2024.3476960>
- Davis, S.B. and Mermelstein, P., 1980. Comparison of parametric representations for monosyllabic word recognition in continuously spoken sentences. *IEEE Transactions on Acoustics, Speech, and Signal Processing*, 28(4), pp.357-366. *[Rujukan klasik yang banyak dikutip di literatur pemrosesan ucapan; detail volume/nomor/halaman perlu diverifikasi ulang ke sumber utama sebelum submit.]*
- Del Pup, F. and Atzori, M., 2023. Applications of self-supervised learning to biomedical signals: where are we now. *TechRxiv preprint*. <https://doi.org/10.36227/techrxiv.22567021>
- Hu, E.J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., Wang, L. and Chen, W., 2022. LoRA: low-rank adaptation of large language models. In: *International Conference on Learning Representations (ICLR)*.
- Kapoor, S. and Narayanan, A., 2023. Leakage and the reproducibility crisis in machine-learning-based science. *Patterns*, 4(9), 100804. <https://doi.org/10.1016/j.patter.2023.100804>

Kohavi, R., 1995. A study of cross-validation and bootstrap for accuracy estimation and model selection. In: *Proceedings of the 14th International Joint Conference on Artificial Intelligence (IJCAI)*, 2, pp.1137-1143.

Lashkarashvili, N., Wu, W., Sun, G. and Woodland, P.C., 2024. Parameter efficient finetuning for speech emotion recognition and domain adaptation. In: *2024 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. IEEE, pp.10986-10990. <https://doi.org/10.48550/arXiv.2402.11747>

LeCun, Y., Bottou, L., Bengio, Y. and Haffner, P., 1998. Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11), pp.2278-2324. [Rujukan klasik CNN yang banyak dikutip; detail volume/nomor/halaman perlu diverifikasi ulang ke sumber utama sebelum submit.]

Liu, X., Zhang, F., Hou, Z., Mian, L., Wang, Z., Zhang, J. and Tang, J., 2023. Self-supervised learning: generative or contrastive. *IEEE Transactions on Knowledge and Data Engineering*, 35(1), pp.857-876.

Lu, Y., Qi, J., Luan, Z., Huang, S., Fung, C., Yang, H. and Qian, D., 2024. FDLORA: personalized federated learning of large language model via dual LoRA tuning. *arXiv:2406.07925 [cs.DC]*.

Nugroho, K.S., Iriananda, S.W., Akbar, I., Isnani, M. and Pardamean, B., 2025. Advancing end-to-end Indonesian speech emotion recognition using XLSR-Wav2Vec2. In: *2025 International Conference on Information Technology Research and Innovation (ICITRI)*. IEEE. <https://doi.org/10.1109/ICITRI67507.2025.11232655>

Ovalle, C.D., Vallejos García, I.L. and Zapata Berrios, F.R., 2024. Real-time transcriptionist based on artificial intelligence to facilitate learning for people with hearing disabilities in virtual classes. *International Journal of Online and Biomedical Engineering (iJOE)*, 20(3), pp.75-88.

Phung, V.H. and Rhee, E.J., 2019. A high-accuracy model average ensemble of convolutional neural networks for classification of cloud image patches on small datasets. *Applied Sciences*, 9(21), 4500. <https://doi.org/10.3390/app9214500>

Powers, D.M.W., 2011. Evaluation: from precision, recall and F-measure to ROC, informedness, markedness and correlation. *Journal of Machine Learning Technologies*, 2(1), pp.37-63.

Santoso, T.B., Budianto, A.N. and Dutono, T., 2026. Development of a speech emotion recognition dataset for Indonesian. *IEEE Access*. <https://doi.org/10.1109/ACCESS.2026.3652377>

Shapiro, S.S. and Wilk, M.B., 1965. An analysis of variance test for normality (complete samples). *Biometrika*, 52(3-4), pp.591-611.

Tang, D., Kuppens, P., Geurts, L. and van Waterschoot, T., 2023. End-to-end transfer learning for speaker-independent cross-language and cross-corpus speech emotion recognition. *arXiv:2311.13678 [eess.AS]*.

Wang, C., Yi, J., Zhang, X., Tao, J., Xu, L. and Fu, R., 2023. Low-rank adaptation method for wav2vec2-based fake audio detection. In: *IJCAI 2023 Workshop on Deepfake Audio Detection and Analysis*. <https://doi.org/10.48550/arXiv.2306.05617>

Wilcoxon, F., 1945. Individual comparisons by ranking methods. *Biometrics Bulletin*, 1(6), pp.80-83.

Wu, H., Chou, H.-C., Chang, K.-W., Goncalves, L., Du, J., Jang, J.-S.R., Lee, C.-C. and Lee, H.-Y., 2024. EMO-SUPERB: an in-depth look at speech emotion recognition. *arXiv:2402.13018 [eess.AS]*.